Tender 心智化教育系统

零基础全流程教学手册 · 完整版

第一至四期：做、验、防、接

增补：开花、结果、森林

版本 5.3

2026 年 10 月 31 日

这本书写给谁

写给**没学过高等数学、没写过算法、没读过论文**的人。
读者只需要会：加减乘除、看百分比、用 Excel。

每一个公式都会先说明**它在说什么**，再说明**每个符号是什么**，
最后说明**它有什么用**，并配一个生活例子。

全文不假设任何先修知识。

目录

第一部分　项目总览与阅读指南 **2**

1　中心主旨：让 AI 成为森林的气候，让人成为生命树的作者 **2**

2　这份手册怎么用 **3**

2.1　一句话架构 3
2.2　三层技术栈 3
2.3　六层产品架构 3
2.4　架构图（从上到下读） 4
2.5　按角色的阅读路径 4

3　项目愿景与四个关键词 **5**

3.1　四个关键词 5
3.2　项目的一句话 5

4 术语统一说明 **6**

5 全书地图 **6**

6 四期地图：做、验、防、接 **7**

7 本书的三种证据 **7**

8 五个最容易犯的错 **7**

第二部分 数学、符号与零基础入门 **8**

9 这本书怎么读 **8**
9.1 三遍法 8
9.2 这本书的四个关键词 8

10 什么是模型：地图不是地形 **8**
10.1 生活类比 8
10.2 形式定义 9
10.3 在本书哪里用到 9

11 什么是指标：体温计和体重秤 **9**
11.1 生活类比 9
11.2 形式定义 9
11.3 好指标的三条标准 9
11.4 在本书哪里用到 10

12 什么是概率：下雨概率 30% **10**
12.1 生活类比 10
12.2 形式定义 10
12.3 最容易误解的地方 10

13 什么是基线：体温 36.5°C **10**
13.1 生活类比 10
13.2 形式定义 10
13.3 本书的最重要升级 11

14 什么是 AUC：医生诊断的区分能力 **11**
14.1 生活类比 11
14.2 形式定义 11
14.3 在本书哪里用到 11

15 什么是效应量和功效：放大镜够不够大 **11**
15.1 生活类比 11
15.2 形式定义 12
15.3 本书最重要的功效数字 12

16 什么是预注册：先写规则，再看数据 **12**
16.1 生活类比 12
16.2 为什么要预注册 12
16.3 预注册锁死什么 12

17 什么是元认知：知不知道自己会不会 **13**
17.1 生活类比 13
17.2 三个一阶指标 13
17.3 两个关键量 13

18 什么是 trait、state 和基线 **13**
18.1 三个词的白话解释 13
18.2 为什么不能把基线当 trait 14
18.3 扰动实验 14

19 一个贯穿全书的例子：小明学语法填空 **14**
19.1 第一期：做 14
19.2 第二期：验 14
19.3 第三期：防 14
19.4 第四期：接 15
19.5 小明的故事告诉我们 15

20 数学基础（零基础版） **15**
20.1 角度与弧度 15
20.1.1 角度 15
20.1.2 弧度 15
20.1.3 三角函数：cos 和 sin 16
20.2 概率 16
20.3 指数与对数 16
20.3.1 指数 16
20.3.2 sigmoid 函数 17
20.3.3 对数 17
20.4 黄金比 17
20.5 哈希 18
20.5.1 一个真实存在的陷阱：低熵值哈希可以被暴力破解 18

21 全部符号总索引 **19**

22 第二期新增的符号索引 **21**

23 第三期新增的符号索引 **22**

24 零基础符号与公式词典 **24**
24.1 元认知 . . . 24
24.2 犹豫与外部脚手架 . . . 24
24.3 耦合基线 . . . 24
24.4 节律与习惯 . . . 24
24.5 群体拓扑 . . . 25
24.6 尺度 . . . 25

25 统一符号词典 **26**
25.1 基础 . . . 26
25.2 元认知 . . . 26
25.3 耦合基线 . . . 26
25.4 节律、习惯与群体 . . . 26
25.5 尺度 . . . 27

第三部分　数据与基础设施层 **27**

26 数据怎么存 **27**
26.1 一条个人记录长什么样 . . . 27
26.1.1 九个字段逐个解释 . . . 27
26.2 群体记录 . . . 28
26.3 教育场景的扩展字段 . . . 28
26.4 出域白名单：五个字段 . . . 29

27 换单位：会话建模 **30**
27.1 转折点 . . . 30
27.2 新假设：基本单位应该是“一次会话” . . . 30
27.3 会话怎么定义 . . . 30
27.4 会话长什么样 . . . 31
27.5 核心结果 . . . 31
27.5.1 配对比较（24 名学生） . . . 31
27.5.2 加入时间重标检验（10 名会话数足够的学生） . . . 31
27.6 切分阈值的敏感性 . . . 31
27.7 三层结构终于闭合 . . . 32
27.8 剩下的 0.54 是什么 . . . 32

28 会话本身长什么样 **33**
28.1 会话有多大：幂律 33
28.2 会话内有疲劳吗：没有，反而有热身 33
28.3 有没有周周期：有，而且很强 34

第四部分 Tender 建模核心 **35**

29 心智化系统的核心公式 **35**
29.1 认知态：一个球面上的点 35
29.1.1 认知态的数学写法 35
29.1.2 从认知态推出“答对概率” 35
29.2 四源合成：θ 是怎么算出来的 36
29.3 序列分量：θ 怎么随时间变化 36
29.4 冲击响应饱和 37
29.5 临界纬线：什么时候算“该干预” 37
29.6 心智化窗口判据 38
29.7 三端的窗口化身 38

30 什么是“自激过程” **39**
30.1 先说什么叫“点过程” 39
30.2 自激是什么意思 39
30.3 Hawkes 过程的三个符号 39
30.4 强度函数：核心公式 40
30.5 分支比：判断会不会“自持” 40

31 第一次建模尝试：一个看起来很漂亮的结果 **41**
31.1 用什么数据 41
31.2 结果 41

32 分层模型：共享形状 **42**
32.1 为什么要共享 42
32.2 算法：交替优化 42
32.3 结果 42
32.4 拟合出的共享形状：一日双峰 42
32.5 产品价值：冷启动 43

33 从群体走向个体：MBTI 这条路 **44**
33.1 为什么想用 MBTI 44
33.2 但必须先说清楚它的证据基础 44
33.3 把抽象维度变成可测指标 44

33.3.1 四个行为指标怎么算 45

34 把 MBTI 和节律指标接起来 46
34.1 之前的因变量不够好 46
34.2 新因变量：把集中度拆成三个 46
34.2.1 实测示例 47
34.3 核心理论点：trait 与 state 必须分开 47
34.4 更新后的假设表 48
34.5 这个结合带来了三样东西 48
34.6 对预注册的影响 48

35 基线：用户与环境的耦合 50
35.1 为什么基线不是“固定性格” 50
35.2 形式定义：耦合动力系统 50
35.3 和 MBTI 的区别 50
35.4 扰动实验：怎么判断一个量是 trait 还是 baseline 51
35.5 真实数据：E2 与 E3 51
35.5.1 E2 节律–安排匹配（EdNet） 51
35.5.2 E3 习惯改变成本（OULAD） 52

36 节律–安排匹配与习惯改变成本 53
36.1 核心原则 53
36.2 E2：节律–安排匹配 53
36.2.1 定义 53
36.2.2 真实结果（EdNet） 53
36.2.3 功效 53
36.3 E3：习惯改变成本 54
36.3.1 定义 54
36.3.2 真实结果（OULAD） 54
36.3.3 边界 54
36.4 课堂怎么用 54

37 黄金比、基线闭环与自相似 55
37.1 三个概念要分开 55
37.1.1 基线闭环 55
37.1.2 自相似 55
37.1.3 黄金比 55
37.2 关键结论：自相似 + 闭环不自动推出黄金比 55
37.3 你项目里现在的数据 56
37.4 如果一定要检验它：预注册比例检验 56
37.5 更稳妥的“和谐”判据 56

第五部分　验证、防错与预注册 **57**

38 关键工具一：安慰剂检验 **57**
38.1 什么是安慰剂检验 . . . 57
38.2 三路对照 . . . 57
38.3 结果 . . . 57
38.4 发现的第一个问题 . . . 57

39 关键工具二：时间重标检验 **59**
39.1 原理 . . . 59
39.2 什么叫“像 Exp(1)” . . . 59
39.3 引入一个真正的竞争模型 . . . 60
39.4 结果 . . . 60
39.4.1 模型比较（45 名学生） . . . 60
39.4.2 时间重标检验 . . . 61
39.5 修正后的结论 . . . 61

40 两次改进尝试（都失败） **62**
40.1 尝试一：加一个时间尺度 . . . 62
40.1.1 动机 . . . 62
40.1.2 第一次尝试失败的原因 . . . 62
40.1.3 修法 . . . 62
40.1.4 合成数据验证（先证明优化器能用） . . . 63
40.1.5 EdNet 上的结果 . . . 63
40.2 尝试二：加昼夜周期 . . . 63
40.2.1 先验证昼夜结构是否存在 . . . 63
40.2.2 昼夜调制 Hawkes . . . 64
40.2.3 结果 . . . 64

41 方法论总结 **65**
41.1 四次尝试的完整对照 . . . 65
41.2 这一期用到的两个检验工具 . . . 65
41.3 对平台场景的落地建议 . . . 65

42 错误一：AIC 漏计参数（推翻上一版结论） **66**
42.1 上一期说了什么 . . . 66
42.2 错在哪里 . . . 66
42.3 修正后结论完全反转 . . . 66
42.4 换上参数化模型后的正确答案 . . . 67

43 错误二：一个不可识别的自由度（振幅） 68
43.1 症状 . . . 68
43.2 原因：正弦积分为零 . . . 68
43.3 修法：对数线性形式 . . . 68
43.4 修正的副作用（必须诚实报告） . . . 69

44 功效分析：事前的防错工具 70
44.1 什么是功效 . . . 70
44.2 样本量 vs 可检测效应 . . . 70
44.3 反过来：想检测某个效应，需要多少人 . . . 70
44.4 用 19 人做实验，功效是多少 . . . 70
44.5 模拟验证：19 人的精度有多差 . . . 71

45 用公开数据标定“真实效应有多大” 72
45.1 为什么不自己估，而是找数据 . . . 72
45.2 做法 . . . 72
45.3 结果：真实效应非常小 . . . 72
45.4 翻译成“要多少样本” . . . 73
45.5 一个反直觉的推论 . . . 73

46 预注册：把规则写在看到数据之前 75
46.1 为什么需要预注册 . . . 75
46.2 预注册锁死了什么 . . . 75
46.3 为什么主假设只有一个 . . . 75
46.4 为什么“未检出”必须配上功效 . . . 76
46.5 分析脚本的自检（含一次真实的翻车） . . . 76

47 方法论主线：从做、验、防到接 77
47.1 每期在解决什么问题 . . . 77
47.2 三期里“翻车”的完整清单 . . . 77
47.3 第三期的三条方法论 . . . 77

48 验证层的翻车与边界 79
48.1 四次翻车 . . . 79
48.2 必须写清的边界 . . . 79
48.3 这一期最值得记住的三句话 . . . 79

第六部分　元认知、教学干预与教师观察者 80

49 元认知：把“知道自己会不会”变成可测的指标 80
49.1 什么是元认知，和“元元”什么关系 . . . 80
49.2 核心文献：元认知必须拆成两个独立的量 . . . 80
49.3 项目里已经有元认知数据 . . . 81
49.4 指标定义（逐符号） . . . 81
49.4.1 元认知敏感性 AUC . . . 81
49.4.2 元认知偏差 . . . 82
49.5 与 L2 元元层的连接 . . . 83
49.5.1 第 14 课的测谎模块做的是同一件事 . . . 83
49.5.2 折减公式 . . . 83
49.6 公开数据集实验：在 1,936 名学生上验证 . . . 83
49.6.1 先踩了一个陷阱：求助行为不是元认知 . . . 83
49.6.2 可用的信号：响应时间 . . . 84
49.6.3 结果 . . . 84
49.6.4 最重要的发现：与学业表现强相关 . . . 84
49.7 三个实验的执行结果（2026-10-07 更新） . . . 85
49.7.1 实验 A：JOL——学生能预测自己考多少吗？ . . . 85
49.7.2 实验 B：根号——教师的重点判断准不准？学生自己知道吗？ . . . 87
49.7.3 实验 C：难度基线 v2——先修掉两个错误 . . . 89
49.7.4 三个实验怎么接回 Tender 和 DaoQL . . . 90
49.8 一个意外发现：单词测试零区分度 . . . 90
49.9 边界与不做的事 . . . 91

50 元元检测：给结论本身打可信度分 92
50.1 什么是“元元” . . . 92
50.2 L2 的元元公式（原文，逐符号解释） . . . 92
50.2.1 综合可信度 . . . 92
50.2.2 四个检测器与黄金比阈值谱系 . . . 93
50.2.3 弱测量算符 . . . 93
50.3 观测者效应：它本身就是元元问题 . . . 94
50.4 把元元用到研究结论上 . . . 95
50.4.1 公式 . . . 95
50.4.2 与 L2 公式是同一个式子 . . . 95
50.5 护栏：为什么加权平均会失效 . . . 96
50.5.1 修正：一票否决 . . . 96
50.6 六个场景的实测对比 . . . 97
50.7 边界：可信度不等于效应量 . . . 97
50.8 小结：这一节连接了两件事 . . . 98
50.9 DAOQL 客观事件与生命树主观体验 . . . 98

51 犹豫：元认知的行为证据 100
51.1 犹豫本身不是元认知 . . . 100
51.2 形式定义：犹豫的元认知敏感性 . . . 100
51.3 真实数据：ASSISTments 的响应时间 . . . 100
51.4 怎么引导应用：犹豫 × 对错四象限 . . . 101
51.5 四种干预的详细脚本 . . . 101
51.5.1 高犹豫 + 答错：知识缺口 . . . 101
51.5.2 高犹豫 + 答对：知识脆弱 . . . 101
51.5.3 低犹豫 + 答错：错误流畅 . . . 102
51.5.4 低犹豫 + 答对：流畅掌握 . . . 102
51.6 电子化采集要记什么 . . . 102

52 外部脚手架：元认知能不能“植入”? 103
52.1 先分清三件事 . . . 103
52.2 形式定义：报告信号与内部信号 . . . 103
52.3 三臂实验：无提示 vs JOL vs JOL + 反馈 . . . 103
52.4 伦理边界 . . . 104
52.5 功效提醒 . . . 104

53 教师观察者与 metameta 105
53.1 元认知的三层结构 . . . 105
53.2 教师观察的形式定义 . . . 105
53.3 实验 B 的真实先验 . . . 105
53.4 E1：教师–学生–观察者三方对照 . . . 106
53.4.1 设计 . . . 106
53.4.2 指标 . . . 106
53.4.3 合成功效（19 名学生 × 5 次测试） . . . 106
53.5 E5：多教师 metameta . . . 107
53.5.1 一次真实的翻车 . . . 107
53.5.2 修正后的功效 . . . 107
53.6 怎么用教师 metameta . . . 107

第七部分 群体、平台与供应链 108

54 实验一：平台逆向实验 108
54.1 要解决什么问题 . . . 108
54.2 内容方案：把一条视频变成一组数字 . . . 108
54.3 排序评分公式 . . . 108
54.4 群体状态 . . . 109
54.5 操作过程：从 PDF 到内容库 . . . 109

54.6 双口径对比：两套权重谁对 110
54.7 招生漏斗 111

55 用量化交易的眼光看平台算法 112
55.1 一个自然的类比 112
55.2 但有五个致命差异 112
55.3 民间算法 = 市场传言 112

56 群体拓扑：拆闭环、留桥接 114
56.1 把班级看成一张图 114
56.2 E4 真实结果：小圈子 vs 桥接 114
56.2.1 帖子触达（mean reads）模型 115
56.2.2 帖子点赞（mean up）模型 115
56.3 边界 115
56.4 课堂 ABAB 设计 115
56.5 “分而治之”的教育翻译 116

57 E1–E6 实验总表与运行方法 117
57.1 总表 117
57.2 运行方法 117
57.3 每个实验最少需要什么数据 118

第八部分 Agent 交互层与 GitHub 教育 Agent 集成 119

58 为什么需要 Agent 层 119
58.1 三层的数据契约 119
58.1.1 DAOQL 事件 119
58.1.2 Tender 状态 120
58.1.3 Agent 消息 120

59 Agent 角色清单 120

60 GitHub 教育 Agent 与平台选型 121
60.1 教育专用层 121
60.2 Agent/RAG 编排层 122

61 集成架构 122
61.1 三层部署图 122
61.2 推荐技术栈 123

62 五条核心工作流 **123**
62.1 学生辅导工作流 . . . 123
62.2 教师副驾驶工作流 . . . 124
62.3 群体促进工作流 . . . 124
62.4 家长沟通工作流 . . . 124
62.5 销售/运营工作流 . . . 124

63 安全、隐私与治理 **125**
63.1 十条硬红线 . . . 125
63.2 Human-in-the-loop . . . 125

64 产品完成路线图 **125**
64.1 MVP：8 周 . . . 125
64.2 Phase 2：3 个月 . . . 126
64.3 Phase 3：6 个月 . . . 126

65 Agent 交互层的完整工程实现 **126**
65.1 DAOQL 因果层 . . . 126
65.2 Tender 心智层 . . . 127
65.3 Agent 运行时 . . . 127
65.4 已接入的真实数据 . . . 127
65.5 API 端点 . . . 127
65.6 部署与验证 . . . 128
65.7 还差什么 . . . 128

66 产品验收清单 **129**

67 一句话总结 **129**

第九部分　实验复现与课堂操作 **129**

68 实验二：知识追踪基准实验（重点） **129**
68.1 什么是知识追踪 . . . 129
68.2 实验用的数据 . . . 130
68.2.1 数据清洗规则 . . . 130
68.2.2 为什么要“按学生”划分训练集和测试集 . . . 130
68.3 模型一：BKT（标准基线） . . . 131
68.3.1 核心思想 . . . 131
68.3.2 四个参数 . . . 131
68.3.3 预测公式 . . . 131
68.3.4 状态更新（看到答案之后） . . . 132

68.3.5 怎么求出这四个参数：EM 算法 . . . 132
68.4 模型二：Tender θ_seq . . . 133
68.4.1 用到的公式 . . . 133
68.4.2 本实验实现的三个变体 . . . 133
68.5 评测指标 . . . 134
68.5.1 指标一：AUC（看排序能力） . . . 134
68.5.2 指标二：RMSE（看数值准不准） . . . 134
68.5.3 指标三：LogLoss（看自信程度是否合理） . . . 135
68.6 实验流程 . . . 135
68.7 实验结果 . . . 136
68.7.1 怎么读这张表 . . . 136
68.8 关键发现一：默认参数 η 太大了 . . . 136
68.8.1 敏感性扫描结果 . . . 136
68.8.2 为什么会这样 . . . 137
68.8.3 这意味着什么 . . . 137
68.9 关键发现二：场景切换惩罚没有用 . . . 138
68.10 关键发现三：按知识点分状态是必要的 . . . 138
68.11 分知识点表现与校准曲线 . . . 138
68.11.1 分知识点对比 . . . 138
68.11.2 校准曲线 . . . 138
68.12 本实验的局限（必须说明） . . . 139
68.13 实验得出的四条修正 . . . 139

69 附录：第一期复现指南 140
69.1 平台逆向实验 . . . 140
69.2 知识追踪基准实验 . . . 140
69.3 产物位置 . . . 140

70 附录：第一期实验总结 141
70.1 最重要的三个数字 . . . 141
70.2 最重要的一句话 . . . 141

71 附录：第二期实验复现 141
71.1 最重要的四个数字 . . . 142
71.2 最重要的一句话 . . . 142
71.3 两期手册的关系 . . . 142

72 附录：第三期实验与数据 143
72.1 主要数据实验 . . . 143
72.2 相关实验（E1–E6，2026-10-09） . . . 144
72.3 产物位置 . . . 144

72.4 最重要的十二个数字 . . . 145
72.5 最重要的一句话 . . . 145

73 采集工具与课堂操作手册 146
73.1 四个采集工具 . . . 146
73.2 六周课堂流程 . . . 146
73.3 数据录入的三条硬规则 . . . 147
73.4 跑分析之前先看功效 . . . 147

74 附录：第四期实验与复现 148
74.1 主要脚本 . . . 148
74.2 主要产物目录 . . . 148
74.3 最重要的数字 . . . 148
74.4 一句话总结 . . . 149

75 课堂六周操作清单 149
75.1 三条硬规则 . . . 150

第十部分　治理与合规 150

76 合规红线 150
76.1 十条红线 . . . 150
76.2 三条最容易被忽略的红线 . . . 150
76.2.1 R3：为什么教师看不到学生的情绪标签 . . . 150
76.2.2 R7 与“离校凭证”的例外 . . . 151
76.2.3 加盐承诺：为什么必须加随机数 . . . 151
76.3 必须排除的具体操作 . . . 152

77 全部翻车清单 153

第十一部分　总览、文件索引与总结 153

78 四期总览 153

79 全部文件与数据索引 153
79.1 四期手册 . . . 153
79.2 主要脚本 . . . 154
79.3 主要产物 . . . 154

80 最重要的 20 个数字 154

81 一句话总结 155

第十二部分　增补：开花、结果、森林与认知构念实验 **155**

82 为什么需要这一部分 **155**

83 三个构念的正式定义 **156**
83.1 开花：从工作记忆表征到稳定认知结构 156
83.2 结果：不同认知结构产生新组合 156
83.3 森林：可持续的认知重组环境 157

84 本项目初步实验 **157**
84.1 EdNet 真实时间间隔 157
84.2 ASSISTments 事件间隔代理 157
84.3 群体构念评分模拟 158

85 项目实现与数据字段 **158**

86 证据边界与后续实验 **159**

第十三部分　增补二：环境型多 Agent 与真桌面弹幕 **159**

87 为什么不再需要一个日常操作页面 **159**

88 日常产品面：桌面圆桌而不是操作页 **159**

89 什么时候才允许出现 **160**

90 打扰预算 **160**

91 提示层级 **160**

92 默认监测边界与本地归一化 **161**

93 功能型多 Agent 圆桌 **161**
93.1 Triage Agent：先分诊，再调用专家 162

94 工程接口 **162**

95 两个首批场景 **163**
95.1 高考报名 163
95.2 提分 163

96 关键指标 **163**

97 V6.6 当前实现状态与验收 **164**
97.1 快捷键 164
97.2 工程文件 164
97.3 本地监测与隐私 165
97.4 验收结果 165
97.5 边界 165

98 教学网站、白皮书与最新架构 **165**
98.1 配套文档 166
98.2 本地入口 166
98.3 边界 166

99 B 端与 C 端交付模型 **166**
99.1 B 端两种交付方式 167
99.2 C 端自有界面 167
99.3 数据边界 167

第一部分　项目总览与阅读指南

1　中心主旨：让 AI 成为森林的气候，让人成为生命树的作者

生命不是被某个框架评价出来的形状，而是在有限时间里，通过选择、关系、承担和创造长出来的年轮。

现有培养体系过于庞大，并且伴随人的一生。它提供秩序，也带来持续的压力和对未知的恐惧。外部标准一旦变成人的内在边界，一个人可能很会解决问题，却逐渐失去对自己生命的解释权。

Tender 要做的，是一层贯穿终身的心智生长环境：

- 在压力出现时，帮助人命名压力；
- 在未知面前，帮助人把恐惧拆成可以理解和行动的风险；
- 在选择面前，帮助人看见自己真正重视什么、愿意承担什么；
- 在行动之后，帮助人保存结果、复盘和形成自己的价值证据；
- 在自主能力增强之后，逐步退到背景，把解释权和决定权归还给人。

生命树	人的成长	Tender 如何承接
种子	尚未展开的可能性	不用一次测评定义一个人
根系	安全、关系、身体状态与真实反馈	先理解支持条件，再讨论表现
树干	长期选择与承担形成的连续性	记录跨时间的承诺、行动和结果
枝叶	探索、试错、跨域连接与角色经验	提供多 Agent 视角，不替人规定方向
开花	第一次有足够证据看见自己的整体成长	用长期证据形成可更正的状态假设
结果	独立迁移、创造作品、影响他人并承担后果	关注真实结果和迁移，而非奖励等级
森林	不同生命在同一生态中互相支撑	保持多样性，拒绝把人修剪成同一种形状

一句话记住　AI 可以模拟风雨，却不能替一棵树长出年轮；它可以提供地图，却不能替一个人决定要去哪里。

这里的“成熟”，指一个人能够理解自己的状态，选择值得追求的事情，承担选择后的结果，在需要时调整、求助并重新出发。

Tender 的中心主旨是：

让 AI 成为森林的气候，让人成为生命树的作者。一个人不必成为最聪明的那个，也不必成为最有用的那个，他仍然可以通过自己的选择、关系、创造和承担，长成独一无二的生命形态。

生命树是叙事与建模语法。具体科学主张仍需通过真实数据、预注册实验和独立复核验证；Tender 把模型输出当作可更正的状态假设，不把它当作诊断，也不承诺替代考试或保证结果。

这一部分先回答三个问题：

1. 这个项目到底在做什么？
2. 整本书按什么架构组织？
3. 不同角色应该怎么读？

2 这份手册怎么用

2.1 一句话架构

Tender 是一个“采集行为 → 建模认知 → 验证结论 → 干预教学 → 连接群体与平台”的心智化教育系统。

2.2 三层技术栈

层	角色	回答什么
DAOQL 层（底层）	事实与因果	发生了什么？因为什么？证据是什么？
Tender 层（中层）	心智化建模	学生现在是什么状态？不确定性多大？
Agent 层（上层）	交互与执行	现在该对谁说什么、做什么、怎么跟进？

2.3 六层产品架构

层	做什么	核心问题	对应章节
数据层	采集会话、事件、JOL、根号、犹豫、教师观察、互动，写入 DAOQL	我们到底有什么数据？	第 3 部分

建模层	用 θ、节律、会话、知识追踪刻画学生，形成 Tender 状态	怎么把数据变成状态？	第 4 部分
验证层	安慰剂、时间重标、换单位、AIC、功效、预注册	怎么防止自己骗自己？	第 5 部分
应用层	元认知、犹豫、外部脚手架、教师 metameta，由 Agent 执行	怎么把状态变成教学干预？	第 6 部分
群体/平台层	群体拓扑、平台逆向、推荐算法、供应链	怎么从个人扩展到群体和平台？	第 7 部分
Agent 交互层	学生辅导、教师副驾驶、家长沟通、分组、运营	谁来执行、谁来跟进？	第 8 部分
治理层	合规、隐私、伦理、翻车清单	哪些事不能做？	第 10 部分

2.4 架构图（从上到下读）

项目架构
Agent 交互层：Student Tutor、Metacognition Coach、Teacher Copilot、Parent、Group Facilitator、Sales
↓
Tender 心智层：θ、Bloch 球、情绪、元认知、知识追踪、节律、基线、群体拓扑
↓
DAOQL 因果层：事件图、因果关系、证据、血缘、时间线、版本
↑
数据来源：课堂、LMS、浏览器插件、教师卡、家长端、平台互动
↓
治理层：合规、隐私、伦理、翻车清单

2.5 按角色的阅读路径

角色	先读什么	再读什么

老师	第 1 部分:零基础入门;第 5 部分：元认知与教学干预；第 7 部分：课堂操作手册	第 2 部分：数据怎么采；第 6 部分：群体与平台
产品经理	第 0 部分：项目总览；第 5 部分：应用层；第 6 部分：群体/平台层	第 2、3 部分：数据与建模
工程师	第 2 部分：数据层；第 3 部分：建模层；第 7 部分：实验复现	第 4 部分：验证层；第 8 部分：治理
研究者	第 3 部分：建模层；第 4 部分：验证层；第 7 部分：实验复现	第 5 部分：元认知实验结果；第 6 部分：群体实验

3 项目愿景与四个关键词

3.1 四个关键词

关键词	白话	在本书哪里
做	先建一个能算的模型	第 2、3 部分：数据层与建模层
验	再检查这个模型是不是骗自己	第 4 部分：验证层
防	事先写死规则，防止事后找理由	第 4 部分：功效与预注册
接	把信号接回学生、教师、群体、环境	第 5、6 部分：应用层与群体/平台层

3.2 项目的一句话

一句话不是给学生贴标签，而是找到最省力的那一个杠杆。

学生、教师、同伴、排课、任务，互相影响；Tender 要做的，是把这个耦合系统里可测量、可干预的部分找出来。

4 术语统一说明

原来的四本分册是按时间写的，所以会出现“第一期/第二期”“这一期/上一期”。本完整版按项目架构重排后，请按下面的对应关系理解：

旧写法	新位置	怎么理解
第一期	第 2–3 部分：数据层与建模层	最初的数据采集和核心公式
第二期	第 4 部分：验证层	安慰剂、时间重标、换单位
第三期	第 4–5 部分：验证层与应用层	功效、预注册、元认知、metameta
第四期	第 5–6 部分：应用层与群体/平台层	犹豫、外部脚手架、耦合基线、群体拓扑
“这一期”	“本章”	按当前章节上下文理解
“上一期”	“前面章节”	按架构顺序回看

5 全书地图

部分	名称	回答什么	关键产出
第 1 部分	数学、符号与零基础入门	我不懂数学，怎么读？	生活类比、符号词典、小明例子
第 2 部分	数据与基础设施层	我们有什么数据？怎么存？	会话、事件、数据表、采集工具
第 3 部分	Tender 建模核心	怎么把数据变成状态？	θ、Bloch 球、节律、知识追踪
第 4 部分	验证、防错与预注册	怎么防止自己骗自己？	安慰剂、时间重标、AIC、功效、预注册
第 5 部分	元认知、教学干预与教师观察者	怎么把状态变成干预？	JOL、根号、犹豫四象限、外部脚手架、metameta
第 6 部分	群体、平台与供应链	怎么从个人扩展到群体和平台？	群体拓扑、平台逆向、推荐算法、供应链
第 7 部分	实验复现与附录	怎么跑、怎么复现？	E1–E6、脚本、结果、文件索引
第 8 部分	治理与合规	哪些事不能做？	十条红线、隐私、伦理、翻车清单

第 9 部分	统一符号与总结	所有符号和一句话	符号词典、最重要的 20 个数字

6 四期地图：做、验、防、接

期	动词	解决什么	核心工具
第一期	做	怎么建模、怎么算指标	会话、节律、知识追踪、θ
第二期	验	怎么检查模型是不是骗自己	安慰剂、时间重标、换单位
第三期	防	怎么防止事后找理由	功效、预注册、元认知、metameta
第四期	接	怎么把信号接回系统	犹豫、外部脚手架、耦合基线、群体拓扑

7 本书的三种证据

证据	例子	能说什么
真实公开数据	EdNet、OULAD、Stanford MOOCPosts	能说“在这个公开数据上，效应方向和大小是什么”
真实课堂数据	9 篇 56–65 题、实验 B	能说“在这 6–19 人的班级里，初步信号是什么”
合成自检	E1/E5/E6 模拟	只能验证“估计器能不能恢复真值”，不能说学生真实结论

读本书的硬规则 看到任何一个数字，先问：

这是真实数据，还是模拟？是相关，还是因果？

8 五个最容易犯的错

1. **把相关当因果**：两件事一起变，不代表一个导致另一个。
2. **把不显著当没有效应**：可能只是样本太小、功效不够。

3. **把基线当性格**：基线是耦合稳定点，环境变了它也会变。

4. **把犹豫当不会**：犹豫只是信号，必须先验证 AUC。

5. **把黄金比当结论**：目前没有证据，只能当隐喻。

第二部分　数学、符号与零基础入门

9　这本书怎么读

9.1　三遍法

1. **第一遍：只读白话。**跳过所有公式和表格，先知道每一章在讲什么故事。

2. **第二遍：看公式和符号。**每个公式下面都有逐符号解释，配一个具体数字例子。

3. **第三遍：跑脚本、看数据。**照着附录里的命令跑一遍，看到真实的图和数字。

一句话 **先懂意思，再看符号，最后动手。**不要一上来就背公式。

9.2　这本书的四个关键词

关键词	白话	在本书哪里
做	先建一个能算的模型	第一期：会话、节律、知识追踪
验	再检查这个模型是不是骗自己	第二期：安慰剂、时间重标、换单位
防	事先写死规则，防止事后找理由	第三期：功效、预注册、元认知
接	把信号接回学生、教师、群体、环境	第四期：犹豫、基线、群体拓扑

10　什么是模型：地图不是地形

10.1　生活类比

你手里有一张北京地铁图。地铁图不是北京，它把真实的城市简化成一堆线和点。但有了它，你就能规划路线。

模型就是地铁图。它不是现实本身，它是现实的简化版。好的模型不是“最像现实”，而是“在你关心的问题上够用”。

10.2 形式定义

模型是一个映射：

$$\text{输入} \ \rightarrow \ \text{模型} \ \rightarrow \ \text{输出}. \tag{1}$$

符号说明：

- 输入：你观察到的数据，例如学生做对了哪几题；
- 模型：你写的规则，例如“做对越多，能力越高”；
- 输出：模型给出的判断，例如“这个学生掌握度 0.7”。

10.3 在本书哪里用到

第一期的 Tender θ、知识追踪 BKT、会话模型，都是模型。模型不是真理，只是暂时可用的地图。

11 什么是指标：体温计和体重秤

11.1 生活类比

体温计把“发烧”变成一个数字：38.5℃。体重秤把“胖瘦”变成一个数字：60 kg。数字不完美，但比“我感觉有点热”更有用。

指标就是把模糊的感觉变成可比较的数字。

11.2 形式定义

指标是一个函数：

$$\text{指标} = \text{函数}(\text{原始数据}). \tag{2}$$

例如：

$$\text{正确率} = \frac{\text{答对题数}}{\text{总题数}}. \tag{3}$$

11.3 好指标的三条标准

1. **可重复**：同样的数据，今天算和明天算结果一样；
2. **可比较**：不同学生、不同时间能放在一起比；
3. **不容易骗**：不能只看一个数就下结论。

11.4 在本书哪里用到

AUC、偏差、Brier、效应量、功效，都是指标。指标不是结论，指标是证据的一部分。

12 什么是概率：下雨概率 30%

12.1 生活类比

天气预报说“明天降雨概率 30%”。这不是说“明天一定下 30% 的雨”，也不是说“明天一定不下雨”。它说的是：在类似情况下，100 次里有 30 次会下雨。

12.2 形式定义

概率 $P(A)$ 是事件 A 发生的可能性，范围是：

$$0 \le P(A) \le 1. \tag{4}$$

- $P(A) = 0$：不可能；
- $P(A) = 1$：一定；
- $P(A) = 0.3$：100 次里大约 30 次。

12.3 最容易误解的地方

概率不是命运。一个学生“掌握度 0.7”，不是说这次一定对 7 题，而是说他这类题的长期正确率大约 70%。

13 什么是基线：体温 36.5℃

13.1 生活类比

医生不会只问“你体温多少”，还会问“你平时体温多少”。36.5℃ 是正常基线，38.5℃ 才是异常。

没有基线，就没有异常。

13.2 形式定义

基线是“在正常情况下，这个指标通常是多少”。

$$\text{偏离} = \text{当前值} - \text{基线}. \tag{5}$$

13.3 本书的最重要升级

第三期之前，基线常被当成“这个人固定的一个数”。第四期把它升级为：

$$x^* = f(x^*, u^*, e^*; \theta). \tag{6}$$

翻译成白话：

基线 = 学生 × 环境的耦合稳定点。

环境变了，基线也会移动。所以“改安排”往往比“强制改习惯”更有效。

14 什么是 AUC：医生诊断的区分能力

14.1 生活类比

医生用一项检查区分“有病”和“没病”。如果这项检查完全瞎猜，AUC = 0.5；如果它完美区分，AUC = 1.0。

14.2 形式定义

$$\mathrm{AUC} = \Pr(\text{正例得分} > \text{负例得分}) + \frac{1}{2}\Pr(\text{相等}). \tag{7}$$

- 正例：你想找出来的东西，例如“错题”“有病”“不会”；
- 负例：其余情况，例如“对题”“没病”“会”；
- AUC = 0.5：没有区分能力；
- AUC = 1.0：完美区分。

14.3 在本书哪里用到

元认知敏感性、犹豫、教师观察，都用 AUC。但 AUC 不是准确率，它只看“能不能把两类分开”。

15 什么是效应量和功效：放大镜够不够大

15.1 生活类比

你想看一只蚂蚁。用肉眼看，看不清；用 10 倍放大镜，勉强；用 100 倍放大镜，很清楚。**效应量就是蚂蚁有多大；功效就是你的放大镜够不够。**样本量就是放大镜的倍数。

15.2 形式定义

效应量：真实差别有多大，例如 $d = 0.2$ 是小效应，$d = 0.8$ 是大效应。
功效：如果真实差别存在，你的实验能把它检测出来的概率。

$$\text{功效} = P(\text{检测到效应} \mid \text{效应真的存在}). \tag{8}$$

15.3 本书最重要的功效数字

场景	样本	能测出多大
相关分析	19 人	$\lvert r\rvert \geq 0.605$
OULAD 最大效应	26,074 人	中位 0.053、最大 0.289
OULAD 最大效应所需样本	约 92 人	检测 0.289

一句话 **不显著，不等于没有效应；可能只是你的放大镜不够。**

16 什么是预注册：先写规则，再看数据

16.1 生活类比

考试前先把答案写下来，考完后不能改。如果你考完再写“我早就知道是这个答案”，那不算数。

预注册就是在看数据之前，先把分析规则写死。

16.2 为什么要预注册

因为人很会事后找理由：

- 本来想测 A，结果 A 不显著，就改测 B；
- 本来想看整体，结果整体不显著，就挑一个子群体；
- 本来想用 0.05 标准，结果刚好 0.06，就说“接近显著”。

预注册就是防止这些“事后找理由”。

16.3 预注册锁死什么

1. 主假设只有一个；
2. 样本量先算好；
3. 主要指标先写死；

4. 排除标准先写死；

5. 如果没显著，也要报告功效。

17 什么是元认知：知不知道自己会不会

17.1 生活类比

考试时，有些学生知道“我这题不会”，有些学生“以为自己会，结果错了”。后者不是知识问题，是**元认知问题**。

元认知 = 对自己认知过程的监控和判断。

17.2 三个一阶指标

1. **JOL**（学习判断）：测试前估计自己能对几题；

2. **根号自标**：学生自己标“哪里不会/是重点”；

3. **犹豫**：响应时间、修改次数、停顿。

17.3 两个关键量

- **校准偏差** $b = \hat{p} - p$：预测正确率减实际正确率；> 0 过度自信；

- **敏感性 AUC**：能不能把“会”和“不会”分开。

最重要的一句话 **相关不等于校准。**

一个学生能预测自己考得好不好（相关高），

不代表他预测的分数一定准（校准好）。

18 什么是 trait、state 和基线

18.1 三个词的白话解释

词	白话	例子
trait	比较稳定的倾向	MBTI 连续分数、节律峰型
state	当前的状态	今天注意力差、刚考完试很累
baseline	当前耦合出来的稳定点	平时晚上 20:00 学习效率最高

18.2 为什么不能把基线当 trait

因为基线会随环境移动：

- 学校把晚自习从 20:00 调到 19:00；
- 基线可能跟着移动；
- 如果你把基线当固定性格，就会误判学生“变差了”。

18.3 扰动实验

想判断一个量是 trait 还是 baseline：

1. 改变环境；
2. 看它动不动；
3. 动得多，是 baseline/state；
4. 几乎不动，才更像 trait。

19 一个贯穿全书的例子：小明学语法填空

我们用一个学生“小明”把四期串起来。

19.1 第一期：做

小明每次做语法填空，我们记录：

- 做了几题、对了几题；
- 什么时候做（节律）；
- 一次学习会话有多长；
- 他的 θ、掌握度。

19.2 第二期：验

我们发现小明的学习有“自激”现象：做得越多，接下来做得越快。但要先做安慰剂检验和时间重标检验，确认这不是假象。最后发现，真正的基本单位是**一次会话**。

19.3 第三期：防

我们事先算好：19 个学生只能测出中等以上效应。然后让小明每次测试前写“估计能对几题”（JOL），再让他自己标“哪里不会”（根号自标）。我们发现：他可能预测得挺准，但不一定校准得好。

19.4 第四期：接

我们继续记录：

- 他做题时犹不犹豫（响应时间、修改次数）；
- 教师对他的预测和信心（metameta）；
- 他和谁讨论（群体拓扑）；
- 他的节律和排课匹不匹配（耦合基线）。

最后我们发现：

- 顺应他的节律排课，比强制他改作息更有效；
- 小圈子和桥接各有优势，取决于要触达还是要认可；
- 教师观察需要折扣，不能当 ground truth；
- 黄金比目前只是隐喻，真正可检验的是闭环和尺度不变。

19.5 小明的故事告诉我们

教育不是一个数字，而是一个耦合系统。
学生、教师、同伴、排课、任务，互相影响。
我们要做的不是给学生贴标签，而是找到最省力的那一个杠杆。

20 数学基础（零基础版）

这一章只讲后面会用到的数学。每个概念都用“生活例子”解释。

20.1 角度与弧度

20.1.1 角度

圆的一圈是 360°。转半圈是 180°，转四分之一圈是 90°。这个大家都熟。

20.1.2 弧度

数学里更常用的是**弧度**。定义很简单：

$$1 \text{ 圈} = 360^\circ = 2\pi \text{ 弧度} \tag{9}$$

符号说明

- π（读作“派”）：圆周率，约等于 3.14159。
- $2\pi \approx 6.283$：一整圈的弧度数。
- 换算方法：$180^\circ = \pi$ 弧度，所以 $90^\circ = \pi/2 \approx 1.571$，$60^\circ = \pi/3 \approx 1.047$。

为什么用弧度：因为弧度直接对应圆上的“弧长”。半径为 1 的圆上，转过 1 弧度，弧长就是 1。这让后面的公式更简洁。

20.1.3 三角函数：cos 和 sin

在一个直角三角形里，取一个锐角 θ（读作“西塔”），那么：

$$\cos\theta = \frac{\text{邻边}}{\text{斜边}}, \qquad \sin\theta = \frac{\text{对边}}{\text{斜边}} \tag{10}$$

符号说明

- θ：希腊字母 theta，读音“西塔”。本文中它表示融合角，取值范围 $[0, \pi]$。
- $\cos\theta$：余弦，输出范围 $[-1, 1]$。
- $\sin\theta$：正弦，输出范围 $[-1, 1]$。
- $\cos^2\theta$ 是 $(\cos\theta)^2$ 的简写，即余弦值的平方。

一个必须记住的等式（后面会反复用到）：

$$\cos^2\left(\frac{\theta}{2}\right) + \sin^2\left(\frac{\theta}{2}\right) = 1 \tag{11}$$

通俗理解：$\cos^2(\theta/2)$ 是一个“占比”，它和 $\sin^2(\theta/2)$ 加起来永远是 100%。后面的“概率”就是从这个占比来的。

20.2 概率

概率就是“可能性”，取值在 0 到 1 之间。0 表示绝不可能，1 表示必然发生。也可以写成百分比：$0.7 = 70\%$。

本文中概率的两个角色：

1. **预测概率：**模型说“这个学生有 0.7 的概率答对”。
2. **实际频率：**在一批题目里，实际做对了 70%。

好的模型应该让这两个数接近。**如果模型说 0.9，实际只有 0.6，这叫“校准不好”。**这是第 5 章的一个核心发现。

20.3 指数与对数

20.3.1 指数

e^x 表示 e 的 x 次方，其中 $e \approx 2.71828$，是一个特殊的常数。

20.3.2 sigmoid 函数

$$\sigma(x) = \frac{1}{1 + e^{-x}} \tag{12}$$

符号说明

- x：任意实数（可正可负）。
- $\sigma(x)$：输出范围是 $(0, 1)$，正好可以当概率用。
- 特性：x 很大时输出接近 1；x 很小时输出接近 0；$x = 0$ 时输出 0.5。

通俗理解：sigmoid 是一个“压缩器”。不管输入多大或多小，它都会把结果压到 0 到 1 之间。所以它常被用来把“分数”变成“概率”。

第 4 章的平台评分公式最后一步就用了它。

20.3.3 对数

$\log(x)$ 表示“e 的多少次方等于 x”。

例：$\log(1) = 0$，$\log(2.718) \approx 1$，$\log(7.389) \approx 2$。

为什么要用对数 对数的作用是压制大数值。比如：

- 一个人参与 10 次，$\log(1 + 10) = 2.40$
- 一个人参与 1000 次，$\log(1 + 1000) = 6.91$

参与次数差了 100 倍，但取对数后只差了 2.9 倍。这样可以防止“刷次数的人”获得过大的权重。第 6 章的共识权重就用了这个技巧。

20.4 黄金比

$$\varphi = \frac{1 + \sqrt{5}}{2} \approx 1.618 \tag{13}$$

符号说明

- φ：希腊字母 phi，读音“斐”。本文中表示黄金比。
- $\sqrt{5}$：5 的平方根，约 2.236。
- 它有个特殊的性质：$\varphi^2 = \varphi + 1$，而且 $1/\varphi = \varphi - 1 \approx 0.618$。

在本文中的用途：φ 是系统里“所有阈值和衰减率”的来源。具体用法见第 3 章。

20.5 哈希

哈希是一种“指纹”算法。你把任意长度的内容丢进去，它输出一串固定长度的乱码。

$$H(\text{内容}) = \text{一串固定长度的十六进制数} \tag{14}$$

符号说明

- H：哈希函数（Hash function）。
- 输入：任意内容（一段文字、一个数字、一个文件）。
- 输出：例如 `a3f5c9...`（通常 64 个十六进制字符）。
- 三个关键性质：**(1) 同样的输入永远得到同样的输出；(2) 输入变一点点，输出完全变样；(3) 无法从输出反推出输入**。

通俗理解：像人的指纹——能证明“是你”，但指纹本身不能还原出你这个人。

20.5.1 一个真实存在的陷阱：低熵值哈希可以被暴力破解

这一点非常重要，第 7 章会详细讲。简单说：

“正确率 62%”这个值的可能性只有 101 种（0% 到 100%）。
所以就算你把它哈希了，别人只要枚举 101 次就能反推出原值。

解决办法是加盐：把数值和一个随机数拼在一起再哈希。

$$C = H(\text{数值} \parallel \text{随机数}) \tag{15}$$

符号说明

- C：承诺值（Commitment）。上链的就是它。
- $\parallel$：拼接符号，表示把两段内容接在一起。
- **随机数**（nonce）：本地生成的、别人猜不到的随机串，只保存在自己手里。
- 验证时，出示“数值 + 随机数”，对方重算一次哈希，对得上就证明“我没改过数据”。
- 不验证时，别人就算知道 C，也推不出数值——因为随机数有无数种可能。

21 全部符号总索引

符号	读法	含义与取值范围
θ	西塔	融合角。$[0, \pi]$。0 = 完全区分（清醒），π = 完全融合（迷糊）
ϕ	斐	认知相位。$[0, 2\pi]$。标记历史路径，不影响概率大小
γ	伽马	认知惯性。$[0, 1]$。越大越固执
α	阿尔法	(1) 颜色权重；(2) 冲击幅度。看上下文
β	贝塔	文字权重，默认 0.30
δ	德尔塔	生理（HRV）权重，动态
η	伊塔	学习率，每步 θ 的更新幅度。**文档默认 0.3，实验建议 0.02**
ξ	克西	场景切换惩罚。**文档默认 0.15，实验建议 0**
ρ	柔	情绪惯性
φ	斐（大写）	黄金比，≈ 1.618
π	派	圆周率，≈ 3.14159
σ	西格玛	(1) 标准差；(2) sigmoid 函数。看上下文
Δ	德尔塔（大写）	增量 / 变化量。Δt = 时间步长
μ	缪	平均值（本文用横线表示）
$\bar{x}$	x-bar	x 的平均值
$\lvert D\rangle$	D 态	区分态（清晰）
$\lvert F\rangle$	F 态	融合态（模糊）
$\lvert\psi\rangle$	普西	认知状态向量
i	——	虚数单位，$i^2 = -1$。仅作数学记号
$H(\cdot)$	H	哈希函数
$\|$	——	拼接符号
$\sum$	西格玛（求和）	求和
$\prod$	派（连乘）	连乘
$\log$	——	自然对数（以 e 为底）
e	——	自然常数，≈ 2.71828
$\cos, \sin$	——	余弦、正弦
$\arccos$	——	反余弦
$P(\cdot)$	——	概率，取值 $[0, 1]$
$P(L_0)$	——	BKT 的先验掌握概率
$P(T)$	——	BKT 的学习转移概率
$P(G)$	——	BKT 的猜测概率
$P(S)$	——	BKT 的失误概率

符号	读法	含义与取值范围
$\hat{p}$	p-hat	模型预测的概率（帽子表示“估计值”）
y	——	实际结果（答对 1，答错 0）
N	——	样本数量
$B_{i,t}$	——	用户 i 在时刻 t 的 Being 记录
B^{group}	——	群体聚合记录
c	——	情绪色相（颜色）
$e(c)$	——	颜色的五维编码向量
M_i	——	心智化综合得分
W	——	心智化窗口是否打开
θ_{th}	θ-th	临界融合角，≈ 0.9046 弧度 $\approx 51.8°$
$r_1 \dots r_5$	——	漏斗各环节转化率

22 第二期新增的符号索引

符号	读法	含义
$\lambda(t)$	兰姆达	瞬时强度。t 时刻事件发生的急迫程度
μ	缪	基线强度。没有历史事件时的发生率
α	阿尔法	激发增量。每个历史事件抬高多少强度
β	贝塔	衰减速率。激发效应衰减多快
$n = \alpha/\beta$	—	**分支比**。一个事件平均引发多少个后续事件
t_j	—	第 j 个历史事件的时刻
Δt	德尔塔 t	时间间隔
$\Lambda(t)$	大写兰姆达	累计强度（补偿器），$\int_0^t \lambda(s)\,ds$
τ_i	陶	重标间隔，$\Lambda(t_i) - \Lambda(t_{i-1})$
τ_{gap}	陶 gap	会话切分阈值，默认 30 分钟
$m(h)$	—	昼夜调制函数
μ_0	—	昼夜基线的整体水平
$\phi(\Delta t)$	斐	核函数，描述“一个事件对后续影响多大”
χ^2	卡方	衡量实际分布与理论分布差多远
k	—	Weibull 形状参数。$k < 1$ 表示间隔聚簇
AIC	—	模型综合评价，越小越好
KS 统计量	—	累积分布的最大垂直距离，越小越好
p 值	—	显著性。$p > 0.05$ 通常视为通过检验
Exp(1)	—	标准指数分布，平均单位时间 1 次且完全随机

23 第三期新增的符号索引

符号	读法	含义
α（幂律）	阿尔法	幂律指数。$P(k) \propto k^{-\alpha}$
χ^2	卡方	实际分布与理论分布的距离度量
$m(h)$	—	相对活跃度调制函数，平均值归一化为 1
Z	—	归一化常数，$\frac{1}{P}\int_0^P \exp(s)\,dh$
$s(h)$	—	对数线性调制的指数部分（傅里叶级数）
R（会符号）	—	合向量长度，作息集中度，取值 $[0,1]$
R_{24}	—	**日内强度**（Rayleigh）。时间点是否固定，取值 $[0,1]$
R_{168}	—	**周内强度**（Rayleigh）。是否集中在周内特定位置
B（节律平衡）	—	R_{168}/R_{24}。B 小 = 每日型；B 大 = 间歇型
$q_{\text{量}}$	—	量偏离：今日活动量的**拟泊松偏差残差**
$q_{\text{时}}$	—	时偏离：今日时相与个人基线的圆形距离（以 6 小时为标度）
$q_{\text{型}}$	—	型偏离：今日小时轮廓与基线轮廓的**余弦距离**
ϕ（过散布）	斐	拟泊松的过散布因子 = 方差 / 均值，≥ 1
trait	特质	**稳定**的个体属性（性格），应预测节律的**水平**
MetaConfidence	—	**综合可信度**，$= 1 - \sum_k \beta_k \,\text{alert}_k$，越大越可信
β_k	贝塔	第 k 个元元检测器的权重，$\sum_k \beta_k = 1$
alert_k	—	第 k 个检测器是否报警，取 0 或 1
s_k	—	研究评分里第 k 个维度的**得分**，$s_k = 1 - \text{alert}_k$
w_k	—	研究评分里第 k 个维度的权重，$\sum_k w_k = 1$
M_{meta}	—	**弱测量算符**，$= I - \eta(1 - \text{MC})P_{\text{模糊}}$
I	—	单位算符（什么都不做）
η（弱测量）	伊塔	弱测量强度系数，L2 取 0.01
$P_{\text{模糊}}$	—	投影到模糊态的算符
V_{veto}	—	**一票否决**的封顶值
min	—	取较小值，用于**不可补偿**的护栏
AUC_{meta}	—	**元认知敏感性**。标记能否区分错与对，0.5 为无效
$\text{bias}_{\text{meta}}$	—	**元认知偏差** $= \bar{M} - \bar{E}$。> 0 过度谨慎，< 0 过度自信
H, FA	—	命中（标记且错）与虚报（标记但对）的计数
$\bar{M}$, $\bar{E}$	—	标记率与错误率
$d(\text{AUC})$	—	自评可信度**折扣函数**，把 AUC 映射到 $[0.3, 1.0]$
MC_{adj}	—	折减后的 MetaConfidence $= \text{MC}_{\text{meta}} \times d(\text{AUC})$
JOL	—	Judgment of Learning。测试前让学生预测自己会做对多少
state	状态	**临时**的状态，影响节律的**波动**（偏离度）

符号	读法	含义
ρ	柔	Spearman 秩相关系数
d	—	Cohen's d，两组均值的标准化差
N	—	样本量（学生人数）
power	功效	真实效应存在时能检出它的概率
α（显著水平）	阿尔法	假阳性率上限，习惯取 0.05
Bonferroni	—	多重比较校正：α/(检验次数)
AIC	—	$-2\log L + 2k$，越小越好
k（AIC 式）	—	参数个数
H1–H8	—	预注册登记的 8 条假设
T1–T3	—	数据采集的三个精度档位

24 零基础符号与公式词典

24.1 元认知

符号	读法	含义
n	en	测试总题数
y	wai	实际答对题数
$\hat{y}$	y-hat	预测答对题数
$p = y/n$	p	实际正确率
$\hat{p} = \hat{y}/n$	p-hat	预测正确率
$b = \hat{p} - p$	bias	校准偏差；> 0 过度自信，< 0 过度保守
$a = \lvert\hat{p} - p\rvert$	absolute error	校准误差，只看大小
Brier	布里尔分数	概率预测的评分，越小越好
AUC	area under curve	区分能力；0.5 无效，1.0 完美
d'	d prime	信号检测论的区分力
MC	metameta confidence	对判断本身的信心

24.2 犹豫与外部脚手架

符号	读法	含义
h	hesitation	犹豫程度（响应时间、修改次数等）
m_{internal}	m-internal	内部监控信号
m_{report}	m-report	报告出来的信心/JOL
E	external input	外部提示、反馈、暗示
g	映射函数	从内部信号到报告的映射

24.3 耦合基线

符号	读法	含义
x_t	x-t	第 t 期学生状态
u_t	u-t	第 t 期学生行为
e_t	e-t	第 t 期环境
θ	theta	慢参数（trait）
f	耦合函数	状态转移函数
x^*	x-star	基线/稳定点
ε_t	epsilon-t	噪声

24.4 节律与习惯

符号	读法	含义
peak_i	peak	学生 i 的日内节律峰型

h_s	h-s	会话 s 的开始小时
fit_s	fit	安排与节律的匹配度，+1 最匹配
habit_change	habit change	周内节奏改变量，0 稳定，1 全变
R_{24}	R-24	日内节律强度
R_{168}	R-168	周内节律强度
$B = R_{168}/R_{24}$	B	每日型（小）vs 间歇型（大）

24.5 群体拓扑

符号	读法	含义
$G = (V, E)$	graph	班级互动图
C_i	clustering	局部聚类系数，小圈子程度
Q	modularity	模块度，班级分裂程度
B_i	bridge ratio	桥接比例，跨圈连接
D_{div}	diversity	群体多样性

24.6 尺度

符号	读法	含义
T	period	回路周期
λ	lambda	尺度因子
α	alpha	标度指数
φ	phi	黄金比 $(1+\sqrt{5})/2 \approx 1.618$

25 统一符号词典

25.1 基础

符号	读法	含义
n	en	总题数或总样本数
y	wai	实际结果，例如答对题数
p	p	概率或正确率
θ	theta	认知态/能力参数
α	alpha	旋转角、标度指数或显著性水平
ε	epsilon	噪声

25.2 元认知

符号	读法	含义
$\hat{p}$	p-hat	预测正确率
$b = \hat{p} - p$	bias	校准偏差；> 0 过度自信
$a = \lvert\hat{p} - p\rvert$	absolute error	校准误差
AUC	area under curve	区分能力；0.5 无效，1.0 完美
d'	d prime	信号检测论的区分力
Brier	布里尔分数	概率预测评分，越小越好
MC	metameta confidence	对判断本身的信心
h	hesitation	犹豫程度

25.3 耦合基线

符号	读法	含义
x_t	x-t	第 t 期学生状态
u_t	u-t	学生行为
e_t	e-t	环境（任务、教师、同伴、排课）
θ	theta	慢参数（trait）
f	耦合函数	状态转移函数
x^*	x-star	基线/稳定点

25.4 节律、习惯与群体

符号	读法	含义

fit	fit	安排与节律匹配度，+1 最匹配
habit_change	habit change	周内节奏改变量，0 稳定，1 全变
R_{24}	R-24	日内节律强度
R_{168}	R-168	周内节律强度
C_i	clustering	局部聚类系数，小圈子程度
Q	modularity	模块度，班级分裂程度
B_i	bridge ratio	桥接比例，跨圈连接

25.5 尺度

符号	读法	含义
T	period	回路周期
λ	lambda	尺度因子
α	alpha	标度指数
φ	phi	黄金比 $(1+\sqrt{5})/2 \approx 1.618$

第三部分　数据与基础设施层

26　数据怎么存

26.1 一条个人记录长什么样

系统把每一次记录存成一条 **Being 记录**：

$$B_{i,t} = \big\langle \underbrace{\text{id}}_{\text{谁}},\ \underbrace{\text{timestamp}}_{\text{何时}},\ \theta_{i,t},\ \phi_{i,t},\ \gamma_{i,t},\ \underbrace{c_{i,t}}_{\text{颜色}},\ e(c_{i,t}),\ \underbrace{\text{text}_{i,t}}_{\text{文字}},\ \text{scenario}_{i,t} \big\rangle \tag{16}$$

26.1.1 九个字段逐个解释

字段	符号	含义
标识	id	全局唯一的编号，回答“这是谁”
时间戳	timestamp	记录时间，回答“这是什么时候”
融合角	$\theta_{i,t}$	范围 $[0,\pi]$。0 = 完全清醒，π = 完全迷糊
认知相位	$\phi_{i,t}$	范围 $[0,2\pi]$。标记“从哪条路过来”
认知惯性	$\gamma_{i,t}$	范围 $[0,1]$。越大越“固执”，越难被新信息改变
情绪色相	$c_{i,t}$	用户自标的颜色（如“红”、“蓝”）
情绪向量	$e(c_{i,t})$	把颜色编成五个数字，方便计算
反思文本	$\text{text}_{i,t}$	用户写的话

场景标签	$\text{scenario}_{i,t}$	当前场景，例如“语法填空第 9 篇”

一个重要的区别

θ 是**算出来的**，c 是用户**自己标的**。

一个是客观计算结果，一个是主观自报。两者可以互相验证——如果一个人说自己“很平静”（蓝色），但算出来的 θ 很高（迷糊），系统就会知道这里有矛盾。

26.2 群体记录

把很多人的记录合并（脱敏后），得到群体记录：

$$B_{s,t}^{\text{group}} = \left\langle s,\ \bar{\theta}_{s,t},\ \sigma_{\theta,s,t},\ \bar{\phi}_{s,t},\ \bar{c}_{s,t},\ H_{s,t},\ C_{s,t},\ N_{s,t} \right\rangle \tag{17}$$

逐符号解释

s	场景标签（比如“早自习”）
$\bar{\theta}_{s,t}$	平均融合角。符号上的横线 $\bar{}$ 表示“平均值”。
$\sigma_{\theta,s,t}$	希腊字母 sigma。标准差，衡量“大家差得多不多”。σ 大 = 有人清醒有人迷糊
$\bar{\phi}_{s,t}$	平均认知相位
$\bar{c}_{s,t}$	平均情绪色相（群体情绪基调）
$H_{s,t}$	场景场强（这个场景的总体压力）
$C_{s,t}$	群体一致性（大家有多齐）
$N_{s,t}$	样本数量（有多少人）

脱敏是什么意思

“脱敏”就是把能识别到具体个人的信息去掉：

- 删掉 ID；
- 人数太少时不出结果（比如少于 5 人）；
- 极端值合并成“其他”。

目的：**任何人拿到这份数据，都不能反推出“某个具体的人状态不好”**。

26.3 教育场景的扩展字段

在教育场景里，Being 记录额外挂一个“学业载荷”：

$$\begin{aligned}\text{academic}_{i,t} = \big\langle\ &\text{item_id},\ \text{question_no},\ \text{correct},\ \text{error_type},\\ &\text{latency},\ \text{marked_words},\ \text{marked_sentences},\ \text{attempt_no}\ \big\rangle\end{aligned} \tag{18}$$

字段	含义
item_id	哪一篇讲义，例如“语法填空第 9 篇”
question_no	第几题，范围 56-65
correct	对还是错
error_type	错因分类：时态 / 语态 / 词性 / 搭配 / 从句 / 非谓语
latency	用了多长时间（秒）
marked_words	这个学生标记的重点单词
marked_sentences	标记的重点句子
attempt_no	第几次做这道题

26.4 出域白名单：五个字段

在校内模式下，学生数据保存在学校。只有这五项允许离开：

允许出域	说明
`item_id`	题目标识
`question_no`	题号
N	作答人数
`correct_rate`	正确率
`error_distribution`	错因分布

绝不出域（这些必须留在学校）：

$$\theta,\ \phi,\ \gamma,\ c,\ e(c),\ \text{text},\ \text{所有学号} \tag{19}$$

为什么这条线要划在这里

- 正确率、错因分布这类数据，说“这个班这道题 70% 做对”是教学信息；
- 而 θ、情绪、文本属于**心理状态信息**，一旦流出就可能被滥用；
- 最危险的是“反推”：如果一个班只有 8 个人，光看“有 1 人情绪异常”很容易猜到是谁。

所以规则是：**聚合到班级以上、且人数足够多时，学业数据可以出域；心智数据永不出域。**

27 换单位：会话建模

27.1 转折点

把三次尝试并排：

加了什么	AIC	时间重标通过率
什么也不加（单尺度）	基准	36.7 %
+ 第二个时间尺度	略好	36 %
+ 昼夜周期	明显好	36.7 %

两个假设都让模型拟合得更好，但没有一个能让时间重标通过。

这个现象指向什么 当模型越改越复杂、却仍然通不过检验时，问题通常在建模对象的定义上，而不在模型的容量上。

换句话说：**不是模型不够强，是“什么算一个事件”选错了。**

27.2 新假设：基本单位应该是“一次会话”

学生行为不是“自激点过程”，而是**“离散学习会话的到达过程”**。

拆开就是：

1. 学生坐下来学习 → 30 分钟内密集作答 20 30 题（**会话内**）；
2. 然后离开 → 可能隔几小时、也可能隔几天（**会话间**）；
3. **会话的发生由作息、课表决定，不是由上一个作答激发的。**

27.3 会话怎么定义

$$\text{相邻两次事件间隔} > \tau_{\text{gap}} \implies \text{换了一个会话} \tag{20}$$

符号说明

- τ_{gap}（读作“tau gap”）：切分阈值，默认取 **30 分钟**。
- 意思是：如果两道题之间隔了超过 30 分钟，就认为“这不是同一次学习”。
- 这个定义简单到近乎粗糙——但后面会看到它对结论不敏感。

27.4 会话长什么样

对 41 名学生切分后：

指标	中位数
每个人的会话数	**14**
每次会话的作答数	**13**
每次会话时长	**15.4 分钟**
会话内作答速率	**51 次 / 小时**

通俗读数：学生一次学习通常持续 15 分钟、做 13 道题，速率约每分钟 0.85 题。会话之间可能隔几小时甚至几天。

27.5 核心结果

27.5.1 配对比较（24 名学生）

指标	事件层面	会话层面
分支比（中位）	0.929	**0.543**
分支比更低的用户数	—	**24 / 24**

每一名学生的分支比都下降了，没有一个例外。这不是抽样波动，是系统性变化。

27.5.2 加入时间重标检验（10 名会话数足够的学生）

指标	事件层面	会话层面
分支比（中位）	0.917	**0.543**
KS 统计量（中位）	0.122	0.135
KS 通过率	**10 %**	**100 %**
分支比更低的用户数	—	**10 / 10**

最关键的一行 **KS 通过率从 10% 升到 100%。**

也就是说，“会话是基本事件”这个模型，**通过了时间重标检验**— 而事件层面的 Hawkes 做了三次改进都无法通过。

27.6 切分阈值的敏感性

会话怎么切，会不会影响结论？扫描 τ_{gap} 从 6 分钟到 4 小时：

τ_{gap}	会话数中位	分支比中位	KS 通过率
0.10 h（6 分）	20	0.492	93 %
0.25 h（15 分）	16	0.500	100 %
0.50 h（30 分）	**14**	**0.497**	**100 %**
1.00 h	12	0.447	100 %
2.00 h	11	0.475	100 %
4.00 h	9	0.000	100 %

读数 在 **6 分钟到 2 小时**这个很宽的范围内：

- 分支比稳定在 0.45 0.50；
- KS 通过率始终在 93% 100%。

结论不依赖阈值的具体取值—这是很强的稳健性证据。

27.7 三层结构终于闭合

层次	问题	答案	证据
(1)	数据有结构吗？	有	0.93 vs 泊松 0.09
(2)	是“单次作答自激”吗？	不是	24/24 人换成会话后分支比下降
(3)	是“会话到达”吗？	是	会话层面 KS 通过率 **100%**

27.8 剩下的 0.54 是什么

会话层面的分支比仍有 0.54，说明**会话之间还有一定的自激**，可能是：

- 一次学习之后更容易再学一次（习惯 / 惯性）；
- 或者作息、周计划带来的规律性。

0.54 是一个“中等自激”的合理读数，与“学生会连着几天学习、也会连着几天不学”的直觉一致。

28 会话本身长什么样

上一期把单位换成会话就停了，没有细看会话本身。这一节先把它看清楚。

28.1 会话有多大：幂律

对 653 次会话（41 名学生）的大小做分布拟合：

分布	参数	对数似然	AIC
幂律	$\alpha = 1.342$	-1929.8	**3861.5**
对数正态	$\mu = 2.23,\ \sigma = 1.19$	-2497.7	4999.4
几何分布	$p = 0.057$	-2501.4	5004.7

幂律以约 1,140 的 AIC 优势胜出——这不是微弱差别。

幂律长什么样 幂律就是 $P(k) \propto k^{-\alpha}$：**大部分会话很小，但偶尔出现极长的会话**，而且这种长尾不是异常值，是分布的固有部分。

拟合出 $\alpha \approx 1.34$，属于长尾很重的一档。通俗说：**少数几次学习，占了总题量的大部分。**

产品含义：如果按“平均每次做 10 题”来设计提醒和任务，会完全错过那几次决定性的长会话。

28.2 会话内有疲劳吗：没有，反而有热身

把会话内部的作答间隔按相对位置分箱（0 = 开始，1 = 结束）：

相对位置	作答间隔中位数（秒）	样本数
0.1（开始）	**42.19**	2,259
0.3	41.40	2,087
0.5	38.60	2,079
0.7	38.63	2,093
0.9（结束）	**38.53**	1,908

这不是疲劳，是热身 如果存在疲劳，应该看到间隔**变长**（越做越慢）。

实测是**变短**（42.2 秒降到 38.5 秒，降幅约 9%）。

说明学生需要一个“进入状态”的过程：前几十秒在回忆规则、适应题型，之后速度稳定下来。

产品含义：会话开头的题目**不应该太难**——那正是学生还在热身的时候。

28.3 有没有周周期：有，而且很强

把全会话开始时刻映射到“周内小时”（0~167）：

检验	χ^2 统计量	自由度
星期分布	**59**	6
周内 168 小时分布	**781**	167

若完全均匀，χ^2 应约等于自由度。实测远大于临界值，周结构显著存在。

第四部分　Tender 建模核心

29　心智化系统的核心公式

这一章回答一个问题：怎么用数据表示“一个人的认知状态”？

29.1　认知态：一个球面上的点

系统用一个叫 **Bloch 球**（布洛赫球）的几何对象来表示认知状态。不要被名字吓到，它就是一个普通的球。

想象一个地球仪：

- 球面上每一个点，代表一种认知状态；
- 用两个角度就能定位一个点：
  - θ（融合角）：决定纬度——点在上半球还是下半球；
  - ϕ（认知相位）：决定经度——点在东半球还是西半球。

29.1.1　认知态的数学写法

$$|\psi\rangle = \cos\left(\frac{\theta}{2}\right)|D\rangle \;+\; e^{i\phi}\sin\left(\frac{\theta}{2}\right)|F\rangle \tag{21}$$

逐符号解释

ψ	希腊字母 psi，读音“普西”。$\|\psi\rangle$ 表示“这个人的认知状态”。
$\|D\rangle$	区分态（Differentiated）。代表“思路清晰、能分清事实与感受”。
$\|F\rangle$	融合态（Fused）。代表“纠缠在一起、分不清”。
θ	融合角，范围 $[0,\pi]$。$\theta=0$ 表示完全区分，$\theta=\pi$ 表示完全融合。
ϕ	认知相位，范围 $[0,2\pi]$。表示“走的是哪条路径”。
$e^{i\phi}$	复数相位因子。本文只用到它的一个性质：模长恒为 1，不影响概率大小。
i	虚数单位，$i^2=-1$。这里只是数学记号，不代表真实物理量子效应。

用一句话理解

θ 越小，$|D\rangle$（清晰态）的成分越多，人越清醒；

θ 越大，$|F\rangle$（融合态）的成分越多，人越迷糊。

29.1.2　从认知态推出“答对概率”

这是本文最关键的映射之一。在 Bloch 球表示下：

$$P(\text{区分态}) = \cos^2\left(\frac{\theta}{2}\right) \tag{22}$$

符号说明与直觉

- 左边：处于“清晰态”的概率，取值范围 $(0, 1)$。
- 右边：$\theta/2$ 的余弦的平方。
- **代入验证：**
  - $\theta = 0$ 时，$\cos^2(0) = 1$，即 100% 清晰；
  - $\theta = \pi$ 时，$\cos^2(\pi/2) = 0$，即 0% 清晰；
  - $\theta = \pi/2$ 时，$\cos^2(\pi/4) = 0.5$，即一半一半。
- **在第 5 章的实验中**，这个量被直接当作“答对概率”使用。

29.2 四源合成：θ 是怎么算出来的

单个来源不够可靠，所以系统用四个来源加权合成：

$$\theta_{i,t} = \alpha_\theta(t)\,\theta^{\text{color}}_{i,t} \;+\; \beta_\theta\,\theta^{\text{text}}_{i,t} \;+\; \gamma_\theta\,\theta^{\text{seq}}_{i,t} \;+\; \delta_\theta(t)\,\theta^{\text{HRV}}_{i,t} \tag{23}$$

逐符号解释

$\theta_{i,t}$	用户 i 在时刻 t 的融合角（最终结果）。
θ^{color}	由用户自标的颜色推算出的融合角。
θ^{text}	由用户写的文字推算出的融合角。
θ^{seq}	由历史行为序列推算出的融合角。
θ^{HRV}	由心率变异性（生理信号）推算出的融合角。
$\alpha_\theta(t)$	颜色权重，动态调整，默认范围 0.10–0.35。
β_θ	文字权重，默认 0.30。
γ_θ	序列权重，默认 0.15。
$\delta_\theta(t)$	生理权重，动态调整，范围 0–0.45。

约束：四个权重之和恒为 1，即 $\alpha + \beta + \gamma + \delta = 1$。

为什么权重是动态的 如果采集到的生理信号质量很差（比如手环没戴稳），系统会自动降低 δ_θ，把权重让给更可靠的来源。这叫“按信号质量分配信任”。

29.3 序列分量：θ 怎么随时间变化

这是第 5 章实验真正用到的公式（因为实验数据只有作答序列）：

$$\theta^{\text{seq}}_{i,t} = \theta_{i,t-1} \;+\; \eta \cdot \Delta t \cdot \text{趋势} \;+\; \xi \cdot \text{场景切换惩罚} \tag{24}$$

逐符号解释

$\theta_{i,t}^{\text{seq}}$	用户 i 在时刻 t 的序列分量。
$\theta_{i,t-1}$	上一个时刻的融合角。
η	希腊字母 eta，读音“伊塔”。学习率，即每一步 θ 变化多大。**文档默认 0.3**。
Δt	时间步长。相邻两次作答时取 1。
趋势	最近的变化方向。本文取：**答对 $= -1$，答错 $= +1$**。
ξ	希腊字母 xi，读音“克西”。**场景切换惩罚**，文档默认 0.15。
场景切换惩罚	当学生从一个知识点换到另一个知识点时，加一点不确定性。

通俗理解：

“如果你刚才就很迷糊，现在大概率也不会突然清醒。”
答对一次，θ 往下走一点（更清醒）；答错一次，θ 往上走一点（更迷糊）。

29.4 冲击响应饱和

如果一道题错了，θ 应该跳多少？系统用了一个“饱和函数”：

$$\alpha = \frac{0.5 \cdot s}{0.618 + |s|} \tag{25}$$

逐符号解释

- s：冲击信号强度。取绝对值 $|s|$。
- 0.5：分子系数。
- 0.618：分母常数，等于 $1/\varphi$（黄金比的倒数）。
- α：实际冲击幅度。

为什么要“饱和”：如果冲击不设上限，一次极端事件就能把状态推到极端。饱和函数的作用是让冲击有一个天花板。

代入计算：当 $|s| = 1$ 时，

$$\alpha = \frac{0.5 \times 1}{0.618 + 1} = \frac{0.5}{1.618} = 0.309 \tag{26}$$

29.5 临界纬线：什么时候算“该干预”

系统画了一条线，θ 超过它就算“不适合干预”：

$$\theta_{\text{th}} = \arccos\left(\frac{1}{\varphi}\right) = \arccos(0.618) \approx 0.9046 \text{ 弧度} \approx 51.8^\circ \tag{27}$$

逐符号解释

- θ_{th}：临界融合角（threshold），本文中读作“θ 阈值”。
- arccos：反余弦函数，是 cos 的反函数。已知余弦值，求对应的角度。
- $1/\varphi = 0.618$：黄金比的倒数。
- 0.9046 弧度：换算成角度约 51.8°。

29.6 心智化窗口判据

$$\text{Mentalizing_Open} = \begin{cases} 1, & \theta < \theta_{\text{th}} \text{ 且 } \rho < \rho_{\text{th}} \\ 0, & \text{其他情况} \end{cases} \tag{28}$$

逐符号解释

- Mentalizing_Open：心智化窗口是否打开。1 = 打开，0 = 关闭。
- θ：当前融合角。小于阈值表示“够清醒”。
- ρ：希腊字母 rho，读音“柔”。情绪惯性，值越大表示情绪越难平复。
- ρ_{th}：情绪惯性的阈值。

这就是整本书的核心 当窗口打开时（θ 小、情绪稳），系统才推新知识；
当窗口关闭时，系统改做低负荷的事，或者只陪伴、不干预。
这一条判断，就是本系统区别于普通教育软件的全部要害。

29.7 三端的窗口化身

同一个判断逻辑，在三类对象上分别表现为：

对象	窗口问题	窗口关闭时的行为
学生端	现在适合学新知识，还是先巩固？	不推新知识点，改做低负荷练习
教师端	现在适合讲新内容，还是先讲错题？	不讲新内容，先做错题干预
销售端	现在适合推招生，还是先建信任？	不发招生内容，先发干货

30 什么是“自激过程”

这一章开始进入这一期真正的主角。

30.1 先说什么叫“点过程”

点过程就是“一串事件发生的时间点”。

例如：一条视频发布后，点赞发生的时刻是 第 3 分钟、第 5 分钟、第 5 分 20 秒、第 12 分钟、……

这一串时间点就是一个点过程。

点过程和普通数据的区别 普通数据是“一次一个值”（比如身高 175cm）。

点过程是“什么时候发生了一件事”。研究的是**时间和时间的间隔**，不是数值大小。

30.2 自激是什么意思

自激（self-exciting）的直觉是：

一件事发生之后，下一件事更容易发生。

例子：

- 地震：一次地震后余震更频繁（这是 Hawkes 过程的原始应用）；
- 交易：一笔大单后常有更多交易；
- 平台：有人说“一个赞会带来更多赞”。

为什么这件事重要 如果“互动会引发更多互动”是真的，那运营策略就是**制造初始互动**。

如果它是假的（只是平台在推流），那策略就应该是**优化内容以通过平台筛选**。

两种解释导致完全不同的做法。

30.3 Hawkes 过程的三个符号

Hawkes 过程是描述自激的标准数学模型。它有三个参数：

符号	名称	含义
μ	基线强度	没有历史事件时，单位时间的发生率
α	激发增量	每来一个事件，后续强度抬高多少
β	衰减速率	激发效应衰减多快

30.4 强度函数：核心公式

$$\lambda(t) = \mu + \sum_{t_j < t} \alpha\, e^{-\beta(t-t_j)} \tag{29}$$

逐符号解释

$\lambda(t)$	t 时刻的**瞬时强度**——可以理解为“此刻事件发生的急迫程度”
μ	基线强度（上面表格里的那个）
$\sum_{t_j<t}$	对所有“发生在 t 之前”的事件求和
t_j	第 j 个历史事件的时刻
$t - t_j$	距离那个事件过去了多久
$e^{-\beta(t-t_j)}$	**衰减因子**。间隔越久，影响越小
α	每个历史事件贡献的强度

通俗理解：

“此刻的活跃程度 = 本来就有多活跃（μ）+ 之前每个事件留下的余温（$\alpha e^{-\beta\Delta t}$）”

30.5 分支比：判断会不会“自持”

$$n = \frac{\alpha}{\beta} \tag{30}$$

分支比的三种情况

n 的值	含义
$n < 1$	**平稳**。一次事件引发的后续影响会逐渐消失
$n \to 1$	**接近临界**。一次事件可能引发很长的连锁反应
$n > 1$	**发散**。过程会爆炸（现实中不可能持续）

直觉：n 就是“一个事件平均能引发多少个后续事件”。

31 第一次建模尝试：一个看起来很漂亮的结果

31.1 用什么数据

我用了 EdNet 数据集——一个公开的在线学习平台日志，里面有**毫秒级的时间戳**。取其中 236 名学生的“作答”事件（respond），转换成小时，然后拟合 Hawkes。

31.2 结果

指标	数值
分析学生数	236
分支比中位数	**0.941**
分支比均值	0.927
分类为“接近临界”的学生	219 人
分类为“强自持”	16 人
分类为“弱自持”	1 人

看到这个结果的第一反应 “分支比 0.94！**学生的作答几乎全部处于临界状态！**”

“临界状态意味着：一次作答能引发接近 1 次后续作答，”“这是典型的自组织临界性，是个重大发现！”

但这个结论是错的。下一章讲怎么发现的。

先记住一条纪律 得到一个漂亮结果时，第一件事不是写论文，而是问：

> **“如果我把它打乱，还会得到同样的结果吗？”**

这就是下一章的**安慰剂检验**。

32 分层模型：共享形状

修好上面两个问题后，才做成了这件事。

32.1 为什么要共享

每个用户单独估 7 个参数（3 个动力学 + 4 个傅里叶系数），但每人只有十几个会话——**形状参数估不准**。

分层方案：把参数分两层。

层	参数	个数
共享层（所有人相同）	傅里叶形状 a_1, b_1, a_2, b_2	4
个体层（每人一套）	幅度 μ_0、自激 α、β	3 / 人

总参数 $= 4 + 3N$。以 $N = 21$ 为例：**67 个**，对比“各自 7 个”的 147 个。

32.2 算法：交替优化

一次性优化 67 维非凸问题很难。改成轮流：

1. 固定共享形状 → 每个用户的 (μ_0, α, β) **互相独立**，可各自快速求解；
2. 固定个体参数 → 只优化 4 个共享系数；
3. 重复 1、2 直到收敛。

实际跑 4 轮，似然变化：$-2205 \to -2177 \to -2173 \to -2173$（第 4 轮已收敛）。

32.3 结果

模型	总对数似然	总 AIC	参数总数
无周期（3 / 人）	-2198.7	4523.5	63
各自独立傅里叶（7 / 人）	-2092.3	**4478.6**	147
共享形状（4 共享 + 3 / 人）	-2173.1	**4480.2**	**67**

核心读数 **AIC 差 1.6，参数少 54%。**

统计上 AIC 差小于 2 通常视为“无差别”。所以：

共享形状用一半的参数，达到了和独立拟合一样的效果。

32.4 拟合出的共享形状：一日双峰

把共享系数转成一天内的相对活跃度 $m(h)$：

时段	相对活跃度	
00 时	2.52	最高
13 时	**1.78**	次峰
06–07 时	**0.13**	谷底
23 时	2.40	高

峰值 2.56（约 24 时），谷值 0.13（6.5 时），峰谷比 20.2 倍。

一个有意思的细节 比较两个谐波的振幅：

谐波	周期	振幅
1 阶	24 小时	0.736
2 阶	**12 小时**	**1.024**

12 小时周期的振幅比 24 小时还大——意味着一日**两个**活跃高峰，而不是“白天活跃、晚上安静”的单峰模式。

与实际一致：**下午（13 时）一个峰，深夜（23–24 时）另一个峰。**

32.5 产品价值：冷启动

新用户只需要估 3 个参数 共享形状已经有了，新用户只需要估 μ_0, α, β 三个参数，**十几个会话就能稳定**。

而独立拟合需要 7 个参数，同样数据量下估不准。

这是分层模型最直接的工程价值。

33 从群体走向个体：MBTI 这条路

前面几节都在处理“群体的作息规律”。这一节开始处理**个体差异**。

33.1 为什么想用 MBTI

出发点很朴素：如果不同的人有不同的“节奏偏好”，那给所有人推同样的学习安排就是浪费。

MBTI 和荣格八维提供了一个现成的语言体系来描述这种差异。

33.2 但必须先说清楚它的证据基础

问题	具体表现
重测一致率低	同一人隔几周重测，得到同一“类型”的比例通常只有 50%–75%
不是双峰分布	四个维度上多数人落在中间，并不天然分成两类
类型学不成立	“16 型”分类框架的构念效度缺乏支持
与五大人格的关系	四维与 Big Five 有中等相关，但**信息量不如 Big Five**
荣格八维	**没有强心理测量学支持**，是解释性框架，不是测量工具

所以本项目的三条使用原则

1. **只用连续分数，不用类型**
   模型里存“外倾倾向 = 73 分”，不是“你是 E 型”。
2. **不宣称是“测量”**
   可以说“这个倾向帮你理解自己的学习节奏”，不能说“测出你是 INTJ”。
3. **必须能被证伪**
   登记具体假设，用数据检验。不通过就撤掉。

33.3 把抽象维度变成可测指标

MBTI 的维度本身测不了，但它的**行为表现**可以测。所以每条假设都对应一个能从会话数据算出的指标：

编号	性格维度	行为指标	方向	理由
H1	J（判断端）	作息集中度 R	+	偏好计划的人作息更规整
H2	J（判断端）	作息熵	−	同上
H3	Si（内倾感觉）	间隔变异 CV	−	习惯固定
H4	Ne（外倾直觉）	间隔变异 CV	+	发散，间隔不稳
H5	S（感觉端）	大小变异 CV	−	偏好稳定，任务量均匀
H6	N（直觉端）	大小基尼	+	容易一口气做很多

H7	E（外倾端）	会话时长中位	−	倾向短而频繁
H8	I（内倾端）	会话时长中位	+	倾向长而稀少

33.3.1 四个行为指标怎么算

指标	定义	取值
作息集中度 R	活动时刻在 168 小时周期上的**合向量长度**	0= 完全分散，1= 完全集中
作息熵	周内分布归一化后的香农熵	0= 集中，1= 均匀
间隔变异 CV	相邻活动间隔的标准差 ÷ 均值	越小越规律
大小基尼	活动量的基尼系数	0= 均匀，1= 极不均

什么是“合向量长度” 把每个活动时刻换算成圆上的一个角度，然后把这些角度的单位向量**加起来**，取合向量的长度。

- 如果所有活动都在同一时段 → 向量全同向 → 合向量很长（$R \to 1$）；
- 如果活动均匀散布在整周 → 向量相互抵消 → 合向量很短（$R \to 0$）。

这是一个纯粹的几何量，不需要任何参数，所以无法通过调参来“制造”结果。

34 把 MBTI 和节律指标接起来

第 6 节列了 8 条 MBTI 假设，第 8 节标定了效应量。但中间还缺一环：**因变量选得对不对。**

34.1 之前的因变量不够好

第 6 节用的是“作息集中度 R”——它只有**一个数**，把两种完全不同的模式混在一起：

模式	集中度 R
天天在固定时间学	高
只在每周三学	**也高**

但这两类学生的干预方式**完全不同**：前者改习惯（几点学），后者改安排（哪几天有课）。

问题出在“一个数描述两件事” “集中度 R”衡量的是活动在周内是否聚集——但“天天同一时刻”和“只在某一天”都会让它变高。

一个指标同时响应两个机制，就没法区分它们。

34.2 新因变量：把集中度拆成三个

用 extbfRayleigh 周期图把“集中度”拆开。这个方法很简单：对一个候选周期 P，把每个事件时刻换成 extbf 相位：

$$\phi_i = \frac{t_i \bmod P}{P} \in [0, 1) \tag{31}$$

如果活动确实以 P 为周期聚集，ϕ_i 就会集中在某个值附近。用**合向量长度**衡量集中程度：

$$C(P) = \frac{1}{n}\sum_i \cos(2\pi\phi_i), \qquad S(P) = \frac{1}{n}\sum_i \sin(2\pi\phi_i) \tag{32}$$

$$R(P) = \sqrt{C(P)^2 + S(P)^2} \in [0, 1] \tag{33}$$

为什么用这个，不用普通功率谱 普通功率谱（FFT / Lomb-Scargle）是给**连续信号**用的。作息是**点过程**——有活动才有记录，一天可能只有一次。

对“每天一次”的脉冲做功率谱，会在 12h、8h、6h……产生大量**谐波**，功率被摊开，反而看不清主节律。

Rayleigh 周期图是点过程的标准工具，**直接问“相位是否聚集”**，不产生谐波问题。

显著性：零假设（相位均匀）下 $Z = nR^2 \sim \mathrm{Exp}(1)$，故 $p = e^{-Z}$。

代入两个关键周期，就得到三个指标：

指标	含义
R_{24}	日内强度。**时间点是否固定**（每次都差不多同一时刻）
R_{168}	周内强度。**是否集中在周内的特定位置**（特定星期几 + 时间）
$B = R_{168}/R_{24}$	**每日型还是间歇型**。B 小 = 天天学；B 大 = 只在某些天学

再加上节律基线给出的两个：

指标	含义
偏离度中位	这个人**平时**偏离自己基线多少（水平）
偏离度标准差	这个人的偏离**稳不稳定**（波动）

34.2.1 实测示例

在 EdNet 数据上，两个学生的对比很清楚地说明这个拆分有用：

学生	R_{24}	R_{168}	B	类型
u1	0.119	0.301	**2.536**	**间歇型**（只在某些天）
u1007	**0.942**	0.600	0.637	**每日型**（天天固定时刻）

u1 的 R_{24} 只有 0.119（时间点很不固定），但 B 高达 2.54；**u1007 的 R_{24} 是 0.942**（时间点高度固定）。在旧的“集中度 R”里，这两个人可能得到相近的分数——**但他们是完全不同的人。**

34.3 核心理论点：trait 与 state 必须分开

这是本次结合中**最重要的一个区分**。

trait（特质）vs state（状态）

	稳定性	影响什么
性格（trait）	稳定	节律的**水平**：R_{24}、B 的平均值
事件（state）	临时	节律的**波动**：偏离度的波动大小

为什么必须分开 如果把两者混在一起，就会把 **“这周考试所以作息乱了”**错误归因成 **“这个人性格如此”**。

这样的结论不仅错，而且会**给学生贴上一个不该贴的标签**——而标签造成的自我实现预言，正是第 6 节开头警告过的事。

所以假设必须分成两组：

- **A 组（水平假设）**：性格 → 节律指标的**平均水平**；
- **B 组（波动假设）**：性格 → 偏离度的**波动大小**。

34.4 更新后的假设表

编号	组	性格维度	因变量	方向	理由
H1	A 水平	JP（判断端）	R_{24}	+	偏好计划 → 时间点固定
H2	A 水平	JP（判断端）	节律平衡 B	−	J 偏每日型，P 偏间歇型
H3	A 水平	Si	R_{24}	+	依赖既有习惯 → 高度重复
H4	A 水平	Ne	节律平衡 B	+	发散探索 → 集中在少数时段
H5	B 波动	JP（判断端）	偏离度标准差	−	计划性强 → 状态更稳
H6	B 波动	Ne	偏离度标准差	+	发散 → 起伏更大
H7	**对照**	EI	偏离度中位	**0**	**阴性对照，理论上不应相关**

H7 是“阴性对照”，为什么要有它 H7

假设 EI（内外倾）与作息稳定性**没有**直接理论联系。

如果这个假设**显著了**，说明分析流程里可能有系统偏差——比如某个共同的混杂变量，或者某个指标定义有问题。

阴性对照的作用，和前面“安慰剂检验”是同一个思路：用一个“本该没有效应”的检验，来检查工具本身。

34.5 这个结合带来了三样东西

1. **因变量从“一个模糊的数”变成“两个可分别干预的维度”**——R_{24} 对应改习惯，B 对应改安排；
2. **引入了 trait/state 的区分**——避免把临时事件错误归因成性格；
3. **加了一条阴性对照**（H7）——可以检测系统性偏差。

34.6 对预注册的影响

预注册文档里的因变量需要相应更新：

预注册 v1（原）	预注册 v2（更新）
主假设因变量：作息集中度 R	主假设因变量：R_{24}（时间点规律）
次要因变量：作息熵、间隔 CV 等	次要因变量：B、偏离度中位、偏离度标准差
—	新增阴性对照 **H7**

必须在看数据之前改 现在还没有收任何 **MBTI** 数据，所以现在改是**合法的**。

一旦收了数据再改因变量，那就变成了事后挑选——

这正是预注册要防的事。

换句话说：**改设计要趁早，趁你还没看到答案。**

35 基线：用户与环境的耦合

35.1 为什么基线不是“固定性格”

假设一个学生原来每天晚上 20:00 学习，表现稳定。后来学校把晚自习调到 19:00，他连续两周状态变差。这时他的“基线”变了吗？

如果基线是固定性格，答案是不变；如果基线是耦合稳定点，答案是：**环境变了，基线也跟着移动。**

第四期采用后一种定义。

35.2 形式定义：耦合动力系统

把学生状态记作 x_t，学生行为记作 u_t，环境记作 e_t，慢参数记作 θ：

$$x_{t+1} = f(x_t, u_t, e_t; \theta) + \varepsilon_t. \tag{34}$$

符号逐一说明：

- x_t：第 t 期的学生状态（注意力、情绪、认知负荷、节律）；
- u_t：学生自己的行为（学习、休息、求助）；
- e_t：外部环境（任务、教师、同伴、排课、家庭）；
- θ：慢参数，类似 trait（MBTI 连续分数、节律峰型、注意偏好）；
- f：耦合函数；
- ε_t：噪声。

基线 x^* 是这个系统的稳定点：

$$x^* = f(x^*, u^*, e^*; \theta). \tag{35}$$

所以：

$$\text{基线} = \text{用户节律} \times \text{任务结构} \times \text{教师安排} \times \text{同伴环境} \tag{36}$$

的耦合结果，而不是“这个人单独拥有的一个数”。

35.3 和 MBTI 的区别

	MBTI 类 trait	**基线**
数学角色	慢参数 θ	耦合系统的稳定点 x^*
来源	自评量表	行为轨迹估计

稳定性	中等，重测信度弱	环境稳定时稳定，环境变则移动
干预	很难直接改	可以通过改安排来移动
正确用法	带不确定度的先验	动态监测的参照点

一句话区分

MBTI 是“这个人倾向于怎样”；
基线是“这个人和当前环境耦合成了怎样”。
两者短期都稳定，但扰动环境后，基线会移动，trait 不会移动那么多。

35.4 扰动实验：怎么判断一个量是 trait 还是 baseline

1. 改变环境：换时段、换任务、换分组；
2. 观察指标是否移动；
3. 如果移动明显，说明它是耦合/状态；
4. 如果几乎不动，才更像慢参数。

这也是“顺应天性优于强制改习惯”的形式化：

$$\Delta x^* = \underbrace{\frac{\partial f}{\partial e}\Delta e}_{\text{改安排}} + \underbrace{\frac{\partial f}{\partial x}\Delta x}_{\text{改习惯}} + \underbrace{\frac{\partial f}{\partial \theta}\Delta \theta}_{\text{改性格，最慢}} . \tag{37}$$

改安排通常成本最低、见效最快；改习惯其次；改性格最慢且最不确定。

35.5 真实数据：E2 与 E3

35.5.1 E2 节律–安排匹配（EdNet）

模型	系数	p
参与度 log(1+事件数) ∼ 匹配度 fit	+0.164	8.3×10^{-10}
退出率 ∼ 匹配度 fit	−0.00344	0.0078

对齐会话 vs 错位会话：3.913 vs 3.534，配对差 +0.379，$p = 2.8 \times 10^{-15}$，$d_z = 0.572$，有双条件的 221 名学生。

35.5.2 E3 习惯改变成本（OULAD）

模型	系数	p
下一周参与度 ~ 习惯改变	-1.134	5.9×10^{-247}
下一周退课 ~ 习惯改变	$+0.233$	1.2×10^{-197}
控制当前周点击后的参与度	-0.431	1.9×10^{-40}

高改变周 vs 低改变周：参与度差 -0.623（$d_z = -0.482$），退课率差 $+0.144$（$d_z = 0.423$）。

边界

E2/E3 都是观察性数据，不是随机强制改习惯的实验。

它们支持“耦合基线”的方向，但不能单独证明因果。

36 节律–安排匹配与习惯改变成本

36.1 核心原则

安排 > 强制改习惯 先改安排（低成本、低风险），再改习惯（高成本、高不确定）。

只有当预期收益超过改变成本时，才要求改习惯。

36.2 E2：节律–安排匹配

36.2.1 定义

每个学生有一个日内峰型 peak_i。一次会话的开始小时记作 h_s。定义匹配度：

$$\text{fit}_s = \cos\left(\frac{2\pi(h_s - \text{peak}_i)}{24}\right). \tag{38}$$

符号说明：

- peak_i：学生 i 的日内节律峰型（0–24 小时）；
- h_s：会话 s 的开始小时；
- $\text{fit}_s = +1$：正好在峰型；
- $\text{fit}_s = -1$：相差 12 小时。

36.2.2 真实结果（EdNet）

模型	系数	p
参与度 $\log(1+\text{事件数}) \sim \text{fit}$	$+0.164$	8.3×10^{-10}
退出率 $\sim \text{fit}$	-0.00344	0.0078

对齐会话 vs 错位会话：3.913 vs 3.534，配对差 $+0.379$，$p = 2.8 \times 10^{-15}$，$d_z = 0.572$。

36.2.3 功效

真实 β	19 人	50 人	100 人
0.05	0.219	0.483	0.774
0.10	0.657	0.970	1.000
0.20	0.997	1.000	1.000

36.3 E3：习惯改变成本

36.3.1 定义

把前 4 周按 $date \bmod 7$ 的点击分布记作 baseline_profile。第 w 周的分布记作 current_profile。定义：

$$\text{habit_change}_w = \frac{1}{2}\sum_{k=0}^{6}\left|\text{current_profile}_{w,k} - \text{baseline_profile}_k\right|. \tag{39}$$

符号说明：

- $k = 0, \ldots, 6$：一周内的 7 个相位；
- 0：完全保持原有节奏；
- 1：完全换了一周节奏；
- 这个量只用点击分布，不用内容，所以可跨课程比较。

36.3.2 真实结果（OULAD）

模型	系数	p
下一周参与度 ~ habit_change	-1.134	5.9×10^{-247}
下一周退课 ~ habit_change	$+0.233$	1.2×10^{-197}
控制当前周点击后的参与度	-0.431	1.9×10^{-40}

高改变周 vs 低改变周：

- 参与度：2.060 vs 2.683，差 -0.623，$d_z = -0.482$；
- 退课率：0.286 vs 0.142，差 $+0.144$，$d_z = 0.423$。

36.3.3 边界

这是观察性关联，不是随机强制改习惯的实验。
控制当前周点击后仍显著，说明不只是“低参与度的镜像”，但仍可能有第三变量。

36.4 课堂怎么用

1. 先测每个学生的节律峰型（可用 1–2 周的自报 + 行为日志）；
2. 排课时尽量把高难度任务放在峰型附近；
3. 如果要改变学生的习惯，先问：是安排不能改，还是我们不愿意改安排？
4. 如果必须改习惯，给小步、给反馈、给缓冲期，不要一次改到底。

37 黄金比、基线闭环与自相似

37.1 三个概念要分开

37.1.1 基线闭环

系统受扰动后回到基线，形成一个回路：

$$x_{t+T} \approx x_t. \tag{40}$$

符号说明：

- x_t：第 t 期状态；
- T：回路周期；
- $x_{t+T} \approx x_t$：经过一个周期后回到接近原来的状态。

37.1.2 自相似

同一结构在不同尺度重复出现：

$$f(\lambda x) = \lambda^{\alpha} f(x). \tag{41}$$

符号说明：

- λ：尺度因子；
- α：标度指数；
- 这是**幂律/尺度不变**，不是黄金比。

37.1.3 黄金比

$$\varphi = \frac{1+\sqrt{5}}{2} \approx 1.618. \tag{42}$$

37.2 关键结论：自相似 + 闭环不自动推出黄金比

自相似只推出“没有特征尺度”（power law），不推出某一个特定常数。
黄金比只在**特定动力系统**里出现，例如某些 KAM 环面的黄金旋转数、Penrose 铺砌、部分最优觅食模型；它不是自相似系统的普遍常数。

37.3 你项目里现在的数据

量	当前值	是不是 φ
会话大小幂律指数	1.342	不是
周节律 168/24	7	不是
24 小时 / 90 分钟	≈ 16	不是

所以：**黄金比目前只能当隐喻，不能当结论。**

37.4 如果一定要检验它：预注册比例检验

1. 先定义两个嵌套尺度，例如：
   - 日循环 / 周循环；
   - 周循环 / 月循环；
   - 个人 / 小组 / 班级。
2. 计算比例 $r = T_{k+1}/T_k$；
3. 用 bootstrap 给 r 的置信区间；
4. 比较三个模型：
   - $H_\varphi : r = \varphi$；
   - $H_1 : r = 1$；
   - $H_2 : r$ 自由估计。
5. 用 Bayes factor 或交叉验证比较。

必须预注册 尺度定义必须先写死。
否则在大量比例里总能找到一个接近 φ 的，属于事后挑选。

37.5 更稳妥的“和谐”判据

与其追求 φ，不如用两个可检验的性质：

1. **回归性**：扰动后能回到基线，不发散；
2. **尺度不变性**：不同尺度上的形状相同，指数稳定。

也就是：

$$\text{闭环} + \text{自相似} \Rightarrow \text{尺度不变的稳定回归}. \tag{43}$$

这比“黄金比”更可证伪，也更贴合花/果/森林结构。

第五部分　验证、防错与预注册

38　关键工具一：安慰剂检验

38.1　什么是安慰剂检验

安慰剂检验（placebo test）来自医学：给病人吃没有药效的“假药”，如果病人也变好了，说明之前的效果不是药带来的。

搬到数据分析上：

> **把数据里的“结构”破坏掉，重新做一次分析。**
> **如果结果不变，说明原来的结果不是那个结构带来的。**

38.2　三路对照

我对 34 名学生做了三件事：

序号	对照	做法
1	**真实时间排布**	原始数据，不动
2	**间隔重排**	保持所有“间隔”的数值不变，只把它们打乱顺序
3	**均匀泊松**	同样的事件数、同样的时间跨度，但时间完全随机

什么叫“均匀泊松” 均匀泊松就是“完全随机、没有记忆”的事件流：任何时刻发生的概率都相同，而且不受之前事件影响。

它是“完全没有结构”的基准线。

38.3　结果

条件	中位分支比	说明
EdNet 真实	**0.9318**	原始数据
间隔重排	**0.9318**	打乱间隔顺序
均匀泊松	**0.0866**	完全随机

这三行怎么读（关键） **第一行 vs 第三行**：差 **0.845** → 学生的作答**确实不是随机的**，有强结构。

第一行 vs 第二行：差 **0.0001**（几乎没有）→ **打乱间隔顺序后，估计值一点没变**。

第二行才是要点：如果自激是真的，打乱先后顺序就该破坏它、让估计值掉下来。但它没掉。这说明这个模型根本没有在用“先后顺序”这个信息。

38.4　发现的第一个问题

> **模型拟合的是“间隔的分布”（有时隔几秒、有时隔几天），而不是“事件之间的激发关系”。**

在统计上这叫**识别性问题**：指数核 Hawkes 与“间隔过度离散的更新过程”在这类数据上**无法区分**。

39 关键工具二：时间重标检验

上一章只发现了问题，没有给出正确结论。这一章用更严格的工具。

39.1 原理

时间重标定理（Meyer 1971，Brown 等 2002）：

如果点过程的条件强度是 $\lambda(t)$，那么把每个事件时刻做如下变换：

$$\Lambda(t_i) = \int_0^{t_i} \lambda(s)\, ds \tag{44}$$

逐符号解释

$\Lambda(t_i)$	第 i 个事件的“累计强度”（读作“大写的 Lambda”）
$\int_0^{t_i}$	从 0 到 t_i 做积分——可以理解为“把这段时间里的强度全加起来”
$\lambda(s)$	s 时刻的瞬时强度（就是式 (29)）

这个定理说了什么 **变换之后，事件流应该变成一个“标准随机流”。**

具体说：重标后的间隔

$$\tau_i = \Lambda(t_i) - \Lambda(t_{i-1})$$

应当服从**标准指数分布 Exp(1)**，而且彼此独立。

所以这就是一个检验：

- 如果 τ 真的像 Exp(1) → 模型对
- 如果不像 → 模型设定有误

39.2 什么叫“像 Exp(1)”

Exp(1) 是“平均每秒发生 1 次、且完全随机”的间隔分布。它的特点：

- 大量短间隔、少量长间隔，长尾很长；
- 变异系数（标准差除以均值）等于 1。

检验方法用 **KS 检验**：

KS 检验零基础版 把实际数据和理论分布画成两条累积曲线，看两条线最大的垂直距离。

- 距离小 → 很像 → 通过
- 距离大 → 不像 → 不通过

这个距离叫 **KS 统计量**，越小越好。
同时给出 p 值：$p > 0.05$ **算通过**，$p < 0.05$ 算不通过。

39.3 引入一个真正的竞争模型

要判断“自激”是不是多余的机制，需要一个更简单的对照：

模型	强度依赖什么	参数个数
Poisson	什么都不依赖	1
Weibull 更新过程	**只依赖上一个事件**	2
Hawkes	**依赖全部历史**	3

为什么这个对照很关键 如果 Weibull 更新过程（**只依赖上一个事件**）与 Hawkes（**依赖全部历史**）拟合得一样好，那“自激 / 长记忆”这个机制就是多余的。
这就是奥卡姆剃刀：**能简单解释，就不要用复杂解释**。

39.4 结果

39.4.1 模型比较（45 名学生）

模型	中位对数似然	中位 AIC
Poisson	−385.4	+772.9
Weibull 更新	+336.4	−668.9
Hawkes	**+481.0**	−956.0

AIC 是什么 AIC 是“模型的综合评价”，同时考虑两件事：

- 拟合得好不好（对数似然越大越好）；
- 参数多不多（参数越多越容易过拟合，要惩罚）。

公式：AIC $= -2 \times$ (对数似然) $+ 2 \times$ (参数个数)。
AIC 越小越好。

读数：Hawkes 优于 Weibull 更新：**43 / 45 人**。中位 AIC 差距约 **287**——不是微小差别。
而且 Weibull 的形状参数中位是 $k = 0.299$（$k < 1$ 表示间隔高度聚簇）。

39.4.2 时间重标检验

模型	中位 KS	通过率	Lag-1 自相关
Hawkes	**0.110**	**38 %**	−0.104
Weibull 更新	0.258	0 %	−0.006
Poisson	0.884	0 %	−0.009

三条读数 **1.**

Poisson 彻底失败（KS 0.884，通过率 0%）：数据绝对不是常速率。

2. Weibull 更新也失败（KS 0.258，通过率 0%）：只依赖上一个事件不够。

3. Hawkes 明显更好，但也没通过（KS 0.110，仅 38% 通过）：方向对了，设定还不对。

39.5 修正后的结论

到这里，故事变成了三层：

层次	问题	答案	证据
(1)	数据有结构吗？	有，很强	0.93 vs 泊松 0.09
(2)	只依赖上一个事件吗？	不是	Hawkes 优于 Weibull：43/45
(3)	Hawkes 够吗？	不够	时间重标只有 38% 通过

所以上一章的表述要修正：“打乱间隔顺序结果不变”现在的解释是——**单指数核在这个参数区间对顺序不敏感**，这是核函数的局限，**不等于“没有长记忆”**。

40 两次改进尝试（都失败）

既然 Hawkes 的设定不对，那就要改。我试了两个方向。

40.1 尝试一：加一个时间尺度

40.1.1 动机

单指数核只有一个时间尺度。而学生的行为至少有两个：

尺度	时间范围	机制
快	秒　分钟	一道题到下一道题（会话内）
慢	小时　天	一次学习到下一次学习（会话间）

所以把核函数改成两个指数相加：

$$\phi(\Delta t) = \alpha_1 e^{-\beta_1 \Delta t} + \alpha_2 e^{-\beta_2 \Delta t} \tag{45}$$

40.1.2 第一次尝试失败的原因

第一次实现时，我直接在 $(\mu, \alpha_1, \beta_1, \alpha_2, \beta_2)$ 上做粗网格 + Nelder-Mead。结果两尺度反而比单尺度更差——这不可能，因为**单尺度是两尺度在 $\alpha_2 = 0$ 时的特例**，似然不可能更低。

这说明什么 **似然更低 = 优化没收敛**，不是模型不好。

问题有三个：

1. β 跨越 0.01 10 三个数量级，线性搜索空间尺度失衡；
2. 平稳性约束靠“拒绝”实现，优化器容易撞墙；
3. 没有 warm start，从随机点出发常常跑到边界。

40.1.3 修法

序号	修法	说明
1	参数变换	在 log 空间优化 $(\log\mu, \log\beta_1, \log\beta_2)$；分支比用两个 logit 保证 $n_1 + n_2 < 0.98$，**约束内建**，不再撞墙
2	warm start	先拟合单尺度，再用它的解分裂出快/慢两个尺度作为初值
3	多起点	从多个初值出发，取似然最高者

40.1.4 合成数据验证（先证明优化器能用）

用已知参数生成数据，再拟合回来：

两个尺度的分离程度	2 尺度中位误差	误差 < 0.10 比例
分离明显（β 差 60 倍）	**0.019**	**4/5**
分离中等（差 13 倍）	0.287	1/5
几乎单尺度（差 2 倍）	0.341	0/5

读数 两个**尺度分离明显时，新优化器能准确恢复参数（误差 0.019）。**

尺度接近时不可识别——这是数学上的必然（两条相近的指数和一条指数无法区分）。

同时可见：当真值是两尺度时，**单尺度核会系统性低估**（误差 -0.27 到 -0.40）。

40.1.5 EdNet 上的结果

指标	1 尺度	2 尺度
中位 AIC	-956.0	-961.5
AIC 更好的人数	—	**19 / 25**
中位 KS	0.1051	0.1032
KS 通过率	**36 %**	**36 %**
中位对数似然提升	—	$+7.2$

拟合出的尺度结构：慢尺度 $\beta = 0.82$、分支比 0.069；快尺度 $\beta = 24.77$、分支比 **0.886**；分离倍数 **28 倍**。

结论 两尺度在 AIC 上确实更好（19/25），但**时间重标通过率一点没改善**。

所以“缺尺度”不是根因。

40.2 尝试二：加昼夜周期

40.2.1 先验证昼夜结构是否存在

对 52 名学生的 49,576 条作答事件，按本地小时统计：

时段	事件数	相对水平
21 时（峰值）	4,770	最高
17 时	3,946	较高
5 时（谷值）	139	最低

$$\chi^2 = 23{,}155 \quad (\text{自由度} = 23) \tag{46}$$

χ^2 是什么意思 χ^2

（读作“卡方”）衡量“实际分布与均匀分布差多远”。

- 如果事件在 24 小时里均匀分布，χ^2 应该约等于自由度 23；
- 实测 **23,155** ——大了 1000 倍。

这是压倒性的周期结构。峰谷比 **34.3 倍**。

40.2.2 昼夜调制 Hawkes

把常数基线换成随时间变化的基线：

$$\lambda(t) = \underbrace{\mu_0\, m(\text{hour}(t))}_{\text{昼夜基线}} + \underbrace{R(t)}_{\text{自激}} \tag{47}$$

逐符号解释

μ_0	基线的整体水平（一个常数）
$m(\cdot)$	昼夜调制函数，表示“这个小时相对活跃多少”
$\text{hour}(t)$	t 时刻是一天中的第几小时
m 的约束	在一个周期上归一化：$\frac{1}{24}\int_0^{24} m(h)\,dh = 1$
$R(t)$	自激分量，与式 (29) 的求和项相同

m 的做法：把一天切成 96 格（每 15 分钟一格），统计每格里有多少事件，做完循环平滑后归一化。

40.2.3 结果

指标	常数基线	昼夜基线
中位 AIC	−978.8	−1000.1
AIC 更好的人数	—	**30 / 30**
中位分支比 n	0.936	0.930
中位 KS	0.1099	0.1089
KS 通过率	**36.7 %**	**36.7 %**

结论 昼夜基线让 AIC **全面改善（30/30，平均改善 21.3）** → 周期结构确实存在且重要。但：**分支比几乎没动**（0.936 → 0.930），**KS 通过率完全没变**（36.7% → 36.7%）。

所以“缺昼夜”也不是根因。

41 方法论总结

41.1 四次尝试的完整对照

序号	尝试	KS 通过率	结论
1	单尺度 Hawkes	36 %	重标失败
2	+ 第二个时间尺度	36 %	AIC 略好，重标仍失败
3	+ 昼夜周期	36.7 %	AIC 明显好，重标仍失败
4	**换成会话为单位**	**100 %**	**通过**

一句话总结这四次尝试 **前三步都是在“把模型改复杂”，第四步是“把单位换对”。**

当模型越改越复杂却仍然通不过检验时，问题通常在**建模对象的定义**，而不在模型的容量。

41.2 这一期用到的两个检验工具

工具	作用
对照实验（三路安慰剂）	用“打乱 / 随机”的版本做对照，看结果会不会变
时间重标检验	把拟合好的模型代回数据，看重标间隔是否像 Exp(1)

为什么这两个工具重要 在一个样本量小、结构不可观测的场景里，**“发现的规律”比“没发现规律”更可疑**。这两个工具的价值就是：**在写结论之前，先证明它不是假的。**

41.3 对平台场景的落地建议

序号	建议
1	**先剔除昼夜与周周期**再做动态建模（昼夜让 AIC 改善 30/30，不剔除就会把周期当自激）
2	**不要假设自激**（三次尝试都无法通过时间重标）
3	**改用“会话到达”建模**—把基本单位从“单次互动”换成“一次访问 / 一次曝光组”
4	**保留时间重标检验作为验收标准**—它是唯一能识别“模型设定是否有误”的工具
5	**记住观测模型 ≠ 干预模型**—无论 Hawkes 拟合得多好，“互动引发互动”与“平台推流”在时间序列上仍不可区分，这需要**干预实验**，不是更复杂的模型

42 错误一：AIC 漏计参数（推翻上一版结论）

这是这一期最重要的内容。

42.1 上一期说了什么

上一期我做了这么个实验：给会话层的 Hawkes 加一个“周课表”基线（把一周切成 168 个自由格），然后看分支比怎么变。

结果是：分支比从 0.497 掉到 **0.000**，而且 **“17/17 人的 AIC 都变得更好了”**。

当时的结论是：

“那 0.54 的自激完全来自课表，不是习惯。”

42.2 错在哪里

这一段代码是错的：

我写的	应该是
`aic = -2*loglik + 2*3`	`aic = -2*loglik + 2*(3+168)`

AIC 的公式与含义

$$\mathrm{AIC} = -2 \times (\text{对数似然}) + 2 \times (\text{参数个数}) \tag{48}$$

- 第一项：拟合得好不好（似然越大越好）；
- 第二项：**参数越多，惩罚越大**（防止过拟合）；
- **AIC 越小越好。**

周课表基线用了 168 个自由格，所以它**应该**被罚 168 个参数。我只罚了 3 个——**等于让这个模型免费获得 168 个自由度**。

42.3 修正后结论完全反转

指标	旧口径（错）	正确口径
无周期 AIC	193.2	193.2
自由格 AIC	173.7	**509.7**
“加周期更好”人数	**17 / 17**	**0 / 17**

自由格模型不是“更好”，而是差了 316 个 AIC 单位——属于严重过拟合。

它之所以能把分支比压到 0，是因为它有 **171 个参数去拟合十几个数据点**。**不是发现了结构，是把噪声也拟合进去了。**

42.4 换上参数化模型后的正确答案

用傅里叶基代替 168 个自由格（第 4 节会讲为什么必须改形式）：

模型	分支比	AIC	参数个数
无周期	0.445	185.3	3
日内 K=1	0.377	182.5	5
日内 K=2	**0.292**	**145.8**	**7**
日内 K2 + 周内 K1	0.238	147.4	9
自由格 168	0.000	**509.7**	171

三条修正后的结论：

1. AIC 最优是“日内 K=2”，**只用 7 个参数**；
2. 作息解释了约 1/3 的自激（0.445 → 0.292），**但没解释完**；
3. 自由格的“归零”是过拟合假象。

这一节最值得记的一句话

“17/17 一致”这种完美结果，最该怀疑。

真实的效应很少全票通过。

当所有样本都指向同一方向、而且方向特别干净时，先去看代码，而不是先庆祝。

43 错误二：一个不可识别的自由度（振幅）

刚修完 AIC，又踩了第二个坑。

43.1 症状

做“跨用户共享节律”时（让所有人共享一套作息形状），第一次拟合系数直接炸到 10^{295}，似然变成 $+\infty$。

43.2 原因：正弦积分为零

原来的调制写法是：

$$m(h) = 1 + \sum \left[a\cos(\omega h) + b\sin(\omega h) \right] \tag{49}$$

问题出在 Hawkes 对数似然里的**补偿项**（积分项）：

$$\int_0^T \lambda(t)\,dt \supset \mu_0 \int_0^T m(h(t))\,dt \tag{50}$$

关键事实 **正弦和余弦在一个完整周期上的积分恰好为 0：**

$$\int_0^P \cos\Big(\frac{2\pi k h}{P}\Big) dh = 0, \qquad \int_0^P \sin\Big(\frac{2\pi k h}{P}\Big) dh = 0 \tag{51}$$

所以调制项的积分只跟“周期数”有关：

$$\int_0^T m \approx 168 \times (\text{周期数}) \tag{52}$$

这个积分完全不依赖振幅 a, b 的大小。

后果：把振幅推到无穷大，- 事件落在波峰时收益很大（似然上升）；- 补偿项却完全不变（没有惩罚）。

于是似然可以无限增长——振幅不可识别。

43.3 修法：对数线性形式

$$s(h) = \sum \left[a\cos(\omega h) + b\sin(\omega h) \right] \tag{53}$$

$$m(h) = \frac{\exp(s(h))}{Z}, \qquad Z = \frac{1}{168} \int_0^{168} \exp(s)\,dh \tag{54}$$

为什么这样就好了

1. **正性**：指数函数永远为正，$m(h) > 0$ 自动满足，不用再裁剪；
2. **归一化**：除以 Z 后平均值恒为 1，所以 μ_0 就是“平均强度”，含义清晰；
3. **振幅可识别**：exp 是**非线性**的——振幅越大，波形越**尖**。尖波形在高峰时段收益更大，但在低谷时段代价也更大，两者平衡后有唯一最优。

程序自检（代入任意系数）：

检查项	实测	应该
周期积分 $M(168)$	168.0000	$= 168$
m 的均值	1.0004	≈ 1
m 的最小值	0.586	> 0

43.4 修正的副作用（必须诚实报告）

版本	分支比中位	问题
修正前（自由振幅）	0.29	振幅不可识别，估计偏乐观
修正后（对数线性）	**0.64**	可信

之前的 0.29 有一部分是靠“不受约束的调制”吸收掉的，不是真实的作息解释力。

这一节最值得记的一句话 **模型里每一个不受约束的自由度，最后都会变成虚高的结论。**

加参数之前，先问：**这个参数的最优值是被数据决定的，还是可以随便跑？**

如果它可以随便跑，那它一定会跑到让你高兴的地方去。

44 功效分析：事前的防错工具

上面那张假设表列好了，下一个问题是：**要多少人才测得出来？**

44.1 什么是功效

功效（power）的定义 假设某个效应**真实存在**，你做的实验能把它检测成“显著”的概率，就叫**功效**。

惯例标准：**功效** ≥ 0.80 才算够用。

功效不足的后果是：**真效应被当成没效应**（假阴性）。

44.2 样本量 vs 可检测效应

在显著水平 $\alpha = 0.05$、功效 0.80 下：

学生数 N	可检测到的最小 $\lvert r \rvert$
10	0.785
15	0.669
19（两个班的规模）	**0.605**
30	0.492
47	0.400
92	**0.289**
200	0.197

44.3 反过来：想检测某个效应，需要多少人

目标 $\lvert r \rvert$	所需学生数
0.3（弱）	**85**
0.4（中）	**47**
0.5（中强）	30
0.6（强）	20
0.7（很强）	14

44.4 用 19 人做实验，功效是多少

真实 $\lvert r \rvert$	$N = 19$ 时的功效
0.3	**24.5%**
0.4	**39.1%**
0.5	63.8%
0.6	83.6%
0.7	96.0%

怎么读这张表 如果真实效应是 0.4（中等），用 19 人做实验，**有 61% 的概率测不出显著结果**——即使这个效应真实存在。

所以：**测不出不等于不存在**。

44.5 模拟验证：19 人的精度有多差

假设真实效应 $r = 0.6$，模拟 19 名学生、重复 2000 次：

指标	数值
估计 r 的均值	0.593
估计 r 的 **95% 区间**	**[0.246, 0.835]**
检验出显著的比例（功效）	**81.2%**

注意那个区间：真实效应是 0.6，但估计值可能从 0.25 到 0.84。**这就是 19 人的精度**。

45 用公开数据标定“真实效应有多大”

功效分析告诉我们“多少样本能测多大的效应”。但还有一个问题没回答：**真实世界里的效应，通常有多大？**

如果效应普遍很小，那需要的人数会比上面算的更多。

45.1 为什么不自己估，而是找数据

MBTI 数据项目里没有。但**同一个问题结构**的公开数据有：

需要的东西	**OULAD 有什么**
个体属性	性别、年龄段、教育背景、地区贫困指数、残障、已修学分、历史重考次数
带日期的行为	`date` + `sum_click`，逐日记录
样本量	**26,074 名学生 / 10,655,280 行**

属性虽然不是 MBTI，但“属性 → 行为规律性”这个问题结构完全一样。

45.2 做法

1. 对每个学生，把他的逐日活跃记录转成一组规律性指标（活跃密度、间隔中位、间隔变异、最长中断）；
2. 计算每个属性与每个指标的效应量：
   - 二元属性（性别、残障）→ **Cohen's** d；
   - 有序属性（年龄、教育、贫困）→ **Spearman 秩相关** r；
3. 看这些效应量的分布。

45.3 结果：真实效应非常小

属性	指标	效应量	p 值
性别 F vs M	活跃占比	−0.289	3.2e-118
性别 F vs M	间隔中位	0.221	2.1e-67
性别 F vs M	最长间隔	0.177	3.7e-45
年龄段	活跃占比	0.101	1.2e-60
残障 Y vs N	间隔中位	0.071	2.2e-02
教育背景	间隔中位	−0.067	3.2e-27
贫困指数	活跃占比	0.046	1.2e-13

汇总	数值
中位绝对效应	**0.053**
最大绝对效应	**0.289**
超过 0.3 的条数	**0 / 20**
超过 0.2 的条数	2 / 20

这里有两个值得注意的地方 **第一：效应量普遍很小。**

中位数只有 0.053——按行为科学惯例，$|d| < 0.2$ 算“可忽略”。二十条里只有两条超过 0.2，最强的（性别）也只有 0.289。

第二：p 值全都极度显著。

2.6 万人的样本下，$|r| = 0.05$ 也能得到 $p = 10^{-118}$。

“显著”和“有用”是两回事——大样本下什么都能显著。

45.4 翻译成“要多少样本”

要检测的效应	所需学生数
0.289（本数据里的最大值）	**92 人**
0.2（“小效应”下限）	194 人
0.05（本数据里的中位值）	**2792 人**

用 19 名学生做这个研究：

真实效应	$N = 19$ 的功效
0.289（最乐观假设）	**约 23%**
0.2	约 12%
0.05	约 5%（等于瞎猜）

这意味着什么 **即使 MBTI 的一个维度，对作息的预测力和“性别”一样强**——这是相当乐观的假设——用 19 名学生也只有 23% 的概率测得出来。

换句话说：**如果测不出，你无法区分这两种可能：**

- 效应不存在；
- 效应存在，但样本不够。

45.5 一个反直觉的推论

本数据里最强的预测变量是**性别**（0.289），而这个变量：

- 与“性格”的关系是间接的；

- 与行为的关系更多来自**生活安排**（比如是否有照顾责任）。

一个由数据提示的猜想 **影响学习作息规律性的，可能主要不是“性格”，而是“生活约束”。**

如果这条成立，那么在做学生作息干预时，**了解他的时间约束（几点下课、几点睡、要不要带弟妹）可能比了解他的 MBTI 更有用。**

（这只是一个猜想，需要专门设计研究才能确认。）

46 预注册：把规则写在看到数据之前

功效分析解决了“要多少样本”。但还有一个更隐蔽的问题：**收完数据之后，你总可以“找到”某个显著结果。**

46.1 为什么需要预注册

假设你有 8 条假设、4 个指标、2 个子组。组合起来有几十种可能的检验，随便试总能碰到 $p < 0.05$ 的。

这在本项目里等价于前面踩过的坑

前面几轮	本质
自由格把分支比压到 0	自由度太多 → 拟合噪声
AIC 漏计 168 个参数	假装没有那些自由度
事后挑选显著结果	**自由度太多 → 挑出噪声**

三个是同一件事。

46.2 预注册锁死了什么

本项目为此生成了一份完整的预注册文档，主要内容：

项目	锁定的内容
主假设	**只有一个**：H1（JP 判断端 → 作息集中度，正相关）
次要假设	5 条，Bonferroni 校正到 $\alpha = 0.05/5 = 0.01$
探索性分析	明确列出，**不得作为结论宣称**
指标公式	全部写死，不事后调整
样本量	90 人（依据 OULAD 标定的最大效应 0.289）
判定规则	支持 / 方向相反 / 未检出，三种措辞都事先规定
失效条件	有效样本 < 70 时不报相关性结论
不做的事	不事后换指标、不事后增删样本、不亚组分析后单独宣称
伦理	监护人同意、去标识、数据不出校、**不反馈个体性格分数**

46.3 为什么主假设只有一个

多重比较问题 如果你检验 20 个独立的假设，每个都用 $\alpha = 0.05$，那么**至少有一个假阳性的概率**是：

$$1 - (1 - 0.05)^{20} \approx 64\% \tag{55}$$

也就是说：**就算这些假设全是假的，你也有 64% 的概率“发现”至少一个显著结果。**

所以主假设只留一个，其余全部降级并做校正。

46.4 为什么“未检出”必须配上功效

三种措辞，事先规定

结果	必须怎么说
主假设 $p < 0.05$ 且方向对	“支持”，报告 ρ 与置信区间
主假设 $p < 0.05$ 但方向反	报告反向结果，**不强行解释**
主假设 $p \geq 0.05$	**“未检出显著相关”**，并注明功效不足
任何情况	**不得说“证明了 MBTI”或“推翻了 MBTI”**

46.5 分析脚本的自检（含一次真实的翻车）

预注册配了一份分析脚本。为了确认它真的能工作，我做了一个自检：造一份“JP 越高活动越集中在固定星期几”的合成数据，看脚本能不能恢复。

第一次自检失败：真实效应是正的，脚本却给出 -0.161。

查出来是**我的数据生成器写错了**：把相位信息转成日期时丢了，而且每周只生成 1 天活动（结果全被“活动次数 ≥ 20”的排除标准筛掉了）。

修完再跑：

假设	ρ	p 值	判定
H1（真实存在）	**0.627**	5.0e-10	**支持**
H2（由 H1 推出）	-0.699	5.4e-13	**支持**
H3–H6（合成数据里不存在）	$-0.13 \sim 0.13$	$0.24 \sim 0.58$	**未检出**

管线能找到真效应，且没有假阳性。

这次翻车说明了什么 如果我没做自检，直接拿脚本去跑真实数据，**所有结果都会是错的**，而且看不出错在哪里。

自检的价值和预注册一样：它让你在“还不知道答案”的时候，先确认工具是可用的。

47 方法论主线：从做、验、防到接

47.1 每期在解决什么问题

期	主题	核心工具	典型错误
第一期	怎么建模、怎么评价	AUC / RMSE / LogLoss	参数选错了优化目标
第二期	怎么检验模型	安慰剂 / 时间重标	单位选错了
第三期	**怎么防止自欺**	**约束 / 功效 / 预注册**	**自由度被滥用**

47.2 三期里“翻车”的完整清单

这一期最值得看的其实是这张表——**这些都是真实发生过的：**

序号	错误	怎么发现的	期
1	η 默认值偏大 15 倍	敏感性扫描	第一
2	事件层的“自激”是会话结构	三路安慰剂	第二
3	自由格“归零”是过拟合	AIC 参数个数对照	第三
4	傅里叶振幅不可识别	共享拟合发散	第三
5	自检数据生成器写错	自检本身	第三
6	差点用 19 人下结论	功效分析	第三

这张表的规律 **每一次错误，都是被“另一个角度”发现的：**

- 换成合成数据（能验证估计器）；
- 换成竞争模型（能暴露过拟合）；
- 换一个更受约束的模型（能暴露自由度滥用）；
- 事前算功效（能避免样本不足）。

没有一次是靠“再想一想”发现的。

47.3 第三期的三条方法论

1. **先问“这个自由度能不能被数据决定”，再决定要不要加它。**
   不可识别的自由度一定会被滥用（振幅那个例子）。

2. **“完美一致”是最该怀疑的信号。**
   “17/17 全票通过”后来被证明是算错参数个数。真实效应很少全票通过。

3. **防错的工具有“事前”和“事后”两类，两类都需要。**
   事后：安慰剂、竞争模型、更受约束的模型。
   事前：功效分析、预注册、管线自检。

48 验证层的翻车与边界

48.1 四次翻车

1. **E5 的 Fisher-z 方差检验设定错误**。把相关估计的采样方差当成已知常数，导致功效低于名义水平；改用 ANOVA 后，5 位教师、$sd_\tau = 0.3$ 时功效为 0.903。
2. **E4 的“抱团有害”假设被数据推翻了一半**。小圈子与触达正相关，桥接与点赞正相关；结果取决于因变量，不能一刀切。
3. **“单词测试零区分度”不能推广**。第 5/7 篇单词测试平均难度为 0.233 和 0.257，并非零区分度。
4. **MBTI 不能当天生硬约束**。重测信度弱，荣格八维也没有强心理测量学支持；只能用连续分数和节律峰型。

48.2 必须写清的边界

边界	说明
观察性 vs 因果	E2/E3/E4 都是观察性数据，不能单独证明因果
公开数据推广	EdNet 是韩国数据，课堂推广前需要本地节律基线
19 人功效	19 人只能测中等以上效应，小效应测不出来
犹豫的混淆	犹豫受疲劳、网络、题长影响，必须控制题目难度和题长
外部脚手架伦理	不能伪造信心、不能用假反馈操纵学生
网络指标	共帖网络不是真实社会关系；reads/up 不是学习结果
黄金比	当前没有证据；只能当隐喻，不能当结论

48.3 这一期最值得记住的三句话

1. 犹豫是元认知的行为证据，但必须先验证 **AUC**，不能因为学生慢就默认他不会。
2. 外部只能“引出和训练”元认知，不能硬植入；区分锚定和内部化的关键是迁移。
3. 基线是用户与环境的耦合稳定点，不是 **MBTI** 式 **trait**；改安排通常比强制改习惯更优。

第六部分　元认知、教学干预与教师观察者

49　元认知：把“知道自己会不会”变成可测的指标

第 6 节讲 MBTI（性格），第 9 节讲节律。这一节讲另一个个体差异维度，但它比前两个都更靠近“学习”本身：**元认知**。

49.1　什么是元认知，和“元元”什么关系

三个“元”的关系

概念	含义
认知	学习、记忆、解题
元认知	**对自己认知的认知**——“我知道我不会这个词”
元元	对测量的测量（第 11 节）——“这个推断有多可信”

元认知是“能力”层面的，元元是“测量”层面的。
但两者结构同源：**都是对某一层再加一层**。

49.2　核心文献：元认知必须拆成两个独立的量

本节最重要的文献是：

> **Fleming & Lau (2014)**, *How to measure metacognition*, Frontiers in Human Neuroscience.
> DOI `10.3389/fnhum.2014.00443`，**被引 1388**

它的核心贡献是：**元认知不是一个数，至少是两个。**

量	含义	高值的表现
元认知敏感性	能不能区分自己“会”与“不会”	标记的重点正好是他做错的
元认知偏差	总体偏自信还是偏保守	决定他标得多还是少

为什么必须分开　一个学生可能：

- **偏自信**（很少标记），但**很敏感**（标的那几个确实不会）；
- 或者**偏保守**（标很多），但**没准头**（标的和错的对不上）。

把两者合成一个数，这两种完全不同的学生会被混为一类——**和“作息集中度把每日型和间歇型混在一起”是同一类错误**。

49.3 项目里已经有元认知数据

这是本节最实用的发现。讲义上的两类数据天然构成元认知测量：

讲义上的东西	认知含义	元认知含义
单词/句子前的**根号**	“这是重点”	**“我不会这个”**
56–65 题的**实际对错**	客观表现	一阶结果

两者一列联，就是标准的元认知 2×2 表：

	实际答错	实际答对
标记为重点	命中H	虚报FA
未标记	漏报	正确拒绝

(56)

这个表里的四个格子

- **命中**：标记了，而且确实错了——元认知对了
- **虚报**：标记了，但实际会——**过度谨慎**
- **漏报**：没标记，但实际错了——**过度自信**
- **正确拒绝**：没标记，也确实会——元认知对了

49.4 指标定义（逐符号）

49.4.1 元认知敏感性 AUC

$$\mathrm{AUC} = P\Big(\text{错题被标记}\Big) \text{ vs } P\Big(\text{对题被标记}\Big) \tag{57}$$

形式化写为：

$$\mathrm{AUC} = \frac{\#(\mathrm{pos} > \mathrm{neg}) + 0.5 \cdot \#(\mathrm{pos} = \mathrm{neg})}{n_{\mathrm{pos}} \cdot n_{\mathrm{neg}}} \tag{58}$$

每一个符号

AUC	曲线下面积。0.5 = 标记与对错无关；1.0 = 标记完美对应错题
$\#(\cdot)$	计数符号：满足条件的配对个数
pos	正类样本，即**实际答错**的那些题的标记值
neg	负类样本，即**实际答对**的那些题的标记值
$>$ 与 $=$	逐对比较：每个错题的标记值与每个对题比
$0.5 \cdot \#(\mathrm{pos} = \mathrm{neg})$	平局算一半
$n_{\mathrm{pos}}, n_{\mathrm{neg}}$	正类与负类的样本数

读法：随机取一道错题和一道对题，错题被标记的概率更高的概率，就是 AUC。

49.4.2 元认知偏差

$$\text{bias} = \bar{M} - \bar{E} \tag{59}$$

每一个符号

bias	元认知偏差
$\bar{M}$	标记率 = 被标记的题数 / 总题数
$\bar{E}$	错误率 = 答错的题数 / 总题数

> 0：标记得比实际错的多 $\rightarrow$ **过度谨慎**（宁可多标）

< 0：标记得比实际错的少 $\rightarrow$ **过度自信**（漏标）

49.5 与 L2 元元层的连接

49.5.1 第 14 课的测谎模块做的是同一件事

	第 14 课（测谎模块）	本节
主观信号	自标颜色	标记的重点
客观信号	HRV 生理	实际对错
一致性	自报–生理一致性	元认知校准度
产出	测谎指数 D	敏感性 AUC
后果	自报权重打折	自评权重打折

同一个元元逻辑，用在不同信号对上。

49.5.2 折减公式

$$\mathrm{MC}_{\mathrm{adj}} = \mathrm{MC}_{\mathrm{meta}} \times d(\mathrm{AUC}) \tag{60}$$

$$d(\mathrm{AUC}) = \mathrm{clip}\left(0.3 + 0.7 \cdot \frac{\mathrm{AUC} - 0.5}{0.9 - 0.5},\ 0.3,\ 1.0\right) \tag{61}$$

每一个符号

$\mathrm{MC}_{\mathrm{meta}}$	L2 元元层算出的原始可信度
AUC	该学生的元认知敏感性
$d(\cdot)$	折扣函数，把 AUC 映射到 $[0.3, 1.0]$
$\mathrm{clip}(\cdot, a, b)$	截断函数：把值限制在 $[a, b]$ 内
$\mathrm{MC}_{\mathrm{adj}}$	折减后的可信度

下限 0.3 是刻意的：不把权重降到 0——“标记不准”不等于“自报完全没信息”，只是可信度低。

49.6 公开数据集实验：在 1,936 名学生上验证

49.6.1 先踩了一个陷阱：求助行为不是元认知

ASSISTments 里有一列 `hint_count`（要了几次提示），看起来像元认知。但列联表显示：

	答错	答对
没求助	52,301	180,892
求助过	**40,033**	**9**

求助过的 40,042 条记录里只有 9 条答对（0.022%）。

为什么这个信号不能用 在 ASSISTments 里，提示是做题过程中**随时可点**的。学生点提示，是因为**已经卡住了**——那时结果基本已经注定。

元认知信号必须发生在**结果未知之前**。求助发生在结果“已经知道”之后，**时点不对**。

如果直接拿它做指标，算出的 AUC 会接近 **1.0**（看似完美），但那是**同义反复**——**好看的数字不等于有意义的数字。**

49.6.2 可用的信号：响应时间

`ms_first_response` 是**首次作答之前**的耗时，发生在结果未知之前。在元认知文献里，**响应时间是标准的不确定性指标**：犹豫 = 自己觉得不确定。

$$\text{AUC} = P\big(\text{答错题的响应时间} > \text{答对题的响应时间}\big) \tag{62}$$

数据：273,235 条作答，1,936 名学生（每人 ≥ 20 条）。

49.6.3 结果

统计量	值
元认知敏感性中位数	**0.5845**
均值	0.5675
标准差	0.1381
AUC > 0.5 的学生比例	**73.7%**
AUC > 0.6 的学生比例	44.2%

三条读数 **(1)** **中位 AUC $= 0.585$，显著高于随机**——响应时间确实携带元认知信息：**犹豫的题更容易错。**

(2) 但 26.3% 的学生 AUC ≤ 0.5——这部分学生的“犹豫”不指向错误，响应时间不携带元认知信息。

(3) AUC > 0.6 的只有 44.2%——**不到一半的学生能通过“犹豫”有效预测自己的错误。**

49.6.4 最重要的发现：与学业表现强相关

$$r(\text{元认知敏感性},\ \text{总体准确性}) = +0.513 \tag{63}$$

变量	效应量	来源
性别	0.289	OULAD（26,074 人）
年龄段	0.101	同上
教育背景	0.067	同上
元认知敏感性	**0.513**	**ASSISTments（1,936 人）**

这张表修正了前面第 8 节的推断 第 8 节用 OULAD 标定后发现“人口学属性的效应只有 0.05–0.29”，由此推断“可能不是性格，而是生活约束”。

现在看到元认知敏感性的相关是 **0.513**——比所有人口学属性都强得多。

这修正了那个推断：不是“性格没用”，而是**之前测错了东西**。人口学属性（性别、年龄）本来就是粗粒度标签，预测力自然弱；**元认知是个体内部的心理过程，预测力强得多。**

49.7 三个实验的执行结果（2026-10-07 更新）

这一节把上一版列出的“三个可做的实验”全部推进到**可复核**的状态。每个数字都注明来源：**公开数据**、**真实课堂数据**，还是**合成自检**。三者不能混着说。

实验	当前状态	数据	最重要的结果
A JOL	公开数据已完成；课堂数据等待录入	OSF yaguz：84+80+53+41 人	JOL 与实际相关约 0.46–0.51；难易效应 $p < 10^{-21}$；全局 JOL 不优于“只说班平均”
B 根号	讲义提取与教师判断已完成；学生自标等待录入	21 份讲义 PDF；9 篇 4 标记 vs 6 未标	AUC = 0.5625，置换 $p = 0.795$；5/7 篇单词全部标记，无对照可识别
C 难度基线	已完成（修正 v1 两处错误）	4 套测试、30 个项目、6–7 人/题	Wilson 宽度中位 0.591；10 题能力 SE ≈ 0.699 logit

49.7.1 实验 A：JOL——学生能预测自己考多少吗？

形式定义（不是隐喻）：对第 s 个学生、第 t 次测试，令

$$n_{st} = \text{本次测试总题数}, \qquad y_{st} = \text{实际答对题数}, \qquad \hat{y}_{st} = \text{测试前预测答对题数}. \tag{64}$$

逐符号说明：

- n_{st}：第 s 个学生在第 t 次测试里一共有多少题；本项目中通常是 10。

- y_{st}：批改后实际答对几题；范围是 $0 \le y_{st} \le n_{st}$。
- $\hat{y}_{st}$：测试**开始前**学生自己估计能对几题；范围同样 $0 \le \hat{y}_{st} \le n_{st}$。
- 实际正确率 $p_{st} = y_{st}/n_{st}$，预测正确率 $\hat{p}_{st} = \hat{y}_{st}/n_{st}$。

由此得到三个核心指标：

$$\text{校准偏差} \quad b_{st} = \hat{p}_{st} - p_{st}, \tag{65}$$

$$\text{校准误差} \quad a_{st} = |\hat{p}_{st} - p_{st}|, \tag{66}$$

$$\text{测试级 Brier 分数} \quad B_{st} = \hat{p}_{st}^2(1 - p_{st}) + (1 - \hat{p}_{st})^2 p_{st}. \tag{67}$$

符号含义：

- $b_{st} > 0$：预测得比实际好，**过度自信**；$b_{st} < 0$：预测得比实际差，**过度保守**。
- a_{st}：只看偏差大小，不看方向；0 最准，1 最差。
- B_{st}：Brier 是“概率预测”的标准评分；越小越好。它同时惩罚“方向错”和“过度自信”。
- 基线：把 $\hat{p}_{st}$ 换成全班平均正确率 $\bar{p}$，得到“只说班平均”的基线。若 JOL 的 B 或 a 不优于基线，说明“学生会预测”没有超过“只说一个班平均分”。

公开数据结果：使用 OSF yaguz（Tekin & Roediger 的延迟 JOL 实验）中的 84 名（Exp1）和 80 名（Pilot）做了 JOL 的被试。数据、脚本和复现路径在附录。

数据	人数	JOL–实际相关	总偏差	校准误差	是否优于班平均
Exp1	84	0.460–0.499	+0.052	0.120	否（MAE 与 Brier 都不优）
Pilot	80	0.324–0.475	−0.178	0.203	否（Pilot 明显更差）

难易效应（公开数据）：容易的项目上，学生偏保守；难的项目上，学生偏过度自信。

数据	易项偏差	难项偏差	配对检验
Exp1	−0.084	+0.189	$p = 5.13 \times 10^{-22}$
Pilot	−0.184	−0.173	$p = 0.696$（不显著）

条件实验（公开数据）：Exp2a 中“做 JOL”和“提取练习”都显著高于“重学”，Exp2b 的效应小一些。

条件	Exp2a 正确率	vs 重学 p	Exp2b 正确率	vs 重学 p
重学（Restudy）	0.398	—	0.426	—
只做 JOL	0.496	2.8×10^{-5}	0.452	0.496
隐蔽 JOL	0.524	3.9×10^{-5}	0.506	0.0177
公开 JOL	0.536	2.9×10^{-6}	0.535	0.0034
公开提取	0.572	1.6×10^{-8}	0.522	0.0046

课堂设计功效：用公开数据的效应量（偏差 SD ≈ 0.15）模拟“19 人 $\times$ 10 次 $\times$ 每次 10 题”。

要检测的效应	功效	判断
平均偏差 0.05	0.268	不够
平均偏差 0.10	0.790	勉强（MDES ≈ 0.10）
个体差异相关 $r = 0.5$	0.609	不够
难易效应斜率 -0.55	1.000	足够
校准改善 $\delta = 0.01$/次	0.872	足够
个体差异 SD $= 0.15$	1.000	足够

下一步（实验 A 的课堂部分）：打印 `jol_collection_cards.html`，每名学生一张；测试前先写“估计能对几题”，批改后由老师填“实际对了几题”；录入 `jol_observations.csv`。真实课堂数据一旦录入，重跑 `run_jol_analysis.py` 就会自动生成 `classroom_analysis.json`。**不要让学生自己填实际对题数**，否则会把“预测”和“事后合理化”混在一起。

49.7.2 实验 B：根号——教师的重点判断准不准？学生自己知道吗？

先说结论：21 份讲义 PDF 里的 $\surd$（U+221A）是**印在 PDF 里的**，同一份讲义所有学生看到的都一样，所以它是**教师/教材的重点判断**，不是学生元认知。上一版“必须先确认根号性质”的问题，现在可以回答：**就这批 PDF 而言，是老师印的。**

讲义提取结果（真实文件，不是模拟）：

讲义	$\surd$ 总行数	$\surd$ 单词	$\surd$ 句子

五讲	17	14	3
七讲	28	23	4
八讲	38	34	4
九讲	30	25	5
十讲	52	48	4
其余各讲	0	0	0

教师判断效度（9 篇 56–65 题，真实课堂数据）：把 10 个空映射到它们所在的句子，4 个句子有 $\surd$（59、62、63、64），6 个没有（56、57、58、60、61、65）。

$$\mathrm{AUC}_{\mathrm{teacher}} = \Pr(\text{标记句错误率} > \text{未标句错误率}) + \tfrac{1}{2}\Pr(\text{相等}). \tag{68}$$

结果：标记句平均错误率 0.625，未标句 0.583，差 +0.042；AUC = 0.5625，置换检验 $p = 0.795$，学生层面 bootstrap 95% CI = $[0.333, 0.812]$。**没有证据表明“教师标为重点的句子”更难**。但这只有 4 个标记句和 6 个未标句，项目数太少，只能算方向性线索。

第 5、7 篇单词测试：设计性退化。检查后发现，这两套单词测试的全部考题（10/10 和 5/5）都在教师 $\surd$ 标记内，没有“未标记但同样考了”的对照项。**因此这两套数据无法识别教师判断效度**——不是老师判断得准或不准，而是设计上没有对照。**这是一个重要的产品/教研教训**：要检验“重点判断是否有效”，测试必须同时包含**标记项**和**未标记的对照项**（foil）。

学生自标元认知管线（等待真实数据）：要测“学生知不知道自己哪里不会”，必须让学生自己打 $\surd$。脚本已经建好：`root_mark_observations_template.csv` 是长表，根号自标采集卡`.html` 是打印卡。分析指标与上一节元认知一致：敏感性 AUC、偏差 $bias$、d'、L2 折扣。

合成自检（不是学生数据）：在已知真实 AUC 的情况下，每人每次 10 题的估计 AUC 非常不稳定：

真实 AUC	个体 AUC 均值	个体 AUC SD	聚合 AUC
0.50	0.522	0.171	0.516
0.65	0.620	0.182	0.614
0.75	0.693	0.141	0.695
0.85	0.767	0.148	0.759

零模型（真实 AUC = 0.5）下，10 题个体 AUC 的 95% 范围是 0.143–0.798。**所以：单次 10 题的 AUC 只能当线索；要看个体差异，至少聚合 5 次测试。**

49.7.3 实验 C：难度基线 v2——先修掉两个错误

v1 有两个问题：

1. **题号类型错误**：9 篇和 7 篇句型的题号是整数，脚本却用字符串去匹配，导致这两套题的难度 p_i 被全部误算成 0。
2. **循环依赖**：学生残差用了“包含该学生自己”的题目难度，自己会影响自己的基线。v2 改为 leave-one-out（留一法）难度。

v2 的题目难度定义不变：

$$p_i = \frac{k_i}{N}, \qquad k_i = \text{第} i \text{ 题做错的人数}, \qquad N = \text{参加该测试的总人数}. \tag{69}$$

Wilson 95% 区间用于小样本；它比常见的正态近似更稳。v2 结果：

测试	人数	项目数	平均难度	Wilson 宽度中位
第 9 篇 56–65 题	6	10	0.600	0.603
第 7 篇句型 1–5	6	5	0.500	0.603
第 7 篇单词	7	10	0.257	0.523
第 5 篇单词	6	5	0.233	0.533

两种精度必须分开说：

- **题目难度精度**取决于“每道题有多少学生”N。现有 $N = 6$–7，Wilson 宽度中位 0.591。要把最坏宽度压到 0.30，需要每道题约 39 人；0.25 约 58 人；0.20 约 93 人。
- **学生能力精度**取决于“每个学生有多少题”k。在 Rasch 模型下，$\mathrm{SE}(\hat{\theta}) \approx 1/\sqrt{\sum_i p_i(\theta)(1-p_i(\theta))}$。现有 $k = 10$ 时，解析 SE ≈ 0.699 logit；要到 ≈ 0.308，需要约 50 题。**学生人数再多也不能替代题数**。

学生残差（v2，真实课堂数据）：用留一法难度算 $Z_s = (X_s - E_s)/\sqrt{V_s}$，其中 X_s 是实际错数，E_s 是 LOO 预期错数，V_s 是 LOO 预期方差；再用 Monte Carlo 零模型给 p 值。正残差 = 比题目难度预期的更差；负残差 = 更好。合成的零模型自检显示：Wilson 覆盖率 0.970（目标 0.95），但残差检验假阳性率 0.088（目标 0.05）——**偏高**。所以下面的 $p < 0.05$ 只能当**筛选线索**，不能当确证：

学生	测试	残差	Monte Carlo p	方向
陆怡婷	第 9 篇 56–65	+2.45	0.0165	比预期差
张钊源	第 9 篇 56–65	−5.55	< 0.001	比预期好

刘泽宇	第 7 篇句型	+3.20	0.0040	比预期差
孙艺轩	第 7 篇句型	+3.20	0.0039	比预期差
孙艺轩	第 7 篇单词	+3.62	0.0008	比预期差
李陈浩然	第 5 篇单词	+4.91	< 0.001	比预期差

一个必须修正的说法：上一版“单词测试零区分度”来自某一批数据；本次新增的第 5/7 篇单词测试**不是零区分度**（平均难度 0.233 和 0.257）。因此“单词测试零区分度”不能推广到所有单词测试，只能限定在原来那批数据上。

49.7.4 三个实验怎么接回 Tender 和 DaoQL

三个实验不是三份孤立报告，它们分别提供一种**状态测量**，再写进 Tender 的会话和 DaoQL 的事件流：

实验	测量	Tender 节点	DaoQL 事件
A JOL	预测 vs 实际 → 偏差、误差、Brier	monitoring（自我监控）	`metacognition_jol`
B 根号	标记 vs 对错 → AUC、bias、d'、L2 折扣	monitoring + L2 元元	`metacognition_root`
C 难度	逐题错误 → p_i、Wilson、学生残差	content/item + student state	`item_difficulty` + `student_residual`

它们都不是情绪测量。JOL 和根号回答的是“知不知道自己会不会”，难度基线回答的是“这道题对这群人有多难”；情绪测量是另一条线，不要把“元认知差”误读成“情绪差”，也不要用情绪模型替代元认知模型。

49.8 一个意外发现：单词测试零区分度

重要限定 本节“单词测试零区分度”来自上一版的某一批单词数据。本次新增的第 5/7 篇单词测试**并不是零区分度**（平均难度分别为 0.233 和 0.257），所以这个发现只适用于原来那批数据，**不能推广到所有单词测试**。

在第 9 篇三项测试都参加的 6 名理科生上：

学生	填空错误率	单词错误率	句型错误率
陆怡婷	0.90	0.17	1.00
孙欣	0.80	**0.00**	0.80
王毅玮	0.50	**0.00**	1.00
柴静轩	0.70	**0.00**	0.60
张钊源	**0.00**	**0.00**	**1.00**
王昱琳	0.70	**0.00**	0.20

两个发现 **(1)** **单词测试几乎全体满分**——它目前在**提供零信息**，既不能区分学生，也不能反映进步。这是**在浪费课堂时间**。

(2) 张钊源：填空全对、单词全对、句型全错——这不是“英语差”，是**明确的单点短板**。而这类学生恰恰是元认知测量最有价值的对象：**他自己知道句型弱吗？**

49.9 边界与不做的事

不做	原因
不用“求助行为”当元认知信号	它是结果之后的反应，不携带额外信息
不用自评问卷测元认知	Double (2025)：问卷测元认知常常是假的
不把相关当因果	$r = 0.513$ 不等于“训练元认知就能提分”
不给学生贴“元认知差”标签	元认知可训练（Huff & Nietfeld 2009），标签会造成自证预言
不在低敏感性时强推自评	敏感性低的学生，其自评应被降权而非直接采信

50 元元检测：给结论本身打可信度分

前面所有章节都在回答“值是多少”。这一节换一个问题：**“这个值有多可信?”**

这个问题在本项目里不是新问题——L2 层早就有一个专门的模块做这件事，叫**元元检测**。本节做的，是把同一套方法用到“研究结论”上。

50.1 什么是“元元”

先把三个词分清楚：

词	做什么	例子
测量	观察一个对象，得到一个值	“你今天 $\theta = 1.2$”
元测量	测量“这次测量有多可信”	“这个 θ 的可信度是 0.72”
元元	对“测量的测量”再做一层	见下面的层次图

项目里的三层结构

层	名字	做什么
L1	状态推断	从颜色、文本、序列合成 θ
L2	**元元检测**	**判断“这个 θ 推得准不准”**
L3	策略与干预	根据 θ 和可信度，决定要不要干预

关键在 L2：它不产生新的状态值，它产生**一个关于可信度的评分**。只有在可信度够高时，L3 才允许做出干预。

50.2 L2 的元元公式（原文，逐符号解释）

50.2.1 综合可信度

$$\mathrm{MetaConfidence} = 1 - \sum_{k=1}^{4} \beta_k \cdot \mathrm{alert}_k \tag{70}$$

每一个符号

MetaConfidence	综合可信度。取值 $[0,1]$，**越大越可信**
k	检测器的编号，从 1 到 4
$\sum_{k=1}^{4}$	求和符号：把 $k=1,2,3,4$ 四项加起来
β_k	第 k 个检测器的**权重**。所有 β_k 之和为 1
alert_k	第 k 个检测器是否报警。取值只有 0（没报）或 1（报了）
$1-(\cdots)$	可信度 $=1$ 减去“所有报警的加权和”

读法：一个警报都没响时，MetaConfidence $=1$（完全可信）；警报越多、权重越大，可信度越低。

50.2.2 四个检测器与黄金比阈值谱系

$$\varphi^{-3}\approx 0.236,\quad \varphi^{-2}\approx 0.382,\quad \varphi^{-1}\approx 0.618,\quad \varphi^{1}\approx 1.618 \tag{71}$$

检测器	阈值	检查什么
数据充分性	$\varphi^{-1}\approx 0.618$	数据量够不够
群体一致性	$\varphi^{-3}\approx 0.236$	群体里大家一致吗
个人历史表现	$\varphi^{-2}\approx 0.382$	这个人的历史是否自洽
状态偏离度	$\varphi^{1}\approx 1.618$	当前状态是否偏离太远

为什么阈值要用黄金比的幂 黄金比 φ 满足 $\varphi^2=\varphi+1$，且 $\varphi^{-1}=\varphi-1$。用它做阈值谱系有两个好处：

1. **尺度自相似：**每一档都是上一档的 φ 倍，所以“松/紧”的划分在任何尺度上看起来都一样；
2. **全系统统一：**L1 的临界角、L2 的阈值都出自同一个 φ，系统里没有第二套常数。

50.2.3 弱测量算符

$$M_{\text{meta}} = I - \eta\cdot\big(1-\text{MetaConfidence}\big)\cdot P_{\text{模糊}} \tag{72}$$

每一个符号

M_{meta}	弱测量算符。作用在状态上产生一个**很轻的修正**
I	单位算符。“什么都不做”——作用在状态上原样返回
η	弱测量强度系数。L2 里取 $\eta = 0.01$，**非常小**
$1 - \text{MetaConfidence}$	**不可信程度**。可信度越低，这个数越大
$P_{\text{模糊}}$	投影到“模糊态”的算符。把状态往“不确定”方向拉一点
$\cdot$	乘法（标量乘算符）

读法：

- 可信度 $= 1$ 时：$1 - \text{MetaConfidence} = 0$，于是 $M_{\text{meta}} = I$，**什么也不做**；
- 可信度低时：往“模糊态”收缩一点点。

为什么叫“弱”测量：η 只有 0.01，修正极小。它的目的是**标记不确定性**，而不是**改变状态**。

50.3 观测者效应：它本身就是元元问题

第 6 节讲 MBTI 时提到三条设计（不告知假设、不反馈分数、不反馈偏离度）。当时是以“伦理要求”给出的。这里补上它的**方法论根据**。

观测者效应的本质

普通测量	观测者效应
观察者 → 被观察者 → 得到一个值	观察者 → 被观察者 → **被观察者知道自己被观察** → 被观察者改变 → **值已经不是原来的值**

一句话：**测量过程回流进了被测量的系统。**

所以它和元元是同一件事 元元层要检测的，正是“测量是否被自身污染”。所以观测者效应不是元元的“邻居”，**它就是元元的对象本身：**

元元层里的概念	在 MBTI 研究里的化身
弱测量（尽量不扰动系统）	**不告知假设、不反馈结果**
MetaConfidence	对“研究结论有多可信”的评分
阈值谱系	分级线：可作结论 / 只能作线索 / 不可作结论
元元检测器	**阴性对照 H7**
护栏	事后改动、系统性偏差

50.4 把元元用到研究结论上

为什么研究结论也需要 MetaConfidence 一份研究报告会说“$\rho = 0.42$，$p = 0.01$”。但它不会说“这个数是在 19 个人身上得到的，而且学生知道我们在验证什么”。

前者是测量值，后者是可信度。两个都要报。

50.4.1 公式

$$\mathrm{MC}_{\text{study}} = \sum_{k=1}^{5} w_k \cdot s_k \tag{73}$$

每一个符号

$\mathrm{MC}_{\text{study}}$	研究结论的元元可信度，取值 $[0, 1]$
k	维度编号，1 到 5
w_k	第 k 个维度的**权重**，且 $\sum_{k=1}^{5} w_k = 1$
s_k	第 k 个维度的**得分**，取值 $[0, 1]$，越大越好

注意 s_k 和 L2 的 alert_k **含义正好相反**：s_k 是“做得多好”，alert_k 是“有没有报警”。两者的关系是 $s_k = 1 - \mathrm{alert}_k$。

维度	权重 w_k	评什么
观测者效应风险	0.25	学生是否知情 / 是否反馈结果 / 记录是否可见
功效	0.25	样本量 N 够不够
阴性对照	0.20	本该没效应的检验是否干净
数据质量	0.15	覆盖天数、活动次数
预注册依从	0.15	有没有事后改动

50.4.2 与 L2 公式是同一个式子

一个值得注意的等价关系 把 $s_k = 1 - \mathrm{alert}_k$ 代入式 (73)：

$$\sum_k w_k s_k = \sum_k w_k(1 - \mathrm{alert}_k) = \underbrace{\sum_k w_k}_{=1} - \sum_k w_k \mathrm{alert}_k = 1 - \sum_k w_k \mathrm{alert}_k \tag{74}$$

最后这个式子**就是 L2 的式** (70)（把 β_k 换成 w_k）。

所以本节的评分卡不是新公式，而是 L2 元元公式在“研究结论”这个对象上的应用。

唯一的区别：连续性

	L2	**本研究**
报警量	$\text{alert}_k \in \{0,1\}$（二值）	$s_k \in [0,1]$（连续）
理由	状态推断只有“够/不够”	设计质量可以“部分达标”

当所有 s_k 只取 0 或 1 时，本研究的形式**退化成 L2 的原始形式**。

MC_{study}	**分级**	**可以说的话**
≥ 0.80	可作结论	可以作为研究结论对外表述
$0.50 \sim 0.80$	只能作线索	只能作为“值得进一步看”的线索
< 0.50	不可作结论	结论无效，需重新设计或重新采集

50.5 护栏：为什么加权平均会失效

一个真实的失败 第一版评分卡跑出来，“看完数据后改了指标”这个场景 **居然得到 0.800 ——被判为“可作结论”**。

原因：其他四项都满分，加权平均把**单项致命缺陷稀释掉了**：

$$0.25(0.80) + 0.25(1.0) + 0.20(1.0) + 0.15(1.0) + 0.15(0) = 0.800 \tag{75}$$

这是评分卡自身的缺陷——也就是“元元自己也需要元元”。

50.5.1 修正：一票否决

$$\text{MC}_{\text{final}} = \min\Big(\text{MC}_{\text{study}},\ V_{\text{veto}}\Big) \tag{76}$$

每一个符号

MC_{final}	最终可信度
$\min(\cdot,\cdot)$	取较小值。这是关键的**封顶算子**
MC_{study}	式 (73) 算出的加权分
V_{veto}	封顶值。触发致命缺陷时取一个小值

触发条件	**封顶 V_{veto}**	**理由**
看过数据后改过假设或指标	**0.30**	事后挑选，结论作废
阴性对照显著（$p < 0.01$）	**0.45**	存在系统性偏差

为什么用 min 而不用减法 如果用减法（MC − c），只要其他项足够高，仍然可能回到“可作结论”区间——**缺陷仍然可补偿**。

而 min 表达的是**“不可补偿”**：无论其他维度多完美，只要触发红线，结论就封顶。

这和项目《指标验证与商业路线图》里的**“护栏（一票否决）”**是同一个设计原则。

50.6 六个场景的实测对比

场景	观测	功效	对照	质量	预注册	MC	分级
理想执行（$N = 90$）	0.80	1.00	1.00	1.00	1.00	**0.950**	可作结论
现实规模（$N = 19$）	0.80	0.15	1.00	1.00	1.00	**0.738**	只能作线索
告知了假设	0.35	0.15	1.00	1.00	1.00	0.625	只能作线索
反馈了分数	0.00	0.15	1.00	1.00	1.00	0.537	只能作线索
阴性对照失败	0.80	1.00	**0.00**	1.00	1.00	**0.450**	**不可作结论**
看完数据改指标	0.80	1.00	1.00	1.00	**0.00**	**0.300**	**不可作结论**

三条读数

1. **理想执行与现实规模差 0.212，全部来自“功效”。**
   其余四项完美，样本不够仍然只能得到“线索”级结论。
2. **观测者效应是最容易失守的一环。**
   “告知假设”一项就掉 0.113；再加“反馈分数”掉到 **0.537**——已逼近 0.50 门槛。**只要既告知假设又反馈结果，这项研究基本就废了。**
3. **两个致命缺陷都被护栏拦住**——包括那个用加权平均差点漏掉的“事后改指标”。

50.7 边界：可信度不等于效应量

两者必须分开报 **元元评分只评估“研究做得对不对”，不评估“效应大不大”。**

- MC = 0.95 的结论，可能效应只有 0.05，**没有实用价值**；
- MC = 0.55 的结论，可能效应很大，**只是样本不够**。

所以报告必须同时给出：

分量	示例
效应量	$\rho = 0.42$，95% CI $[0.22, 0.58]$
元元可信度	MC = 0.74（只能作线索：样本仅 19 人）

只报前者会误导（好像很确定）；**只报后者也误导**（好像很小）。

50.8 小结：这一节连接了两件事

连接	说明
观测者效应 ↔ 元元	观测者效应的本质是“测量回流进系统”，这正是元元要检测的对象
L2 元元公式 ↔ 本研究评分卡	$s_k = 1 - \text{alert}_k$ 时两者**完全等价**，本研究是其连续推广
弱测量 ↔ 研究设计	不告知假设、不反馈结果 = 对研究对象的“弱测量”
护栏 ↔ 一票否决	两者都用**不可补偿的红线**，而不是加权扣分

50.9 DAOQL 客观事件与生命树主观体验

这一版新增一个关键分层：**DAOQL 记录客观世界，生命树记录主观体验。**

层	回答什么	保存什么
DAOQL 客观层	谁在什么时间做了什么，来源和证据是什么？	原始事件、时间、来源、证据、版本与审计
metameta 主观体验层	这个事件在生命树中可能意味着什么？	体验节点、脑图区域、记忆类型、置信度与不确定性

新增 Agent `metameta_cartographer` 读取客观事件，生成两类派生记录：

- `subjective_experience_node`：把一次事件拆解到工作记忆、海马体索引、长期记忆、内省反馈、情绪、代谢治理等区域；
- `subjective_experience_summary`：保存主区域、最多 6 个标签、生命树阶段和体验节点 ID。

关系边明确写成：

客观事件 `--experienced_as-->` 主观体验节点
客观事件 `--yields_subjective_experience-->` 体验摘要
体验摘要 `--contains_experience_node-->` 体验节点
体验节点 `--索引/编码/内省/表达等关系-->` 体验节点

每个体验节点都带 `epistemic_status = subjective_experience`、`derived = true`、客观来源事件 ID、匹配证据词、置信度、不确定性和生命树阶段。客观事件保持原样；体验节点可以更正、重算和撤回。

接口为：

```
POST /metameta/decompose/{student_id}
GET  /metameta/map/{student_id}
```

边界 这些区域是认知隐喻与检索标签，不是脑区扫描、临床诊断或客观事实。生命树回答“如何被体验”，DAOQL 回答“发生了什么”。两者通过来源边相连，不能互相冒充。

51 犹豫：元认知的行为证据

51.1 犹豫本身不是元认知

犹豫是一个行为量。它可以是：

- 响应时间变长；
- 停顿、回看、修改；
- 鼠标或键盘反复操作；
- 语言标记：“嗯”“可能”“应该是”“我不确定”。

但行为量不等于元认知。犹豫只有在满足两个条件时，才算**元认知信号**：

1. **发生在结果之前**：如果学生已经看到答案才犹豫，那是事后反应，不是事前监控；
2. **能预测错误，且超出题目难度本身**：如果只是题长、题难导致慢，那不是元认知。

51.2 形式定义：犹豫的元认知敏感性

把“犹豫程度”记作 h，实际对错记作 $e \in \{0,1\}$，其中 $e=1$ 表示答错。定义：

$$\mathrm{AUC}_{\mathrm{hesitation}} = \Pr(h_{\text{错题}} > h_{\text{对题}}) + \frac{1}{2}\Pr(h_{\text{错题}} = h_{\text{对题}}). \tag{77}$$

逐符号说明：

- $h_{\text{错题}}$：答错题上的犹豫程度；
- $h_{\text{对题}}$：答对题上的犹豫程度；
- $\Pr(\cdot)$：概率；
- $\mathrm{AUC}=0.5$：犹豫与对错无关，不是元认知信号；
- $\mathrm{AUC}>0.5$：犹豫确实携带“我不确定”的信息；
- $\mathrm{AUC}=1.0$：犹豫完美区分错题与对题。

51.3 真实数据：ASSISTments 的响应时间

第三期已经在 ASSISTments 上做过这个实验：

信号	真实结果
响应时间（首次作答前）	元认知敏感性中位 $\mathrm{AUC}\approx 0.585$；犹豫确实携带信息

求助行为 hint_count	求助过的 40,042 条里只有 9 条答对；它是“卡住后的反应”，不是事前判断

关键区分 **事前犹豫**（响应时间、首次作答前停顿）可以是元认知信号。

事后求助（hint、看答案、问老师）大多是结果之后的控制行为，不能当元认知判断。

51.4 怎么引导应用：犹豫 × 对错四象限

这是第四期最实用的一张表。把每个学生每道题放进四象限：

	实际答对	实际答错
高犹豫	**知识脆弱**：会，但不稳。安排变式练习、间隔复习、用自己的话复述。	**知识缺口**：不会。先问“卡在哪一步”，再给最小提示、示范、拆步。
低犹豫	**流畅掌握**：可以提速、进阶、做迁移题。	**错误流畅**：很确定地错。用反例、对比题、同伴互评制造认知冲突。

51.5 四种干预的详细脚本

51.5.1 高犹豫 + 答错：知识缺口

不要直接给答案。按四步：

1. 让学生指出卡点：“你是哪一步开始不确定的?”
2. 给最小提示，不展开完整讲解；
3. 让学生自己补完这一步；
4. 换一道同结构题，验证是否真的补上。

对应 T-ACR 的“注入 $\rightarrow$ 扰动 θ”。

51.5.2 高犹豫 + 答对：知识脆弱

学生会，但靠的是临时回忆，不是稳定结构。安排：

- 间隔 1 天、3 天、7 天各做一次变式；
- 要求学生解释“为什么选这个形式”；
- 不要马上加难度，先把稳定性做出来。

对应“驻波耦合 $\rightarrow$ 裸传压缩”。

51.5.3 低犹豫 + 答错：错误流畅

这是最危险的一类。学生“很确定地错”，重复讲一遍往往没用。应该：

- 给反例，让学生自己发现矛盾；
- 让同伴互评，先让学生听到不同答案；
- 用“预测—实际”冲突：先写预测，再看实际结果。

对应“强制再观测”。

51.5.4 低犹豫 + 答对：流畅掌握

可以：

- 换情境、换题型；
- 让学生当小老师；
- 进入下一层布鲁姆层级（分析、评价、创造）。

对应“结果”——让 θ 基线台阶式上移。

51.6 电子化采集要记什么

字段	含义	注意
首次作答时间	从题目呈现到第一次输入	要排除网络延迟和题长
修改次数	答案被改了几次	反复改是犹豫的强信号
回看次数	回看题干或材料的次数	需要平台支持
信心条	学生自报 0–100	与响应时间互补
语言标记	可能/应该/不确定/嗯	中文可用 hedging 词表
题目难度	该题错误率 p_i	必须控制，否则会把题难误判成犹豫

边界 犹豫也受疲劳、网络、题目长度影响。
至少要控制：题目难度、题长、题序、学生基线反应时。
不能因为学生慢，就默认他不会。

52 外部脚手架：元认知能不能“植入”？

52.1 先分清三件事

“外部植入”这个词太粗。要拆成三层：

层次	做法	改变的是什么
引出 elicit	问“你估计能对几题”“你有多确定”	把内部信号变成可观测数据
增强 augment	给校准反馈、复盘、对照	可能真正改善监控敏感性
锚定 anchor	暗示“你应该有 80% 信心”	大多只改变报告，不一定改变内部监控

52.2 形式定义：报告信号与内部信号

把内部监控记作 m_{internal}，报告出来的信号记作 m_{report}，外部输入记作 E：

$$m_{\text{report}} = g(m_{\text{internal}}, E). \tag{78}$$

符号说明：

- m_{internal}：学生真实的“我有多确定”；
- m_{report}：学生写出来的信心、JOL、标记；
- E：外部提示、反馈、同伴信息、教师暗示；
- g：从内部到报告的映射。

判断标准：

- 如果 E 只改变 m_{report}，拿掉 E 就恢复原样 $\rightarrow$ 这是**锚定**；
- 如果 E 改变了 m_{internal}，在**新任务、无提示**下仍然改善 $\rightarrow$ 这是**内部化**。

核心结论 不能“植入”第一人称的元认知体验；
但可以外部**脚手架化**：引出、反馈、训练、迁移。

52.3 三臂实验：无提示 vs JOL vs JOL + 反馈

这是可以直接在语法填空课堂做的实验。

组别	每次测试做什么	要检验什么
A 对照	正常测试，不提示	基线校准水平
B JOL	测前写“估计能对几题”	光有提示能不能改善
C JOL + 反馈	测前 JOL，批改后给“预测 vs 实际”反馈	反馈能不能改善敏感性，而不只是偏差

结果看三件事：

1. **偏差** $b = \hat{p} - p$：C 组是否降低过度自信？
2. **敏感性 AUC**：C 组是否提高对“会/不会”的区分？
3. **迁移**：撤掉反馈后，下一轮是否仍然更准？

判读规则 只有偏差改善、AUC 不变、撤掉反馈就恢复 → 那是锚定，不是元认知训练。
AUC 上升且迁移到新任务 → 才能说外部脚手架促进了内部监控。

52.4 伦理边界

- 不要伪造信心；
- 不要用假反馈操纵学生；
- 不要把“外部提示”包装成“学生自己的判断”；
- 外部植入只能做“引出 + 反馈 + 训练”，不能做欺骗性锚定。

52.5 功效提醒

第三期已经算过：19 名学生 × 5 次测试，相关 $r = 0.5$ 时功效约 0.61，$r = 0.6$ 时约 0.82。所以三臂实验更适合看**组间方向**和**个体内变化**，不要指望一次就测出小效应。

53 教师观察者与 metameta

53.1 元认知的三层结构

1. **一阶：学生自我监控**——学生自己预测、自己标重点（JOL、根号自标）；
2. **二阶：教师作为观察者**——教师判断“这个学生哪里不会、现在是什么状态”；
3. **三阶：metameta**——教师对自己判断的校准：教师不仅要有判断，还要知道自己判断得准不准。

53.2 教师观察的形式定义

对教师 O 的判断质量：

$$\mathrm{AUC}_O = \Pr(\text{教师标记的错题} > \text{教师标记的对题}) + \frac{1}{2}\Pr(\text{相等}). \tag{79}$$

$$\mathrm{MC}_O^{\mathrm{adj}} = \mathrm{MC}_O \times \mathrm{discount}(\mathrm{AUC}_O). \tag{80}$$

符号说明：

- $\mathrm{AUC}_O = 0.5$：教师标记与对错无关，观察没有信息；
- $\mathrm{AUC}_O = 1.0$：教师标记完美对应错题；
- MC_O：教师自报的观察置信度；
- $\mathrm{discount}(\cdot)$：把教师观察折进学生状态时使用的可信度折扣；
- $\mathrm{MC}_O^{\mathrm{adj}}$：折后置信度，才是 Tender 真正应该采信的教师观察权重。

53.3 实验 B 的真实先验

第三期实验 B 的教师题目级判断：

$$\mathrm{AUC}_{\mathrm{teacher}} = 0.5625, \quad p = 0.795, \quad 95\%\ \mathrm{CI} = [0.333, 0.812]. \tag{81}$$

按当前 confidence_discount 映射：

$$\mathrm{discount}(0.5625) = 0.30 + 0.70 \times \frac{0.5625 - 0.5}{0.9 - 0.5} \approx 0.409. \tag{82}$$

解释 教师重点判断目前只能被当作**弱证据**，不能当作 ground truth。
这不是说教师不重要，而是说教师观察者本身必须被 metameta 校准。

53.4 E1：教师–学生–观察者三方对照

53.4.1 设计

每次测试采集：

1. 学生预测：我估计能对几题（0–10）；
2. 教师预测：我估计该生能对几题（0–10）；
3. 教师信心：0–100；
4. 实际对题数。

53.4.2 指标

- 学生偏差 $b_s = \hat{p}_s - p$；
- 教师偏差 $b_t = \hat{p}_t - p$；
- 学生校准误差 $a_s = |b_s|$；
- 教师校准误差 $a_t = |b_t|$；
- 教师 metameta $= \mathrm{corr}(\text{教师信心}, -a_t)$。

53.4.3 合成功效（19 名学生 × 5 次测试）

教师 MAE 优势	功效
0.00	0.047
0.02	0.121
0.04	0.377
0.06	0.682
0.08	0.891
0.10	0.978

相关功效：

真实相关 r	功效
0.2	0.131
0.3	0.249
0.4	0.406

0.5	0.612
0.6	0.816
0.7	0.948

53.5 E5：多教师 metameta

现有项目只有一位教师，无法估计教师间差异。第四期做了合成功效。

53.5.1 一次真实的翻车

最初的 Fisher-z 方差检验把相关估计的采样方差当成已知常数，导致功效低于名义水平。后来改用 **ANOVA 检验教师间校准误差差异**，这才是正确做法。

53.5.2 修正后的功效

教师间真实差异 sd_τ	5 位	10 位	20 位	50 位
0.3	0.903	0.987	1.000	1.000
0.5	0.970	0.990	1.000	1.000
0.8	0.983	1.000	1.000	1.000

设计结论 只要每位教师有 19 名学生 × 5 次测试（95 个观测），**5 位教师就足以检出中等以上的教师间差异**。门槛不是“几百位教师”，而是“至少 5 位、每位足够多观测”。

53.6 怎么用教师 metameta

1. 教师观察不要直接当 ground truth，先乘 discount(AUC_O)；
2. 教师信心不是教师能力，它本身也要被校准；
3. 教师在场会产生观测者效应，所以还要记录“教师在什么观察方式下更准”；
4. 多教师实验至少 5 位，最好 10–20 位。

第七部分　群体、平台与供应链

54　实验一：平台逆向实验

54.1　要解决什么问题

内容创作者想知道：**同一条内容，发到不同平台，效果会不会不一样？怎么改能更好？**

这个问题不能靠“平台内部算法”回答（那是拿不到的），但可以靠**公开能看到的数据**建立一个近似模型。

本实验的界限　**做什么**：用公开可观测的互动数据，建立一个可校准的排序先验。

不做什么：不读取平台私有算法、不刷量、不控制账号、不绕过风控。

所有平台权重都标记为 `prior_only`，即“未经真实数据校准的猜测值”。

54.2　内容方案：把一条视频变成一组数字

系统把一条内容抽象成一组 0 到 1 之间的分数：

字段	含义
`hook_strength`	开头吸引力（前两秒能不能抓住人）
`cognitive_load`	认知负荷（理解起来累不累）
`novelty`	新颖度（跟别人像不像）
`authority`	权威感（说话的人可信不可信）
`social_proof`	社会证明（有没有案例、别人怎么说）
`search_intent`	搜索意图（标题有没有覆盖真实搜索词）
`emotional_intensity`	情绪强度
`completion_prob`	完播概率
`interaction_prob`	互动概率
`share_prob`	转发概率
`follow_prob`	关注概率
`content_quality`	内容质量
`compliance_risk`	合规风险（越高越差）
`negative_feedback`	负反馈风险

54.3　排序评分公式

$$\text{得分} = \sigma\Big(\big(\text{调整后正分} - 0.42\big) \times 8\Big) \tag{83}$$

其中“调整后正分”为：

$$\text{调整后正分} = \text{原始正分} \times \Big(0.75 + 0.25 \times \text{群体修正}\Big) \times e^{-\text{惩罚项}} \tag{84}$$

逐符号解释

$\sigma(\cdot)$	sigmoid 函数（见 2.4 节），把任意实数压到 $(0, 1)$。
0.42	中心偏移量。让“没有优势的内容”得分低于 0.5。
8	陡峭度。值越大，得分曲线越陡（区分度越高）。
原始正分	各正向信号乘以各自权重后的总和。
群体修正	由观众群体的对齐度、多样性等算出的修正系数。
$e^{-\text{惩罚项}}$	指数衰减。惩罚项越大，整体得分被压得越低。

通俗理解：这个公式做了三件事——

1. 把各个正向信号加权加起来（原始正分）；
2. 乘上一个群体修正（观众群体配合得好不好）；
3. 乘上一个衰减项（有风险就扣分）。最后用 sigmoid 压到 0 到 1，方便比较。

54.4 群体状态

系统还跟踪观众群体的六个指标：

指标	含义
`alignment`	对齐度：大家的看法一致不一致
`diversity`	多样性：观点是不是单一
`reciprocity`	互惠度：有没有来回互动
`network_density`	网络密度：人群之间连得紧不紧
`common_ground`	共同基础：有没有共享背景
`mismatch`	错位度：有没有理解偏差

为什么要跟踪多样性 如果内容只吸引一种人，短期数据好看，长期会把群体压成“回音室”——大家只能说同样的话。多样性指标就是为了防止这件事。

54.5 操作过程：从 PDF 到内容库

具体做了什么：

1. **读入原始文案**：一份 22 页的 PDF，里面有 58 条口播文案。
2. **解析**：把每条文案拆成“标题 + 正文”，并识别它属于哪个栏目（K12 学习方法、家庭教育、音乐、体育、书法、编程等）。
3. **规则标注**：用关键词规则给每条打标签：
   - 结尾动作（CTA）：是在引导评论、引导领取资料，还是引导转发；

- 钩子类型：是问句、是反常识，还是负面警示；
- 情绪驱动：焦虑、损失厌恶、亲情内疚等；
- 合规风险：有没有绝对化承诺、有没有制造教育焦虑。

4. **映射成内容方案**：把标注结果换算成 4.2 节的那组 0-1 分数。

5. **分平台排序**：用不同平台的权重算出得分，排出名次。

6. **生成排期**：按“平台轮换 + 栏目去重”的规则排出 30 天日历。

规则标注是什么 “规则”就是“如果出现某个词，就打某个标签”。例如：
如果结尾出现“评论区”，就标记为引导互动；
如果出现“一定”、“必须”、“100%”，就加合规风险分。
这样做的好处是**完全可解释**——每一条标签都能说出为什么。
缺点是**不理解语义**，只能靠词面。

54.6 双口径对比：两套权重谁对

实验里做了一件很重要的事：同一批文案，用**两套权重**各排一次名。

口径	来源
实验口径	本实验自己设定的一套权重，强调完播和互动
文档口径	一份招生素材里声称的平台权重，例如“收藏率 35%、复访率 25%”

为什么要对比：因为在没有真实数据的情况下，两套权重谁对是不知道的。对比的价值在于找出“排名变化最大的那些选题”——那些就是最需要做实验验证的。

结果示例（抖音）：

编号	选题	实验排名	文档排名	变化
WX-011	孩子“一眨眼”就长大了	4	27	−23
WX-003	数学考 90 分以上的五个关键习惯	22	2	+20
WX-004	小学语文预习五步法	24	4	+20

怎么读这张表 “变化 = 实验排名 − 文档排名”。负数表示在两套口径里都排在前面（稳定）；变化大的表示口径敏感。
比如《数学考 90 分以上的五个关键习惯》，在实验口径里排第 22，在文档口径里排第 2——差了 20 名。说明这条内容的好坏高度依赖“收藏重要还是完播重要”。

54.7 招生漏斗

把“看到内容”到“报名”分成六级：

$$\text{曝光} \to \text{有效停留} \to \text{互动} \to \text{留资} \to \text{咨询} \to \text{报名} \tag{85}$$

每一级的转化率用乘法串联：

$$\text{报名数} = \text{曝光} \times r_1 \times r_2 \times r_3 \times r_4 \times r_5 \tag{86}$$

逐符号解释

r_1	曝光 → 有效停留的比例（先验值 0.30）
r_2	有效停留 → 互动的比例
r_3	互动 → 留资的比例（先验值 0.06）
r_4	留资 → 咨询的比例（先验值 0.45）
r_5	咨询 → 报名的比例（先验值 0.18）

这些数字从哪来 有的来自那份招生素材里写的行业基准（例如“5 秒完播率 30% 是基础标准”），有的是直接假设的。**全部标记为“未校准先验”，不能当预测用。**

一句重要的话：一个内容的“曝光到报名”转化率通常只有**万分之几**。所以不要指望一条视频带来很多报名——它是长期积累的事。

55 用量化交易的眼光看平台算法

55.1 一个自然的类比

量化交易（用程序买卖股票）和做内容，在结构上很像：

量化交易	做内容
市场	平台的流量池
标的（股票）	一条内容
价格	互动指标（完播、点赞、收藏）
成交量	曝光量
撮合引擎	推荐系统
交易员	创作者
杠杆	投流（花钱买曝光）
回撤	流量下滑
制度变化	平台改算法

55.2 但有五个致命差异

如果忽略下面这五条，量化框架就会被误用。

序号	差异	说明
1	没有价格	你拿到的“曝光量”是平台单方面给的，不是所有参与者同意的数字
2	看不到订单簿	你只能看到自己这一条内容，看不到同赛道有多少人在抢观众
3	平台是裁判又是对手盘	它希望你一直生产，但不保证给你回报
4	样本量差 6 个数量级	股票 5 年有 50 万根 K 线；一个创作者一年只有几百条内容
5	不可做空、不可对冲	你只能“做多”，数据差时唯一的选择是不发

第 2 条为什么最要命 在股票市场，你能看到**订单簿**——知道有多少人想买、多少人想卖。

在平台上，你**看不到同赛道有多少人在发同类内容**。

所以“这条内容是不是太拥挤了”这个判断，你**根本没有数据**。

55.3 民间算法 = 市场传言

“民间算法”指创作者圈子里流传的平台规则解读（比如各种“秘籍”“白皮书”）。

在量化里，它对应的是“技术分析流派”和“市场传言”。

用因子的标准去筛：

说法	可观测吗	容量	判定
“收藏率权重 35%、复访 25%”	否（拿不到权重）	—	不可检验
“5 秒完播率 30% 是基础线”	是	大	可检验
“7 天长效赛马”	是	大	可检验
“前 3 秒放钩子”	是	小	会衰减

最重要的一个概念：因子衰减 在量化里，一个因子一旦被广泛使用，超额收益会被套利掉。

在平台上，**民间算法的传播本身就在加速这个衰减过程：**

> 有人发现“前 3 秒放钩子”有效 → 写进白皮书、做成课程卖钱 → 所有人都在用 → 观众对钩子脱敏 → **钩子失效**

推论：公开流传的平台“秘籍”，价值已经在传播过程中被消耗掉了。

56 群体拓扑：拆闭环、留桥接

56.1 把班级看成一张图

把班级互动看成图 $G = (V, E)$：

- V：学生节点；
- E：互动边（提问、互评、讨论、求助）；
- C_i：节点 i 的局部聚类系数，衡量“我的朋友是否也互相认识”；
- Q：模块度，衡量班级是否分裂成若干封闭社区；
- B：桥接比例，跨社区边数 / 总边数；
- D_{div}：群体多样性（不同观点、强项、节奏的接触面）。

设计目标可以写成：

$$\max J = \alpha B - \beta \overline{C} - \gamma Q + \delta D_{\text{div}} + \eta \text{Var}(\text{individual growth}). \tag{87}$$

符号说明：

- $\overline{C}$：平均聚类系数；越高，越容易形成封闭小圈子；
- Q：模块度；越高，班级越分裂成抱团社区；
- B：桥接比例；越高，跨圈信息流越强；
- D_{div}：多样性；
- Var(individual growth)：个体成长差异，防止“为了群体和谐牺牲个体发展”；
- $\alpha, \beta, \gamma, \delta, \eta$：权重，需要按教学目标标定。

56.2 E4 真实结果：小圈子 vs 桥接

数据：Stanford MOOCPosts。

- 29,585 条帖子；
- 11,042 名作者；
- 62,857 条共帖边；
- 有网络指标的作者 7,148。

56.2.1 帖子触达（mean reads）模型

控制 degree 和课程固定效应：

预测变量	标准化 β	p
桥接比例 B_i	-0.096	8.7×10^{-58}
聚类系数 C_i	$+0.188$	1.6×10^{-98}
log(degree)	$+0.661$	≈ 0

56.2.2 帖子点赞（mean up）模型

预测变量	标准化 β	p
桥接比例 B_i	$+0.043$	0.0008
聚类系数 C_i	-0.012	0.400
log(degree)	$+0.038$	0.0059

关键解释 结果不是简单的“抱团坏、桥接好”：
对**触达（reads）**，小圈子作者更高；
对**认可（upvotes）**，桥接作者略高。
所以“拆闭环”要按目标选：要传播，还是要质量反馈。

56.3 边界

- 共帖网络不是真实社会关系；
- reads/up 不是学习结果；
- 这是观察性网络分析，不能直接说拆圈子导致成长；
- 19 人班级网络只有 $19 \times 18/2 = 171$ 条可能边，只能当探索性试点。

56.4 课堂 ABAB 设计

周	分组	任务
W1–W2	固定分组	基线
W3–W4	每周轮换分组	加跨组任务和桥接角色

W5–W6	再固定	看是否回到闭环
每周五	互动调查	写本周问过/讨论过的 3 个同学，其中至少 1 个跨组

56.5 “分而治之”的教育翻译

1. 定期轮换分组，打断固定小团体的路径依赖；
2. 设置跨组任务和桥接角色；
3. 小组任务必须能拆出个人贡献，避免搭便车；
4. 每个学生有自己的成长曲线，不拿圈子平均水平替代个体；
5. 保留正当合作，只禁止**封闭合作**。

57 E1–E6 实验总表与运行方法

57.1 总表

实验	状态	数据	最重要结果	产物目录
E1 教师–学生–观察者	设计 + 合成 + 功效；课堂数据待录入	实验 B 教师 AUC 先验	AUC = 0.5625，折后可信度 ≈ 0.409；MAE 优势 0.08 功效 0.891	E1_observer
E2 节律–安排匹配	真实公开数据完成	EdNet：340 人、16,335 会话	参与度 $\beta = 0.164$（$p = 8.3 \times 10^{-10}$）；退出率 $\beta = -0.0034$；$d_z = 0.572$	E2_arrangement_fit
E3 习惯改变成本	真实公开数据完成	OULAD：3,829 单元、84,095 学生–周	参与度 $\beta = -1.134$；控制当前点击后 $\beta = -0.431$；退课 $\beta = +0.233$	E3_habit_change
E4 群体拓扑	真实公开数据完成	Stanford MOOC-Posts：11,042 作者、62,857 边	触达：聚类 +0.188、桥接 −0.096；点赞：桥接 +0.043	E4_group_topology
E5 多教师 metameta	合成功效完成；真实多教师待采集	模拟 5–50 位教师	5 位教师、$sd_\tau = 0.3$ 时 ANOVA 功效 0.903	E5_multi_teacher
E6 天性/安排先验	合成 +OULAD 先验完成；真实量表待采集	19 人 × 10 次模拟；OULAD 效应量	MDES ≈ 0.35；中位效应 0.053 需约 2,789 人，最大 0.289 需约 92 人	E6_trait_prior

57.2 运行方法

在 PowerShell 里，先设好 Python 和 PYTHONPATH：

```
$b = "D:\Tender"
$py = "$b\Tender-Demo\backend\.venv\Scripts\python.exe"
$env:PYTHONPATH = "$b\experiments\platform_reverse_lab"
```

然后逐个运行：

```
& $py run_teacher_student_observer.py
& $py run_arrangement_fit.py
& $py run_habit_change_cost.py
& $py run_group_topology.py
& $py run_multi_teacher_trait.py
```

产物都在：

```
D:\Tender\experiments\platform_reverse_lab\outputs\related_experiments\
```

57.3 每个实验最少需要什么数据

实验	最少数据	注意
E1	19 学生 × 5 次：学生预测、教师预测、教师信心、实际	三方不要互相看
E2	每人 1–2 周行为日志 + 节律峰型	公开 EdNet 可先做先验
E3	每人 10 周学习节奏	OULAD 可先做先验
E4	6 周互动调查，每人每周写 3 个联系人	19 人只能当试点
E5	至少 5 位教师，每位 19 学生 × 5 次	每位教师 95 个观测
E6	MBTI 连续分数 + 节律峰型 + 任务结构偏好	不要填 16 类型

第八部分　Agent 交互层与 GitHub 教育 Agent 集成

这一部分把产品补成完整的三层技术栈：

层	角色	回答什么
DAOQL 层（底层）	事实与因果	发生了什么？因为什么？证据是什么？
Tender 层（中层）	心智化建模	学生现在是什么状态？不确定性多大？
Agent 层（上层）	交互与执行	现在该对谁说什么、做什么、怎么跟进？

58　为什么需要 Agent 层

DAOQL 负责“记事实”，Tender 负责“懂状态”，但两者都不会主动做事。Agent 层负责把 DAOQL 的事实和 Tender 的状态，翻译成对老师、学生、家长、运营可执行的动作。

一句话

DAOQL 是因果事实层，Tender 是心智层，Agent 是交互层。

没有 Agent，前两层只是数据仓库和模型；有了 Agent，才成为产品。

58.1　三层的数据契约

58.1.1　DAOQL 事件

DAOQL 只存**发生过的、可追溯的事实**，不存模型的猜测。

```
{
  "event_id": "evt_...",
  "event_type": "metacognition_jol",
  "student_id": "S01",
  "session_id": "ses_...",
  "timestamp": "2026-10-16T20:00:00+08:00",
  "payload": {"predicted_correct": 7, "n_items": 10},
  "source": "browser_plugin|teacher_card|platform|agent",
  "provenance": {"device": "...", "course": "...", "item_ids": [...]}
}
```

58.1.2 Tender 状态

Tender 把 DAOQL 事件合成为带不确定性的学生/教师/群组状态。

```
{
  "student_id": "S01",
  "timestamp": "2026-10-16T20:05:00+08:00",
  "cognitive": {"theta": 0.72, "phi": 1.20, "uncertainty": 0.08},
  "emotion": {"valence": 0.30, "arousal": 0.60},
  "metacognition": {"jol_bias": 0.08, "auc": 0.63, "hesitation": 0.42},
  "baseline": {"arrangement_fit": 0.81, "habit_change": 0.12},
  "knowledge": {"concept_id": "grammar.tense", "mastery": 0.67},
  "group": {"clustering": 0.55, "bridge_ratio": 0.21}
}
```

58.1.3 Agent 消息

Agent 之间的通信也走统一消息格式，保证可审计、可回放。

```
{
  "message_id": "msg_...",
  "from_agent": "metacognition_coach",
  "to_agent": "student_tutor",
  "student_id": "S01",
  "intent": "scaffold_hesitation",
  "evidence": {"daoql_event_ids": [...], "tender_state_version": "..."},
  "action": {"type": "prompt", "text": "你卡在哪一步？"},
  "policy": {"requires_teacher_approval": false, "max_turns": 3},
  "status": "proposed|approved|executed|rejected"
}
```

59 Agent 角色清单

Agent	对谁	主要职责	依赖层
Student Tutor Agent	学生	苏格拉底式提问、分步提示、变式练习	Tender + DAOQL + RAG
Metacognition Coach	学生	JOL、信心校准、犹豫四象限干预	Tender 元认知 + DAOQL

Assessment Agent	学生/老师	题目生成、难度标定、知识追踪更新	Tender 知识追踪 + DAOQL
Teacher Copilot	教师	班级状态摘要、干预建议、教师 metameta 反馈	Tender + DAOQL
Parent Communication Agent	家长	周报、成长曲线、隐私过滤后的沟通	Tender 聚合状态
Group Facilitator Agent	教师/学生	分组轮换、桥接角色、闭环预警	Tender 群体拓扑 + DAOQL
Content Curator Agent	教研	课标/讲义/题库入库、RAG 切片、版本管理	DAOQL + RAG
Sales/Operations Agent	机构	线索评分、onboarding、续费信号	聚合 DAOQL + 运营数据
Safety/Guardrail Agent	全部	内容安全、年龄适配、隐私、升级人工	全局策略
Data Steward Agent	工程/合规	数据质量、血缘、同意、保留与删除	DAOQL + 治理规则

60 GitHub 教育 Agent 与平台选型

60.1 教育专用层

仓库	Stars	License	能提供什么	集成方式
ECNU-ICALK/EduChat	973	无 License	中文教育对话大模型、数据清理、教育语料	参考/替换为有 License 的模型
ECNU-ICALK/EduChat-Math	59	无 License	中文多模态数学数据集与评测	作为评测集参考
classroomio/classroomio	1,719	AGPL-3.0	课程、作业、班级管理 LMS	外部 LMS，通过 API 接
moodle/moodle	7,488	GPL-3.0	全球最成熟开源 LMS	外部 LMS，通过插件/API 接
openedx/openedx-platform	8,203	AGPL-3.0	大规模在线课程平台	外部 LMS，通过 API 接
pykt-team/pykt-toolkit	450	MIT	深度知识追踪基准与模型库	直接用于 Tender 知识追踪

bigdata-ustc/EduKTM	266	Apache-2.0	知识追踪模型动物园	直接用于 Tender 知识追踪

60.2 Agent/RAG 编排层

仓库	Stars	License	能提供什么	集成方式
langchain-ai/langgraph	43,347	MIT	有状态 Agent 工作流编排	核心编排引擎
crewAIInc/crewAI	59,759	MIT	角色化多 Agent 协作	教研/运营多 Agent
microsoft/autogen	61,440	CC-BY-4.0	多 Agent 研究与实验	研究实验，注意 License
langgenius/dify	158,627	Other	低代码 Agent + RAG + 工具	快速原型/运营后台
labring/FastGPT	29,840	Other	知识库问答 + 工作流	国内部署候选
infiniflow/ragflow	92,317	Apache-2.0	文档解析 + 深度 RAG	教材/讲义/题库 RAG
open-webui/open-webui	155,868	Other	聊天界面、多模型接入	学生/教师前端
n8n-io/n8n	207,606	Fair-code	400+ 集成与自动化	CRM/通知/运营自动化

License 风险必须先说 **可直接商用：**RAGFlow（Apache-2.0）、LangGraph（MIT）、CrewAI（MIT）、pyKT（MIT）、EduKTM（Apache-2.0）。

Copyleft：Moodle（GPL-3.0）、Open edX（AGPL-3.0）、ClassroomIO（AGPL-3.0）——建议当外部 LMS 通过 API 接，不要直接改代码闭源分发。

需要法务确认：EduChat（无 License）、Dify/FastGPT/Open WebUI（Other）、n8n（fair-code）、AutoGen（CC-BY-4.0）。

原则：核心链路优先用 MIT/Apache；无 License 的模型只能参考，不能直接商用。

61 集成架构

61.1 三层部署图

Agent 交互层

Student Tutor • Metacognition Coach • Assessment • Teacher Copilot • Parent • Group Facilitator • Sales

↓

Tender 心智层

θ • Bloch 球 • 情绪 • 元认知 • 知识追踪 • 节律 • 基线 • 群体拓扑

↓

DAOQL 因果层

事件图 • 因果关系 • 证据 • 血缘 • 时间线 • 版本

61.2 推荐技术栈

能力	推荐组件	理由
Agent 编排	LangGraph	MIT、状态机清晰、可审计
多 Agent 协作	CrewAI	MIT、角色化、适合教研/运营
RAG	RAGFlow	Apache-2.0、文档解析强、国内可部署
低代码后台	Dify / FastGPT	快速搭运营和教研 Agent，注意 License
聊天前端	Open WebUI	多模型、可自托管，注意 License
工作流自动化	n8n	CRM/通知/运营集成，注意 fair-code
知识追踪	pyKT / EduKTM	MIT / Apache-2.0，直接进 Tender
教育对话	EduChat（参考）	中文教育语料强，但无 License，需替换或获授权
LMS	ClassroomIO / Moodle / Open edX	外部系统，通过 API 接，避免 AGPL/GPL 污染

62 五条核心工作流

62.1 学生辅导工作流

1. DAOQL 收到答题事件、响应时间、修改次数、JOL；
2. Tender 更新 θ、元认知偏差、犹豫 AUC、知识掌握度；
3. Metacognition Coach 判断“高犹豫/低犹豫 × 对错”；

4. Student Tutor 选择提示层级：最小提示 → 变式 → 讲解；
5. 学生行动再次写回 DAOQL，形成闭环。

62.2 教师副驾驶工作流

1. Teacher Copilot 读取班级 Tender 状态；
2. 标出“需要今天干预的 3 个学生”；
3. 给出可执行建议，并附证据链接到 DAOQL 事件；
4. 教师执行后记录结果，作为教师 metameta 的训练数据；
5. 每周给教师一份“你的判断 vs 实际结果”的校准报告。

62.3 群体促进工作流

1. Group Facilitator 读取互动调查，构建班级图；
2. 计算 C_i, Q, B，识别封闭小圈子；
3. 生成轮换分组和桥接角色建议；
4. 教师确认后执行，下一周重新测量；
5. 目标不是拆散合作，而是拆闭环、留桥接。

62.4 家长沟通工作流

1. Parent Agent 只读取聚合后的 Tender 状态；
2. 输出“本周进步、下周建议、需要家庭配合的一件事”；
3. 禁止输出诊断标签、排名、原始情绪分数；
4. 家长反馈写回 DAOQL，作为环境变量 e_t。

62.5 销售/运营工作流

1. Sales Agent 读取机构级聚合数据，不接触学生 PII；
2. 识别续费风险、招生线索、课程匹配；
3. n8n 自动触发 CRM、企微、短信、日程；
4. 所有动作留审计日志，遵守教育数据合规。

63 安全、隐私与治理

63.1 十条硬红线

1. 不把原始学生 PII 交给第三方模型；
2. 不把诊断标签展示给学生或家长；
3. 不用情绪分数做惩罚或排名；
4. Agent 不得自行修改课程标准；
5. 所有自动干预必须可回滚、可审计；
6. 未成年人数据默认最小化采集；
7. 数据出境必须走白名单和脱敏；
8. 无 License 的模型只能参考，不得直接商用；
9. AGPL/GPL 组件当外部服务接，避免污染闭源代码；
10. 任何“因果”结论必须有 DAOQL 证据链。

63.2 Human-in-the-loop

- 高风险动作（通知家长、调整分组、生成正式评语）必须教师确认；
- 低风险动作（提示、练习推荐）可以自动执行，但要记录；
- 所有 Agent 建议都带证据链接和置信度；
- 教师可以一键否决，否决本身也是训练数据。

64 产品完成路线图

64.1 MVP：8 周

周	目标	交付
W1–W2	DAOQL 事件模型 + Tender 状态服务	事件 schema、状态 schema、数据接入
W3–W4	Student Tutor + Metacognition Coach	RAGFlow + LangGraph + 合规 LLM
W5	Teacher Copilot	班级仪表盘、metameta 报告
W6	Group Facilitator + 基线耦合	互动调查、分组建议、节律匹配

W7	Safety + Data Steward	红线策略、审计日志、数据血缘
W8	ClassroomIO/Moodle 接入 + 19 人试点	端到端闭环、课堂报告

64.2 Phase 2：3 个月

- 多教师 metameta（至少 5 位教师）；
- Parent Communication Agent；
- Sales/Operations Agent（对接万象学院招生白皮书）；
- 群体拓扑 ABAB 实验；
- pyKT/EduKTM 知识追踪上线；
- 浏览器插件/移动端数据采集。

64.3 Phase 3：6 个月

- 多租户 SaaS；
- 学生成长联盟链/数字供应链；
- 平台逆向与推荐算法；
- 教育 Agent 应用商店；
- 合规认证与等保。

65 Agent 交互层的完整工程实现

这一节把前面的架构落成可运行工程。工程目录：`D:\Tender\agent_layer`。

65.1 DAOQL 因果层

已实现：

- 事件表 `events`：事件编号、类型、学生、会话、时间、载荷、来源、血缘；
- 因果边表 `causal_edges`：源事件、目标事件、关系、置信度、证据；
- 审计表 `audit_log`：谁、做了什么、目标、载荷、时间；
- `causal_path`：在因果图上做 BFS，查找“原因 → 结果”路径；
- `event_graph`：用 NetworkX 输出学生事件图。

65.2 Tender 心智层

已实现并复用项目已有模型：

- 掌握度与 θ；
- JOL 偏差、犹豫程度；
- 元认知敏感性 AUC、偏差、d'、L2 折扣（复用 `platform_reverse_lab.metacognition`）；
- 节律 R_{24}、R_{168}、平衡 B（复用 `rhythm_periodogram`）；
- 基线偏离（复用 `rhythm_baseline`）；
- 教师 metameta（复用 `metameta`）；
- 群体聚类系数与桥接比例。

65.3 Agent 运行时

- 10 个 Agent YAML 配置；
- RAG：本地 TF-IDF 字符 n-gram，可选 RAGFlow；
- LLM：OpenAI-compatible API，默认 mock，配置 `OPENAI_API_KEY` 后自动切换；
- 护栏：敏感词、PII、年龄适配、人工升级；
- 审计：每次 Agent 调用写入 `audit_log`；
- 报告：学生、教师、家长、机构四类报告。

65.4 已接入的真实数据

- 完整版手册：91,096 字，切成 115 个 RAG 块；
- 语法填空题库：1,148 行 CSV 已写成 DAOQL 事件；
- 19 名学生：种子演示生成 380 条事件；
- 已有 Tender 实验模块：元认知、节律、基线、metameta 已接入。

65.5 API 端点

端点	作用
`GET /health`	健康检查 + 事件总数
`GET /agents`	列出 10 个 Agent
`POST /daoql/events`	写入 DAOQL 事件

`POST /daoql/edges`	写入因果关系
`GET /daoql/graph/{student_id}`	学生事件图
`GET /daoql/causal_path`	因果路径查询
`GET /tender/state/{student_id}`	Tender 状态
`GET /reports/student/{id}`	学生报告
`GET /reports/teacher/{class}`	教师报告
`GET /reports/parent/{id}`	家长报告（隐私过滤）
`POST /agents/{agent_id}/invoke`	调用 Agent
`GET /audit`	审计日志
`POST /rag/search`	RAG 检索
`POST /rag/ingest`	RAG 入库

65.6 部署与验证

```
cd D:\Tender\agent_layer
python run_demo.py
python tests/run_all.py
python scripts/ingest_manual.py
python scripts/ingest_grammar_bank.py
python scripts/run_pilot.py
uvicorn app.main:app --port 8080
```

已验证：

- 4 个测试模块全部通过；
- 端到端试点通过：19 名学生、380 条事件、Tender 状态、元认知教练、学生报告；
- 手册 RAG 115 块、语法填空题库 1,148 行已入库；
- LLM 默认 mock，配置真实 Key 后切换为 OpenAI-compatible 模型。

65.7 还差什么

1. 真实 LLM Key 与模型选型；
2. 真实 LMS API（ClassroomIO/Moodle/Open edX）；
3. 19 人课堂试点；
4. AGPL/GPL/Other License 法务确认；
5. 浏览器插件/移动端采集；
6. 等保与未成年人数据合规。

完成度 **架构、手册、DAOQL、Tender、Agent、RAG、报告、护栏、审计、测试、部署骨架全部完成。**

剩下的是“接真实账号、接真实学校、跑试点”，不是从零开始。

66 产品验收清单

维度	验收标准
数据	每次事件可追溯到来源；同意、保留、导出、删除全流程可用
模型	Tender 状态有版本号和不确定性；离线校准达标
Agent	每个 Agent 有工具白名单、护栏、审计日志
集成	LMS、插件、教师卡、家长端、CRM 至少各打通一条链路
评估	离线指标 + 在线 A/B + 安全评估 + 人工抽检
商业	定价、打包、ROI、续费信号、机构隔离
合规	十条红线全部通过；无 License 风险

67 一句话总结

DAOQL 记事实，Tender 懂心智，Agent 做执行。

三层各司其职，才能把“教育数据”变成“教育产品”。

第九部分 实验复现与课堂操作

68 实验二：知识追踪基准实验（重点）

这是本文篇幅最长、也最重要的一章。它回答一个很实际的问题：

本系统的 θ 表示，和学术界成熟的方法比，到底行不行？

68.1 什么是知识追踪

知识追踪（Knowledge Tracing）要预测的是：

给定一个学生过去做过的所有题，预测他下一题做对的概率。

举例：小明做了 5 道关于“一元一次方程”的题，对错分别是“对、对、错、对、错”。知识追踪要回答：第 6 道同类题，他做对的概率有多大？

为什么这件事重要 如果能准确预测“哪道题他做不对”，系统就能：

- 只推他不会的题（不浪费时间）；
- 判断他是否真的掌握了（而不是运气好）；
- 给老师提示“这个知识点全班都没掌握”。

68.2 实验用的数据

项目	数值
数据集名称	ASSISTments 2009（美国中小学数学辅导系统的公开数据）
原始记录数	346,860 条
原始学生数	4,217 人
原始知识点数	101 个
清洗后记录数	**273,364 条**
清洗后学生数	**4,128 人**
清洗后知识点数	**81 个**
训练集	218,945 条 / 3,303 人
测试集	54,419 条 / 825 人

68.2.1 数据清洗规则

1. **删掉没有知识点标签的记录**：101 个知识点里有 20 个样本太少，保留会造成误判。
2. **去重**：同一个人对同一道题的多条重复记录只保留一条。
3. **按时间和学生排序**：必须还原出“谁先做了什么、后做了什么”。

68.2.2 为什么要“按学生”划分训练集和测试集

这一点很重要，是一个常见的错误来源：

划分方式	后果
按记录随机划分	成绩虚高。同一个学生的历史同时出现在训练和测试里，模型等于“见过答案”。
按学生划分	测试集里的学生，训练时**完全没见过**。这才反映真实使用场景。

本实验采用按学生划分（80% 学生训练，20% 学生测试）。

68.3 模型一：BKT（标准基线）

BKT 全称 **贝叶斯知识追踪**（Bayesian Knowledge Tracing），是学术界用了三十多年的经典方法。

68.3.1 核心思想

对每一个知识点，用一个“是否已掌握”的开关来建模：

状态	含义
未掌握	该知识点还没学会
已掌握	该知识点已经学会（而且不会忘记）

68.3.2 四个参数

每个知识点有四个参数，全部是概率：

符号	名称	含义
$P(L_0)$	先验掌握概率	开始做题之前，他已经掌握这个知识点的概率
$P(T)$	学习转移概率	做一道题之后，从“未掌握”变成“已掌握”的概率
$P(G)$	猜测概率	**没掌握**却答对的概率（蒙对）
$P(S)$	失误概率	**已掌握**却答错的概率（手滑）

为什么要区分“猜对”和“真会” 这是 BKT 的关键洞察。如果一个学生答对了：

- 可能是真会（掌握状态 + 正常发挥）；
- 也可能只是蒙对（未掌握状态 + 猜对）。

BKT 用概率的方式同时考虑这两种可能，所以比“答对就是会”要准得多。

68.3.3 预测公式

$$P(\text{答对})_t = P(L_t)\big(1 - P(S)\big) + \big(1 - P(L_t)\big)P(G) \tag{88}$$

逐项解释

- $P(L_t)$：第 t 步时“已掌握”的概率。
- $P(L_t)(1 - P(S))$：如果他已掌握，那么“正常答对”的概率。
- $(1 - P(L_t))P(G)$：如果他未掌握，那么“蒙对”的概率。
- 两项相加 = 总的“答对”概率。这是全概率公式的应用：把所有可能的情况加总。

68.3.4 状态更新（看到答案之后）

答对之后，掌握概率要更新：

$$P(L_t \mid \text{答对}) = \frac{P(L_t)\big(1 - P(S)\big)}{P(\text{答对})_t} \tag{89}$$

看到答案之后，还要考虑“学了一道题会不会掌握”：

$$P(L_t^+) = P(L_t \mid \text{答对}) + \Big(1 - P(L_t \mid \text{答对})\Big)P(T) \tag{90}$$

$(1 - P(S))$ 是什么 $P(S)$ 是“已掌握却答错”的概率。那么 $1 - P(S)$ 就是“已掌握且正常答对”的概率。两个数加起来是 1，这是概率的基本要求。

式 (89) 的直觉 这是一个贝叶斯更新。分子是“已掌握并且答对”的概率，分母是“答对”的总概率。相除得到“在答对的条件下，他确实掌握了”的概率。
直观理解：答对之后，“已掌握”的可信度应该上升，但不会变成 100%——因为可能只是蒙对。

68.3.5 怎么求出这四个参数：EM 算法

四个参数不是人给的，是从数据里“学”出来的。用的是一个叫 **EM 算法**的方法。

EM 算法用生活例子解释 假设你想知道“一个班有多少人真正会做这道题”，但你不能直接问。你只能看到“谁答对了”。
问题：答对的人里，哪些是真会，哪些是蒙的？
EM 算法的做法是“猜—修正”循环：

1. **E 步（估计）**：先随便猜一组参数，然后算出“每个答对的人有多大概率是真会”；
2. **M 步（最大化）**：用上一步的结果，重新算一组更合理的参数；
3. 重复 1、2，直到参数不再明显变化。

数学上可以证明，这个循环会让“数据出现的可能性”（似然）单调上升，最终收敛到一个较好的解。

为什么要跑多次（多次重启） EM 算法有一个缺点：它可能停在“局部最优”——也就是在一个小山头上停住，而没找到最高峰。
解决办法：**用不同的随机初始值跑很多次，取最好的那个**。
本实验对每个知识点跑了 3 次随机重启，每次最多迭代 50 轮。

68.4 模型二：Tender θ_seq

这是本项目的模型。它的思路和 BKT 完全不同：

对比项	BKT	Tender θ_seq
状态是什么	一个概率（0 到 1）	一个角度（0 到 π）
状态怎么变	学会就永久记住	可以上升也可以下降
答对的影响	掌握概率上升	角度下降（更清醒）
答错的影响	掌握概率下降	角度上升（更糊涂）

68.4.1 用到的公式

（1）状态递推——公式 (24)：

$$\theta_t = \theta_{t-1} + \eta \cdot \text{趋势} + \xi \cdot \text{场景切换惩罚} \tag{91}$$

（2）预测——公式 (22)：

$$P(\text{答对}) = \cos^2\left(\frac{\theta}{2}\right) \tag{92}$$

（3）默认参数（来自项目文档）：

参数	文档默认值	含义
η	0.30	每步 θ 的更新幅度
ξ	0.15	切换到新知识点时的额外惩罚
θ 初始值	由 0.65 反解	假设该知识点初始正确率约 65%

“由 0.65 反解”是什么意思 如果我们假设某个知识点的初始正确率是 65%（即 0.65），那就可以用公式 (22) 反过来求出对应的 θ：

$$0.65 = \cos^2\left(\frac{\theta}{2}\right) \implies \theta = 2\arccos(\sqrt{0.65}) \approx 1.26$$

这一步叫“反解”，是为了让模型的出发点符合该知识点的实际难度。

68.4.2 本实验实现的三个变体

为了弄清楚“是哪一部分在起作用”，实验做了三个变体：

1. **全局初始化**：所有知识点共用一个初始 θ，搜索最优的 θ_0、η、ξ。
2. **分技能初始化**：每个知识点的初始 θ 由该知识点的实际正确率反解，只搜索 η、ξ。
3. **文档默认参数**：完全采用文档给的值（$\eta = 0.3$、$\xi = 0.15$），不做任何调优。

另外还做了一个**消融实验**：把“按知识点分状态”这个设计去掉（只维护一个 θ），看性能掉多少。消融实验的作用是验证“某个设计到底有没有用”。

68.5 评测指标

68.5.1 指标一：AUC（看排序能力）

AUC 用生活例子解释 想象你把这批测试题分成两组：一组是学生实际答对的，一组是实际答错的。

现在**随机取一道答对的题和一道答错的题**，比较模型给它们打的“答对概率”：

- 如果模型给答对的那道打了更高的分，算赢；
- 如果给答错的那道打了更高的分，算输；
- 平局算一半。

AUC 就是“赢”的比例。

AUC 值	含义
0.50	等于瞎猜（模型没有区分能力）
0.60	有一点用
0.70	不错
0.80	很好
1.00	完美（现实中几乎不可能）

注意：AUC 只看“谁排在前面”，不看概率数值是否准确。一个模型可以说“这题 99% 会做”而实际只有 60%，只要排序对，AUC 仍然高。

68.5.2 指标二：RMSE（看数值准不准）

RMSE 全称“均方根误差”。公式：

$$\text{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}\left(y_i - \hat{p}_i\right)^2} \tag{93}$$

逐符号解释

N	测试样本总数（本实验 54,419）
y_i	第 i 条的实际结果。答对 $=1$，答错 $=0$
$\hat{p}_i$	模型预测第 i 条答对的概率
$y_i - \hat{p}_i$	误差。比如实际答对（1）但模型只给 0.3，误差就是 0.7
$\sum$	求和符号，把所有样本的误差平方加起来
$\frac{1}{N}$	除以样本数，得到平均值
$\sqrt{\cdot}$	开平方。这样单位回到原来的量纲

通俗理解：RMSE 就是“平均差多少”。值越小越好。

68.5.3 指标三：LogLoss（看自信程度是否合理）

LogLoss 是本文最重要的指标，因为它能抓出一种很危险的问题：过度自信。

$$\text{LogLoss} = -\frac{1}{N}\sum_{i=1}^{N}\Big[y_i \log \hat{p}_i \;+\; (1-y_i)\log(1-\hat{p}_i)\Big] \tag{94}$$

为什么这个公式能抓出“过度自信” 关键在 log（对数）的形状：log 在接近 0 的地方会急剧下降。

实际情况	模型预测	惩罚
答对	0.99	很小
答对	0.60	中等
答对	0.10	很大
答对	**0.01**	**极大**

所以如果模型用很肯定的语气说“这题他肯定不会做”，结果他做对了，LogLoss 会飙升。

数值参考 以一个只有 66% 正确率的总体为参照，如果模型只会说“永远是 66%”，LogLoss 大约 0.639。**如果模型的 LogLoss 比 0.639 还差，说明它的预测比“什么都不说”更有害。**本实验里就出现了这种情况——见 5.8 节。

68.6 实验流程

1. 读入 346,860 条原始记录；
2. 清洗，得到 273,364 条有效记录；
3. 按学生分成训练集（3,303 人）和测试集（825 人）；
4. 在训练集上：
   - 对 81 个知识点分别跑 BKT 的 EM 估计；
   - 用网格搜索找出 Tender 的最优 η、ξ（以及初始 θ）；
5. 在测试集上预测每一题的答对概率；
6. 计算 AUC、RMSE、LogLoss；
7. 做 η 敏感性扫描、分知识点对比、校准曲线。

什么是“网格搜索” 如果要找最优的 η，它可能是 0.01、0.02、0.05……任何一个值。网格搜索的做法是：**列出一串候选值，一个个试，取最好的。**

比如本实验试了 $\eta \in \{0.01, 0.02, 0.05, 0.10, 0.15, 0.20, 0.30, 0.45\}$，再和 $\xi \in \{0, 0.1, 0.25, 0.4\}$ 组合，总共试 32 种搭配。

这是最笨但在小参数空间上最可靠的方法。

68.7 实验结果

模型	AUC ↑	RMSE ↓	LogLoss ↓
全体均值（下限参照）	0.5000	0.4726	0.6388
学生历史平均分	0.6797	0.4532	0.7436
知识点平均分	0.6135	0.4634	0.6196
BKT（标准基线）	**0.6794**	**0.4487**	**0.5910**
Tender θ（全局初始化）	**0.6853**	0.4608	0.6164
Tender θ（分技能初始化）	0.6661	0.4534	0.6010
Tender θ（**文档默认** $\eta = 0.3$）	**0.6895**	0.4740	**1.1155**
Tender θ（单状态消融）	0.6444	0.4864	**1.3291**
Tender θ（分技能 + 校准）	0.6661	0.4533	0.6005
逻辑回归（控制组）	**0.7058**	**0.4416**	**0.5752**

表 110: 模型对比。箭头表示“越大越好”或“越小越好”。

“逻辑回归控制组”是什么，为什么要有它 逻辑回归是一种最基础、最简单的统计模型。

实验给它喂了几个朴素的特征：学生历史平均分、知识点平均分、做题位置、在该知识点上的尝试次数。

为什么要加它：如果 Tender 连这么简单的方法都打不过，那就说明“θ 这个表示没有带来额外价值”。

结果是：逻辑回归全面最好（AUC 0.7058）。

68.7.1 怎么读这张表

1. **按 AUC 看：**Tender（0.666–0.690）和 BKT（0.6794）基本打平，其中“文档默认参数”那一档（0.6895）还略高。
2. **按 RMSE / LogLoss 看：**Tender 明显不如 **BKT**。
3. **和逻辑回归比：**Tender 和 BKT 都不如那个简单控制组。
4. **BKT 的 0.6794 落在文献常见区间（0.67–0.70）**，说明实现是可信的，不是因为代码写错才输。

68.8 关键发现一：默认参数 η 太大了

这是整个实验最有价值的发现。

68.8.1 敏感性扫描结果

固定 $\xi = 0$，让 η 从小到大变化，观察两个指标：

η	测试 LogLoss ↓	测试 AUC ↑	说明
0.01	0.626	0.6853	
0.02	**0.616**	0.6853	校准最优点
0.05	0.638	0.6854	
0.10	0.722	0.6855	
0.20	0.953	0.6885	
0.30	**1.148**	0.6918	文档默认值
0.45	1.421	**0.6957**	排序最优点
0.60	1.549	0.6948	
0.80	1.759	0.6923	

这张表里最重要的一件事 请注意这两个指标的方向是**相反**的：

- 按 **LogLoss**（概率准不准），η 越小越好，最优点在 **0.02**；
- 按 **AUC**（排序对不对），η 越大越好，最优点在 **0.45**。

68.8.2 为什么会这样

用一句话解释这个矛盾 η 越大，θ 摆动越剧烈，预测概率越极端（越来越接近 0 或 1）。

极端预测不改变“谁排在前面”——所以排序指标（AUC）反而略有改善；
但极端预测会让概率严重偏离真实频率——所以校准指标（LogLoss）崩掉。

一个具体的例子：

η	模型说的话	实际正确率	后果
0.02	“这题 70% 会做”	70%	正确，老师可以信任
0.30	“这题 95% 会做”	70%	误导，老师会误判

68.8.3 这意味着什么

结论 文档里的 $\eta = 0.3$ **不算错，但它优化的目标不是“概率校准”。**

- 如果 Tender 只用于**排序**（比如决定今天先讲哪道题），$\eta = 0.3$ 可以接受；
- 如果 Tender 要**显示概率**给老师看，必须用 $\eta \approx 0.02$ 并做校准。

这个区别必须在产品里写清楚。

68.9 关键发现二：场景切换惩罚没有用

网格搜索的结果显示，ξ 的最优值落在边界 **0**。也就是说，“学生切换到新知识点时加一点不确定性”这条设定，在这个数据上没有带来任何增益。

可能的原因 因为模型本来就是**按知识点分别维护** θ 的。学生切换到新知识点时，这个知识点的 θ 从初始值开始——**不确定性已经通过“初始化”体现了**，再加惩罚是重复计算。

68.10 关键发现三：按知识点分状态是必要的

变体	AUC	LogLoss
按知识点分别维护 θ	0.666–0.685	0.601–0.616
只维护一个 θ（消融）	**0.6444**	**1.3291**

去掉技能维度之后，AUC 掉了 0.03–0.04，LogLoss 翻了一倍多。

结论：Tender“每个知识点各自维护 θ”的设计是需要的，不是多余的复杂度。

68.11 分知识点表现与校准曲线

68.11.1 分知识点对比

在 77 个可比知识点上，逐一对 BKT 和 Tender 算 AUC：

- Tender 更好的知识点：**42 个**
- BKT 更好的知识点：**35 个**
- 中位差：**+0.0050**（Tender 略占优）

怎么解读“互有胜负、中位持平” 这说明**两者没有谁系统性碾压谁**。不同的知识点，两种方法各有优势——可能有的知识点适合“掌握/未掌握”的二元模型，有的更适合“连续变化的角度”模型。这种结果在研究中很常见，不是失败。

68.11.2 校准曲线

校准曲线的读法：

- 横轴：模型说的答对概率；
- 纵轴：实际答对频率；
- 如果模型是可信的，这条线应该贴近 45 度对角线。

实验结果：

- **BKT**：基本贴合对角线；

- **Tender**（$\eta = 0.02$）：也接近，两端略有偏离；
- **Tender**（$\eta = 0.3$）：**严重偏离**。在预测 0.9 以上的样本里，实际正确率远低于 0.9。

这就是“过度自信”的样子 把不确定的状态说成确定的。

在教学场景里，这种错误很危险：老师会以为学生掌握了，从而跳过必要的讲解。

68.12 本实验的局限（必须说明）

1. **只测了一个来源**。完整 Tender 有四个来源（颜色、文本、序列、生理），本实验的数据只有“作答序列”，所以只测了 θ^{seq}。**这是下界，不是完整 Tender 的能力上限。**
2. **数据集不匹配**。ASSISTments 是**美国中学生的数学题**，不是中文语法填空。结论对数学知识点更可靠，对语言类要重新验证。
3. **没有和深度模型比**。像 DKT、SAKT 这类深度知识追踪方法，在这个数据集上 AUC 通常能到 0.72–0.75。本实验没有跑这些，所以**不能宣称“θ 达到了前沿水平”**。
4. **只做了一次划分**。种子固定，没有做多种子重复实验。差异在 ± 0.01 以内的比较不应过度解读。

68.13 实验得出的四条修正

序号	改什么	依据
1	把 η 从 0.30 改成 0.02 附近，并加概率校准	LogLoss 从 1.15 降到 0.62
2	ξ 默认改成 0，文档注明与分技能状态重复	网格搜索最优在边界
3	保留“按知识点分状态”	消融实验显著变差
4	教师端不显示概率，改显示等级（未掌握 / 接近 / 已掌握）	规避校准误差误导

第 4 条值得特别说明 即使调整了 η 并做了校准，模型输出的仍然是概率。但老师看到“73%”这样的数字，其实很难判断该怎么做。

改成三个等级之后：

- 老师一眼就能判断；
- 校准误差被“分级”吸收了，不会造成严重误导。

这在产品设计上叫“用合适的粒度呈现不确定性”。

69 附录：第一期复现指南

69.1 平台逆向实验

```
$env:PYTHONPATH='D:\Tender\experiments\platform_reverse_lab'
$py = 'D:\Tender\Tender-Demo\backend\.venv\Scripts\python.exe'

# 1) 重建内容库（从原始文案文本）
& $py "$base\tools\build_content_library.py"

# 2) 内容库排序 + 30 天日历 + 图表
& $py "$base\run_content_library.py"

# 3) 实验口径 vs 文档口径 排序对比
& $py -m platform_reverse_lab.dual_prior

# 4) 整合报告（含招生漏斗）
& $py "$base\run_integration.py"
```

69.2 知识追踪基准实验

```
$env:PYTHONPATH='D:\Tender\experiments\knowledge_tracing_bench'
$py = 'D:\Tender\Tender-Demo\backend\.venv\Scripts\python.exe'

# 跑基准（约 5 分钟）
& $py D:\Tender\experiments\knowledge_tracing_bench\run_benchmark.py

# 出图表与分析（约 30 秒）
& $py D:\Tender\experiments\knowledge_tracing_bench\analyze.py
```

69.3 产物位置

文件	内容
outputs/metrics.csv	各模型指标
outputs/metrics_with_lr.csv	含逻辑回归控制组
outputs/per_skill_auc.csv	分知识点 AUC
outputs/eta_sensitivity.csv	η 敏感性扫描
outputs/test_predictions.parquet	逐条预测（可做误差分析）
outputs/fig_*.png	五张图
REPORT.md	完整实验报告

70 附录：第一期实验总结

按时间顺序，本阶段完成的工作：

序号	做了什么	产出
1	用 OCR 识别了 67 页的图片版 PDF	3.6 万字文本
2	解析了 22 页的文案 PDF	58 条结构化文案
3	给每条文案做规则标注	栏目、钩子、CTA、情绪、合规风险
4	建立平台排序模型	4 个平台的评分公式
5	做了双口径对比	找出 12 条“口径敏感”选题
6	建立招生漏斗	六级转化 + 系数依据
7	检索了相关学术文献	13 个方向、带 DOI
8	**做知识追踪基准实验**	**8 个模型对比、5 张图**
9	验证了 η 参数	发现默认值偏大 15 倍
10	做了消融实验	验证“分知识点状态”的必要性
11	建立三端架构设计	教师端 / 学生端 / 销售端
12	设计了数据契约与合规清单	10 条红线
13	设计了平台化路径	链上链下边界、加盐承诺

70.1 最重要的三个数字

1. **0.02** ——η 应该改成这个值（原为 0.30）。
2. **1.15 → 0.62** ——改完之后 LogLoss 的改善幅度。
3. **42 : 35** ——Tender 与 BKT 在 77 个知识点上的胜负比。

70.2 最重要的一句话

θ 这个表示可用但不占优：排序能力和标准方法打平，概率校准还不够好。
真正的问题不在表示，而在默认参数选错了优化目标——
文档调的是“排序好看”，产品需要的是“概率可信”。

本文档由项目实际执行结果生成 | 所有数值均可在 `outputs/` 中复核

71 附录：第二期实验复现

按时间顺序：

序号	做了什么	产出

1	把量化交易框架映射到平台算法	结构映射表、五个致命差异、因子衰减概念
2	复用项目已有的 Hawkes 强度函数	`hawkes.py` 模块
3	合成回环验证	优化器能用，但有系统性低估
4	EdNet 真实事件流拟合	分支比 0.94（看似成功）
5	**三路安慰剂检验**	**发现 0.93 是假象**
6	**时间重标检验**	引入 Weibull 更新过程做竞争模型
7	模型比较	Hawkes 优于 Weibull：43/45
8	**修正结论**	Hawkes 方向对、设定有误（38% 通过）
9	尝试多尺度核	合成验证通过；EdNet 上 AIC 略好但重标无改善
10	验证昼夜周期	$\chi^2 = 23{,}155$，峰谷比 34.3 倍
11	实现昼夜调制 Hawkes	AIC 30/30 改善，但重标无改善
12	**换成会话为单位**	**分支比 0.93→0.54，KS 通过率 10%→100%**
13	阈值敏感性	6 分钟到 2 小时范围内结论稳定

71.1 最重要的四个数字

1. **0.9318 / 0.9318** — 真实的与打乱的分支比完全一样，第一处警报。
2. **38%** — 单尺度 Hawkes 的时间重标通过率，三次改进都没能提高。
3. **23,155** — 昼夜结构的卡方值（均匀应为 23）。
4. **100%** — 换成会话为单位后的通过率。

71.2 最重要的一句话

问题从来不是模型不够强，而是基本单位选错了。

前三步都在把模型改复杂，第四步是把单位换对— 而能发现“该换单位”的，是那两个检验工具。

71.3 两期手册的关系

	第一期	第二期
主题	建模与基准实验	检验与换单位
核心工具	AUC / RMSE / LogLoss	安慰剂 / 时间重标
数据	ASSISTments（数学题）	EdNet（学习事件流）
主要发现	η 默认值偏大 15 倍	基本单位应是会话
结论	概率校准比排序更重要	换单位比加复杂度更重要

本文档由项目实际执行结果生成 | 所有数值均可在 `experiments/platform_reverse_lab/outputs/` 中复核

72 附录：第三期实验与数据

72.1 主要数据实验

实验	数据	结论
会话大小分布	653 次会话	幂律（α=1.342），AIC 领先 1,140
会话内节奏	10,000+ 间隔	无疲劳，有热身（42.2s → 38.5s）
周周期	全会话	χ^2=59（星期）、781（周内小时）
参数化调制	40 人	作息解释约 1/3，AIC 最优为 7 参数
共享形状	21 人	参数减半、拟合不变；一日双峰
效应量标定	OULAD 26,074 人	中位 0.053、最大 0.289
作息周期图	EdNet 41 人	R_{24}=0.533、R_{168}=0.320、B=0.659；26 人日内主导
节律基线	EdNet 25 人	合成验证 AUC=1.0；458 个学生-日
元元评分	六种设计场景	理想执行 MC=0.950 / 现实规模 MC=0.738；两项致命缺陷被一票否决
元认知公开数据	ASSISTments 1,936 人	敏感性中位 0.585；与准确性 $r = +0.513$；求助行为不可用作信号
功效分析	模拟	N=19 只能测 $\|r\| \geq 0.605$
管线自检	合成 95 人	H1 ρ=0.627，无假阳性
JOL 公开数据（实验 A）	OSF yaguz：84+80+53+41 人	相关 0.46–0.51；难易效应 $p < 10^{-21}$；全局 JOL 不优于班平均基线
JOL 课堂功效（实验 A）	模拟 19 人 × 10 次	平均偏差 MDES = 0.10；$r = 0.5$ 功效 0.61；难易效应功效 1.00；$\delta = 0.01$/次功效 0.87
根号讲义提取（实验 B）	21 份讲义 PDF	五/七/八/九/十讲共 165 个 $\surd$ 标记；其余各讲 0
教师判断效度（实验 B）	9 篇 56–65，6 人	4 标记 vs 6 未标；AUC = 0.5625，置换 $p = 0.795$；95% CI = $[0.333, 0.812]$
学生自标元认知（实验 B）	合成自检	10 题个体 AUC SD 0.14–0.18；零模型 95% 范围 0.143–0.798；真实学生数据等待录入
难度基线 v2（实验 C）	4 套测试、30 个项目、6–7 人/题	Wilson 中位宽度 0.591；n 为 0.30/0.25/0.20 需 39/58/93 人；10 题能力 SE 0.699

残差检验自检（实验 C）	合成 300 次	Wilson 覆盖率 0.970；假阳性率 0.088（偏高，故 $p < 0.05$ 只当线索）

72.2 相关实验（E1–E6，2026-10-09）

本节把“顺应天性、教师观察者、拆闭环”三条原则推进到可复核的实验。详细报告见 `experiments/platform_reverse_lab/outputs/related_experiments/`全部相关实验执行报告`.md`。

实验	数据	真实结果	边界
E1 教师–学生–观察者	实验 B 教师 AUC 先验	AUC = 0.5625，折后可信度 ≈ 0.409	真实课堂数据待录入
E2 节律–安排匹配	EdNet：340 人、16,335 会话	参与度 $\beta = 0.164$（$p = 8.3 \times 10^{-10}$）；退出率 $\beta = -0.0034$（$p = 0.0078$）；对齐 vs 错位 $d_z = 0.572$	观察性数据；课堂 19 人只能测中等以上效应
E3 习惯改变成本	OULAD：3,829 单元、84,095 学生–周	参与度 $\beta = -1.134$（$p \approx 5.9 \times 10^{-247}$）；控制当前点击后 $\beta = -0.431$（$p = 1.9 \times 10^{-40}$）；退课 $\beta = +0.233$	观察性关联，不是随机强制改习惯
E4 群体拓扑	Stanford MOOC-Posts：11,042 作者、62,857 边	触达：聚类 +0.188、桥接 −0.096；点赞：桥接 +0.043	共帖网络不是真实社会关系；触达不是学习结果
E5 多教师 metameta	合成 5–50 位教师	5 位教师、$sd_\tau = 0.3$ 时 ANOVA 功效 0.903	真实多教师数据待采集
E6 天性/安排先验	合成 19 人 × 10 次 + OULAD 先验	19 人 MDES ≈ 0.35；OULAD 中位 0.053 需约 2,789 人，最大 0.289 需约 92 人	MBTI 只作连续先验，不作硬分类

72.3 产物位置

目录	内容
`outputs/session_model/`	会话层刻画
`outputs/session_fourier/`	参数化调制
`outputs/shared_rhythm/`	分层共享形状
`outputs/traits/`	MBTI 假设与功效分析
`outputs/oulad_traits/`	26,074 人效应量标定
`outputs/preregistration/`	预注册研究包（含采集模板）

`outputs/jol/`	实验 A：JOL 公开数据、功效分析、采集卡
`outputs/root_marks/`	实验 B：讲义 $\surd$ 提取、教师判断效度、学生自标模板
`outputs/difficulty_baseline/`	实验 C：题目难度、Wilson 区间、LOO 残差、v2 图

72.4 最重要的十二个数字

1. **1.342** — 会话大小分布的幂律指数。
2. **509.7 vs 145.8** — 自由格与参数化模型的 AIC（自由格差 364）。
3. **0.289** — OULAD 标定出的最大真实效应。
4. **0.053** — 同一批数据里的中位效应。
5. **92** — 检测 0.289 所需的学生数（现在只有 19）。
6. **0.627** — 管线自检中恢复出的真实效应（证明工具可用）。
7. **0.460–0.499** — 公开 JOL 数据中 JOL 与实际的相关系数（Exp1）。
8. 5.13×10^{-22} — Exp1 难易效应的配对检验 p：易项偏保守，难项偏过度自信。
9. **0.10** — 19 人 $\times$ 10 次课堂设计能检测的最小平均 JOL 偏差（80% 功效）。
10. **0.5625** — 教师 $\surd$ 标记预测“更难”的 AUC（9 篇）；置换 $p = 0.795$，没有显著证据。
11. **0.591** — 难度基线的 Wilson 宽度中位；要压到 0.30/0.25/0.20，需要 39/58/93 人/题。
12. **0.699** — 10 题时学生能力的解析 SE（logit）；要到约 0.308，需要约 50 题。

72.5 最重要的一句话

三个实验把“元认知”从一句口号变成了三组可复核的数字。

JOL 告诉我们：学生会预测，但预测不等于校准，也不自动优于“只说班平均”；根号告诉我们：讲义上的 $\surd$ 是教师判断，5/7 篇单词甚至没有对照，学生自标必须另采；难度基线告诉我们：6–7 人、10 题的课堂数据只能粗筛，不能精细诊断。**真正的进步不是多了一个漂亮模型，而是知道哪些结论现在还不能下。**

73 采集工具与课堂操作手册

73.1 四个采集工具

工具	路径	用途
E1 采集表	outputs/related_experiments/E1_observer/E1_teacher_student_observer.html	学生预测 + 教师预测 + 教师信心 + 实际
E4 互动调查	outputs/related_experiments/E4_group_topology/E4_group_topology_survey.html	每周写 3 个联系人 + 1 个跨组联系人
E5 多教师模板	outputs/related_experiments/E5_multi_teacher/multi_teacher_metameta_template.csv	5 位教师 × 19 学生 × 5 次
E6 天性模板	outputs/related_experiments/E6_trait_prior/trait_prior_template.csv	MBTI 连续分数 + 节律峰型 + 任务结构偏好

73.2 六周课堂流程

周	做什么	对应实验
W0	打印 E1 采集表、E4 互动调查表	准备
W1	每次测试前学生写预测，教师写预测 + 信心	E1 第 1 次
W1 周五	填 E4 互动调查	E4 基线
W2	重复 E1；开始记录电子题的响应时间和修改次数	E1、犹豫
W3	轮换分组 + 跨组任务；继续 E1	E4 干预
W4	继续轮换；做三臂外部脚手架实验（可选）	E4、外部脚手架
W5	恢复固定分组；继续 E1	E4 回退

W6	最后一次 E1 + E4；跑分分析脚本	全部

73.3 数据录入的三条硬规则

1. **先预测，后看题**：学生先写预测，教师再独立写预测和信心；
2. **预测不许改**：写错可以划掉重写，但要保留痕迹；
3. **实际对题数由老师填**：不让学生自己填，避免事后合理化。

73.4 跑分析之前先看功效

不要跳过功效 19 人 × 5 次只能测中等以上效应。

如果结果是“不显著”，先问：是真的没有效应，还是功效不够？

第三期已经给过答案：$N = 19$ 只能测 $|r| \geq 0.605$。

74 附录：第四期实验与复现

74.1 主要脚本

脚本	用途
run_teacher_student_observer.py	E1 教师–学生–观察者
run_arrangement_fit.py	E2 节律–安排匹配（EdNet）
run_habit_change_cost.py	E3 习惯改变成本（OULAD）
run_group_topology.py	E4 群体拓扑（Stanford MOOCPosts）
run_multi_teacher_trait.py	E5 多教师 metameta + E6 天性先验

74.2 主要产物目录

目录	内容
outputs/related_experiments/E1_observer/	E1 采集表、功效、合成自检
outputs/related_experiments/E2_arrangement_fit/	EdNet 会话、匹配度、图
outputs/related_experiments/E3_habit_change/	OULAD 学生–周、习惯改变、图
outputs/related_experiments/E4_group_topology/	共帖边、作者网络指标、图
outputs/related_experiments/E5_multi_teacher/	多教师模板、ANOVA 功效
outputs/related_experiments/E6_trait_prior/	天性模板、功效、恢复
outputs/related_experiments/all_related_experiments_report.md	E1–E6 完整报告

74.3 最重要的数字

1. **0.409**：教师观察的折后可信度（AUC=0.5625）。
2. **0.164**：EdNet 上节律匹配对参与度的效应（$p = 8.3 \times 10^{-10}$）。
3. **0.572**：对齐 vs 错位会话的配对效应量 d_z。
4. **-1.134**：OULAD 上习惯改变对下一周参与度的效应。
5. **-0.431**：控制当前点击后的习惯改变效应（$p = 1.9 \times 10^{-40}$）。
6. **+0.188 / -0.096**：Stanford 论坛上聚类/桥接对触达的标准化效应。

7. **0.903**：5 位教师、$sd_\tau = 0.3$ 时 ANOVA 功效。
8. **0.35**：19 人 × 10 次的 arrangement-fit MDES。
9. **2,789 / 92**：OULAD 中位/最大效应所需人数。
10. **1.342**：会话幂律指数；不是黄金比。

74.4 一句话总结

犹豫是元认知的行为证据；外部只能引出和训练，不能硬植入；
基线是用户与环境的耦合稳定点，不是固定性格；
黄金比目前只是隐喻，真正可检验的是闭环、自相似和尺度不变。

本文档由项目实际执行结果生成 | 所有数值均可在
`experiments/platform_reverse_lab/`
`outputs/related_experiments/` 中复核

75 课堂六周操作清单

周	做什么	对应实验/工具
W0	打印 E1 采集表、E4 互动调查表	准备
W1	每次测试前学生写预测，教师写预测 + 信心	E1
W1 周五	填 E4 互动调查	E4 基线
W2	重复 E1；电子题记录响应时间和修改次数	E1、犹豫
W3	轮换分组 + 跨组任务；继续 E1	E4 干预
W4	继续轮换；三臂外部脚手架实验（可选）	E4、外部脚手架
W5	恢复固定分组；继续 E1	E4 回退
W6	最后一次 E1 + E4；跑分析脚本	全部

75.1 三条硬规则

1. 先预测，后看题；
2. 预测不许改；
3. 实际对题数由老师填。

第十部分 治理与合规

76 合规红线

这一章把“不能做什么”列成一张清单。这些不是法律建议，是产品设计的自我约束。

76.1 十条红线

序号	红线	原因
R1	情绪 / 心智数据永不上链	一旦上链无法删除
R2	不可从群体信息反推出个人状态	小样本极易定位到人
R3	个体情绪状态不呈现给任何教师	贴标签会造成预期偏差
R4	学生数据不得用于任何营销触达	未成年人保护
R5	不采集未成年人生物特征	人脸 / 声纹属于敏感信息
R6	不发币、不 ICO、不证券化	金融监管
R7	学生数据不出校（离校凭证除外）	校内模式的立身之本
R8	销售端禁用学生个体数据	防止把教学数据变成营销素材
R9	教育广告禁止承诺升学、禁止制造焦虑	广告法
R10	未满 18 岁上链需监护人单独同意	未成年人保护

76.2 三条最容易被忽略的红线

76.2.1 R3：为什么教师看不到学生的情绪标签

给人贴情绪标签有两重危害：

1. **合规上**：这属于处理敏感个人信息，需要额外的合法性基础；
2. **教学上**：老师一旦认为“这个学生情绪不好”，就会不自觉地降低对他的期待——这是自我实现的预言。

正确的做法：

不要这样	应该这样
“张三情绪低落，请多关注”	“张三 • 第 9 篇 • 时态题连续 3 次未掌握”
“这个学生状态很差”	“本班今日心智化窗口偏窄，建议降低新知识负荷”

也就是说：**情绪数据参与“建议的生成”，但不呈现为任何学生的标签。**

76.2.2 R7 与“离校凭证”的例外

R7 说学生数据不出校。但有一个例外：**学生成年后，可以带走自己的成果凭证。**

触发条件必须精确 错误

理解：“离开机构就可以上链”。

为什么错：一个初二学生离开机构，他仍然是未成年人，保护要求一点没变。“离开机构”不会让一个孩子变成成年人。

正确条件：

$$\text{可签发} = \big(\text{年满 18 周岁}\big) \ \vee \ \big(\text{未满 18 但监护人与本人均同意}\big) \tag{95}$$

上链的内容范围：

可以上链	绝不上链
学习内容范围（完成 21 篇讲义）	θ、ϕ、γ、情绪色相 c
时间跨度	反思文本
掌握度变化的区间（如“提升 $\geq 15\%$”）	任何可反推心智状态的量
机构签名 + 学生标识	原始逐题对错（加盐承诺可以）

一句话总结这条边界 上链的是**“学习成果的凭证”，不是“学习过程的监控录像”。**

76.2.3 加盐承诺：为什么必须加随机数

回到第 2.6 节讲的陷阱。假设某班正确率是 62%：

做法	后果
直接存 62%	数据完全暴露
存 $H(0.62)$	**枚举 101 次就能还原**（0% 到 100%）
存 $H(0.62 \,\|\|\, \text{随机数})$	**安全**。随机数有无数种可能，无法枚举

76.3 必须排除的具体操作

在做平台研究时，有一类“看起来有效”的做法必须排除：

操作	排除原因
买特定号段的手机卡注册账号	规避平台风控
连续 7 天每天刷 2 小时同品类视频“养号”	人为制造虚假兴趣信号
组织 50 人点赞、完播	刷量
直播间安排“水军”配合逼单	虚假互动、误导消费者
“没效果退全款”这类效果承诺	广告合规风险
用愧疚感促使家长下单	操纵性营销
用数字人批量生产同质内容	低质内容治理风险

为什么这些要单独列出来 因为这些操作**在短期内确实能提升数据**，所以很有诱惑力。但它们的代价是：账号风险、法律风险，以及——研究结论会被污染。如果数据是靠刷出来的，那么“什么内容有效”这个结论就不可信了。

77 全部翻车清单

1. **第一期**：默认参数 η 太大；场景切换惩罚没有用。
2. **第二期**：自激过程看起来很美，但安慰剂和时间重标显示是过拟合；两次改进失败，最后靠“换单位”成功。
3. **第三期**：AIC 漏计参数导致结论被推翻；振幅不可识别；19 人功效不足；“单词测试零区分度”不能推广。
4. **第四期**：E5 的 Fisher-z 方差检验设定错误，改用 ANOVA；E4 的“抱团有害”假设只对了一半；MBTI 不能当天生硬约束；黄金比没有证据。

为什么保留翻车清单 因为**知道自己哪里错过，比多写一个漂亮结论更重要**。

这份手册的价值，不是它从来不犯错，而是它把错误也写下来。

第十一部分 总览、文件索引与总结

78 四期总览

期	解决什么	核心方法	最重要的结果	产物
第一期	怎么建模、怎么算指标	会话、节律、知识追踪、θ	会话是比“一次点击”更好的基本单位	全流程手册
第二期	怎么检查模型是不是骗自己	安慰剂、时间重标、换单位	自激归零是过拟合；会话模型闭合三层结构	第二期手册
第三期	怎么防止事后找理由	功效、预注册、元认知、metameta	19 人只能测 $\lvert r\rvert \geq 0.605$；元认知敏感性中位 0.585	第三期手册
第四期	怎么把信号接回系统	犹豫、外部脚手架、耦合基线、群体拓扑	顺应节律更好；改变节奏有成本；小圈子与桥接各有优势	第四期手册

79 全部文件与数据索引

79.1 四期手册

文件	内容
Tender 零基础全流程教学手册.pdf	第一期：建模与指标

Tender 零基础教学手册-第二期.pdf	第二期：检验与防错
Tender 零基础教学手册-第三期.pdf	第三期：预注册与元认知
Tender 零基础教学手册-第四期.pdf	第四期：从元认知信号到耦合基线

79.2 主要脚本

脚本	用途
run_teacher_student_observer.py	E1 教师–学生–观察者
run_arrangement_fit.py	E2 节律–安排匹配（EdNet）
run_habit_change_cost.py	E3 习惯改变成本（OULAD）
run_group_topology.py	E4 群体拓扑（Stanford MOOCPosts）
run_multi_teacher_trait.py	E5 多教师 metameta + E6 天性先验

79.3 主要产物

目录	内容
outputs/related_experiments/E1_observer/	E1 采集表、功效、合成自检
outputs/related_experiments/E2_arrangement_fit/	EdNet 会话、匹配度、图
outputs/related_experiments/E3_habit_change/	OULAD 学生–周、习惯改变、图
outputs/related_experiments/E4_group_topology/	共帖边、作者网络指标、图
outputs/related_experiments/E5_multi_teacher/	多教师模板、ANOVA 功效
outputs/related_experiments/E6_trait_prior/	天性模板、功效、恢复

80 最重要的 20 个数字

1. **1.342**：会话大小幂律指数。
2. **0.627**：管线自检恢复出的真实效应。
3. **0.605**：19 人相关分析能检测的最小 $|r|$。
4. **0.053**：OULAD 中位效应。
5. **0.289**：OULAD 最大效应。
6. **92**：检测 0.289 所需人数。
7. **0.585**：ASSISTments 响应时间的元认知敏感性中位 AUC。
8. **+0.513**：ASSISTments 元认知敏感性与准确性的相关。

9. **0.5625**：教师题目级判断 AUC。
10. **0.409**：教师观察折后可信度。
11. **0.164**：EdNet 节律匹配对参与度的效应。
12. **0.572**：对齐 vs 错位会话的配对 d_z。
13. **-1.134**：OULAD 习惯改变对下一周参与度的效应。
14. **-0.431**：控制当前点击后的习惯改变效应。
15. **+0.233**：OULAD 习惯改变对退课率的效应。
16. **+0.188 / -0.096**：Stanford 论坛聚类/桥接对触达的效应。
17. **+0.043**：桥接对点赞的效应。
18. **0.903**：5 位教师、$sd_\tau = 0.3$ 时 ANOVA 功效。
19. **0.35**：19 人 × 10 次的 arrangement-fit MDES。
20. **1.618**：黄金比；目前只是隐喻，不是本项目结论。

81 一句话总结

第一期学会“做”，第二期学会“验”，第三期学会“防”，第四期学会“接”。

犹豫是元认知的行为证据；外部只能引出和训练，不能硬植入；
基线是用户与环境的耦合稳定点，不是固定性格；
黄金比目前只是隐喻，真正可检验的是闭环、自相似和尺度不变。

本文档由四期手册和项目实际执行结果合并生成 | 所有数值均可在项目 outputs 目录中复核

第十二部分 增补：开花、结果、森林与认知构念实验

82 为什么需要这一部分

“开花、结果、森林”最早只是产品隐喻。隐喻可以帮助理解，但不能直接用于测量、预测或宣称效果。为了让它成为可检验模型，本增补做三件事：

1. 把三个隐喻拆成可观测的构念；
2. 给出公式、符号、阈值和证据等级；
3. 用公开数据和合成案例做初步检验，并明确哪些结论还不能下。

先给结论 开花不是“突然懂了”，而是知识经过重复提取、间隔、延迟保持和迁移，逐渐进入稳定认知结构。

结果不是“人多力量大”，而是不同认知结构在准确分工和协调下发生重组，产生超过个体基线的新颖且有用产出。

森林不是人数，而是不同认知能够长期共存、持续调用和重组的环境。

目前公开数据支持“继续验证”，不支持“已经证明”。

83 三个构念的正式定义

83.1 开花：从工作记忆表征到稳定认知结构

设学习者在延迟时间 t 的提取正确率为 R_t，新情境迁移成绩为 T，结构化解释或图式一致性评分为 S，认知负荷为 C。定义：

$$B = \sigma\left(\beta_0 + \beta_R \bar{R} + \beta_T T + \beta_S S - \beta_C C\right) \tag{96}$$

其中，$\sigma(z) = 1/(1+e^{-z})$ 是 Logistic 函数；$\bar{R}$ 是 24 小时、7 天和 30 天延迟提取的加权平均；$T, S, C \in [0,1]$。默认阈值取 $B \geq 0.65$，并要求 $R_{7d} \geq 0.60$、$T \geq 0.50$。

符号说明：

- B：开花得分，表示证据综合后知识进入稳定认知结构的概率性程度；
- β_0：截距；$\beta_R, \beta_T, \beta_S, \beta_C$：各证据的权重；
- R_t：延迟 t 后无提示或低提示提取正确率；
- T：换材料表面、换任务形式后是否仍能迁移；
- S：能否用结构化解释说明知识之间的关系；
- C：完成任务时的心理努力或认知负荷，越高越不利。

即时答对、熟悉感或单次自评不能代替上述证据。

83.2 结果：不同认知结构产生新组合

设群体成员 i 的独立新颖性为 $N(I_i)$，群体产出为 G，综合比例为 X，有用性为 U，交互记忆系统为 M，关系冲突为 K。定义：

$$Q = \sigma\left(\rho_0 + \rho_N \max(0, N(G) - \max_i N(I_i)) + \rho_X X + \rho_U U + \rho_M M - \rho_K K\right) \tag{97}$$

默认阈值取 $Q \geq 0.35$，并要求 $N(G) > \max_i N(I_i)$、$U \geq 0.60$、$X \geq 0.50$。

符号说明：

- Q：结果得分；

- $N(G) - \max_i N(I_i)$：群体相对最佳个体的新颖性增益；
- X：最终产出中能够追溯到至少两位成员独立贡献的比例；
- U：盲评质量或真实任务效用；
- M：群体是否知道彼此擅长什么，并能准确调用；
- K：关系冲突和协调损耗。

讨论时长、想法数量、群体满意度不能单独作为“结果”成立证据。

83.3 森林：可持续的认知重组环境

设认知多样性为 D，交互记忆为 M，贡献均衡为 E，历史重组成功为 H，趋同为 X。定义：

$$F = \sigma\left(\phi_0 + \phi_D D + \phi_M M + \phi_E E + \phi_H H - \phi_X X\right) \tag{98}$$

默认阈值取 $F \geq 0.60$，并要求 $D \geq 0.50$、$M \geq 0.50$、$X < 0.50$。

这里的森林不是人数，也不是所有成员达成一致，而是差异能够保留、知识能够被正确调用、组合能够重复发生。

84 本项目初步实验

84.1 EdNet 真实时间间隔

在 4,172 名学习者、11,495 道题和 1,247,784 条重复作答记录上，按学习者分组进行五折交叉验证并重复五次：

模型	AUC	LogLoss
基线特征	0.6648	0.6472
加入真实时间间隔	0.6839	0.6345
增量	+0.0191	-0.0127

间隔四分位的观察正确率依次为 36.0%、48.2%、52.1% 和 68.8%，并非严格单调。

84.2 ASSISTments 事件间隔代理

在 3,913 名学习者、81 个技能和 238,869 条首次后的机会记录上，用“两次同技能机会之间的其他事件数”作为间隔代理。加入该代理只带来 +0.00033 AUC 和 −0.00021 LogLoss 的增量。

因此，事件位置不能替代真实时间。产品必须记录真实时间、延迟提取和迁移任务。

84.3 群体构念评分模拟

在 10,000 个已知类别的合成案例中：

构念	AUROC	准确率	敏感度	特异度
结果	0.993	83.3%	67.1%	99.4%
森林	0.999	84.2%	68.4%	100%

这说明评分规则能够拒绝“最佳个人答案冒充群体重组”和“高趋同环境冒充森林”，但**不是**真人群体实验。

85 项目实现与数据字段

对象	机制	最小字段
工作记忆负荷	任务难度、提示、心理努力	load_estimate, effort_rating, cue_level
提取与间隔	检索、间隔、反馈	retrieval_attempt, delay, accuracy, feedback_type
认知结构	图式连接、解释、迁移	schema_links, explanation_score, transfer_context
开花判定	延迟保持 + 迁移 + 低负荷	bloom_probability, retention_7d, transfer_score
群体重组	个体基线、综合、交互记忆	member_baseline, synthesis_links, tms_score
结果判定	新颖性 + 有用性 + 组合性	novelty_gain, utility_score, result_probability
森林健康	多样性、协调、趋同	cognitive_diversity, contribution_entropy, homogenization

项目已经提供：

```
GET  /cognition/constructs
POST /cognition/assessments/{student_id}
GET  /cognition/assessments/{student_id}
```

评分结果写入 DAOQL 的 cognitive_construct_assessment 事件，并进入审计链。默认权重和阈值是待校准产品先验，不是科学常数。

86 证据边界与后续实验

不能宣称的事情 不能宣称“开花已经被实验证明”；
不能宣称“间隔越久越有效”；
不能宣称“不同人在一起就会创造”；
不能宣称“合成模拟证明了真实群体协作有效”。

下一步需要真人随机对照实验：

1. 开花：集中重复、间隔提取、间隔提取 + 结构化解释 + 迁移任务三组对照；
2. 结果：最佳成员汇总、纯头脑风暴、认知画像 + 综合支架、反趋同提示四组对照；
3. 森林：多轮协作网络追踪，测量多样性、贡献均衡、交互记忆、重组和趋同。

完整证据、公式、测量协议与参考文献见：

- Tender-认知机制学术补编-V1.2.pdf；
- Tender-认知构念实验报告-V1.0.pdf；
- experiments/cognitive_constructs_bench/REPORT.md。

开花，是知识从工作记忆进入稳定认知；
结果，是不同认知重组出单个人不会产生的新东西；
森林，是让这种重组持续发生的多样认知环境。

第十三部分 增补二：环境型多 Agent 与真桌面弹幕

87 为什么不再需要一个日常操作页面

传统 App 要求用户主动打开、查找功能、填写表单，再决定下一步。Tender 的新方向不是让用户更频繁地打开页面，而是让 Agent 存在于用户正在做的事情旁边：

后台理解状态，在恰当时机出现一句真的有用的话。

这不表示“没有控制权”。日常操作页被取消，但隐私、授权、历史和退出入口仍保留在控制面中。

88 日常产品面：桌面圆桌而不是操作页

V6.6 的日常产品面不是网页，也不是要求用户每天打开的任务面板。它由三层组成：

1. 全屏桌面弹幕层：独立于浏览器运行，始终置顶、无边框、鼠标穿透、不抢焦点；

2. 功能型 Agent 圆桌：每个 Agent 从不同专业视角给出建议；

3. 最小控制面：回复、静默、清空和退出都可以通过快捷键完成。

桌面弹幕采用浅灰半透明底和黑色文字。顶部显示本轮在场的全部 Agent，但屏幕上最多同时保留两条弹幕，其余自动排队接力。这样既保留多人协作感，又避免用户不知道该看哪一条。

一轮判断可以产生多位 Agent 的观点；用户当前只需要阅读其中最重要的两条。

89 什么时候才允许出现

允许触发的情形包括：

- 连续卡住或同类错误反复出现；
- 长时间空闲或频繁切换窗口；
- 深度专注过久，适合做一次短提取；
- 用户主动求助；
- 高风险安全情形需要升级，但普通弹幕不承担高风险沟通。

90 打扰预算

规则	含义
冷却时间	默认每 3 分钟最多一条
每日限额	默认每天最多 8 条
静默	用户可静默 30 分钟
负反馈	选择“不是这样”后立即停止当前提示并修正判断
深度工作	默认不打扰
升级	高风险内容进入安全流程，不使用普通弹幕

91 提示层级

1. 状态点：只表示“我在”，不打断；

2. 单条弹幕：一句话加一个最小动作；

3. 展开卡：用户主动查看证据和原因；

4. 对话：用户主动发起，或高风险情况下升级。

92 默认监测边界与本地归一化

桌面端在用户授权后默认提取以下行为特征：

- 前台应用类别：学习、文档、编程、视频、聊天、游戏、浏览器；
- 短任务提示：如“高考报名”“语法填空”“PDF”“数学”；
- 空闲时长；
- 前台窗口切换次数；
- 键盘和鼠标活动强度；
- 连续专注时长。

窗口标题只在本地用于归一化分类，例如把“某网站——高考报名”映射为 `study` 和“高考报名”。原始窗口标题不会上传服务器，也不写入 DAOQL。

桌面端不读取：

- 屏幕截图；
- 其他窗口正文；
- 剪贴板；
- 摄像头与麦克风；
- 文件内容。

如果未来增加 OCR、可访问性树或可穿戴设备，必须重新取得授权、完成隐私影响评估并保留退出机制。

93 功能型多 Agent 圆桌

V6.6 的圆桌成员不是同一内容的不同性格版本，而是功能型 Agent：

Agent	专业功能	典型输出
学习策略师	任务拆解、优先级、复习节奏	两分钟动作、完成条件
学科专家	知识点、先修关系、错因	卡在概念、公式、条件或计算
神经认知师	注意力、工作记忆、认知负荷	切换成本、休息窗口、单窗口策略
心理调节师	焦虑、回避、动机、自我评价	区分逃避与疲劳、降低羞耻

营养健康师	睡眠、饮食、补水、身体能量	困、饿、头痛、眼疲劳的检查
生涯规划师	专业兴趣、目标路径、长期证据	当前动作与目标专业的关系
安全保护官	隐私、身心安全、求助边界	证件信息、健康风险和升级
元认知教练	策略觉察、监控和复盘	当前策略、证据、下一步调整

93.1 Triage Agent：先分诊，再调用专家

V6.6 的 Triage Agent 先读取用户消息和行为信号，输出问题类型、置信度、风险等级、证据、替代解释和相关专家列表。专家圆桌负责配置可用专家，Triage Agent 决定本轮真正被调用的专家。

例如：

- 用户说“我很焦虑”，调用心理调节师和神经认知师；
- 用户说“数学题不会”，调用学科专家、学习策略师和元认知教练；
- 用户说“我困得看不进去”，调用营养健康师和神经认知师；
- 用户说“报名还没确认”，调用安全保护官、学习策略师和生涯规划师。

无关专家保持静默。低置信度时，Triage Agent 先提出一个最小澄清问题，不贸然调用专业 Agent。

功能型 Agent 必须输出非冗余内容。若两条建议语义相似，应合并或只保留更具体的一条。

设第 t 轮显示 N_t 条消息，语义向量为 $\mathbf{v}_i$，则语义冗余定义为：

$$R_t = \frac{2}{N_t(N_t-1)} \sum_{i<j} \cos(\mathbf{v}_i, \mathbf{v}_j)$$

其中 R_t 越高，表示重复越多。产品先用最多两条并发和低冗余约束来控制认知负荷。

94 工程接口

```
POST /ambient/plan/{student_id}
POST /ambient/feedback/{student_id}
POST /ambient/reply/{student_id}
GET  /ambient/personas
GET  /ambient/persona/{student_id}
POST /ambient/persona/{student_id}
GET  /ambient/ensemble/{student_id}
```

```
POST /ambient/ensemble/{student_id}
GET  /ambient/status/{student_id}
```

规划器必须执行冷却、每日限额和静默窗口；每个提示都要说明为什么出现，并将提示与反馈写入 DAOQL 和审计链。

95 两个首批场景

95.1 高考报名

高考报名是高利害、强截止、清单化的流程任务。Tender 只监测授权后的流程状态：距离截止还有多久、是否还有未确认事项、确认、缴费或照片审核是否完成。

弹幕示例：

> 报名截止前还有 2 项未确认。先处理最紧急的一项，不在这里展示证件号码。

安全边界：不在弹幕中展示身份证号、家庭住址、照片或支付信息；不替代官方报名系统。

95.2 提分

提分是长期学习、错点复发、最小练习和结果验证的循环。Tender 可以提醒一个最常错、最影响分数的小点，并要求用户完成一个最小练习，再用真实结果验证。

弹幕示例：

> 时间不多，先不要铺开复习。今天只处理一个最常错、最影响分数的小点。

两个场景使用不同指标：报名场景看完成率、漏项率和误提醒率；提分场景看行动恢复率、同类错点复发率和迁移表现。

96 关键指标

指标	说明
提示接受率	选择“有用”的比例
误打扰率	选择“不是这样”的比例
行动恢复率	提示后重新开始行动的比例
同类卡点复发率	同一问题在多轮中再次出现的比例
静默与退出率	用户主动关闭辅助的频率
主动求助率	用户在没有提示时主动请求帮助的比例
学习护照留存	长期记录是否被持续使用

97 V6.6 当前实现状态与验收

当前实现已经从页面级原型升级为 Windows 真桌面悬浮层：

- 独立进程运行，不依赖浏览器；
- 全屏透明、始终置顶、无边框；
- 鼠标穿透，不抢键盘焦点；
- 浅灰半透明底、黑色文字；
- 屏幕上最多同时两条 Agent 弹幕，其他自动排队；
- 顶部显示全部在场 Agent；
- 用户可按 `Ctrl+Alt+R` 回复，形成一小段功能型多 Agent 对话；
- 用户回复、反馈和静默写入 DAOQL 与审计链。

97.1 快捷键

快捷键	作用
`Ctrl+Alt+Space`	触发一轮 Agent 弹幕
`Ctrl+Alt+R`	打开回复框
`Ctrl+Alt+P`	修改 Agent 圆桌成员
`Ctrl+Alt+B`	使用当前实时行为测试一轮
`Ctrl+Alt+1`	这条有用
`Ctrl+Alt+2`	这条不合适
`Ctrl+Alt+3`	静默 30 分钟
`Ctrl+Alt+0`	清空当前弹幕
`Ctrl+Alt+Q`	退出桌面弹幕层

97.2 工程文件

```
D:\Tender\agent_layer\app\ambient.py
D:\Tender\agent_layer\app\functional_agents.py
D:\Tender\agent_layer\desktop_overlay\tender_overlay.py
D:\Tender\agent_layer\desktop_overlay\config.json
D:\Tender\agent_layer\desktop_overlay\start_overlay.ps1
```

97.3 本地监测与隐私

桌面端只使用本地归一化后的应用类别、短任务提示、空闲时长、窗口切换和输入活跃度。原始窗口标题不上传、不写入 DAOQL；不截图、不读取其他窗口正文、不读取剪贴板、不启用摄像头和麦克风。

97.4 验收结果

- 桌面窗口具备置顶、鼠标穿透、不抢焦点属性；
- 功能型 Agent 数量为 8；
- 每个 Agent 按功能生成不同内容；
- 两条并发、其余排队的弹幕调度正常；
- 灰底黑字可读；
- 回复、反馈、静默和审计事件可追溯；
- 全量 93 项自动测试通过。

97.5 边界

多 Agent 不等于多个独立科学专家。营养、心理、神经认知内容属于产品级启发式，不构成诊断或医疗建议。多 Agent 的价值不在于同时说更多，而在于在低打扰条件下调用正确的专业视角。

98 教学网站、白皮书与最新架构

Tender Academy 教学网站已经接入本地应用，入口为 `/guide/`。教学网站按白皮书架构组织，不采用普通功能目录，而是从客观世界与黑盒 API 开始，经过 DAOQL、有限接触面与 Agent Bridge，进入生命树树冠、开花、结果与知识森林。

课程主题	要回答的问题
生命树与有限世界	学习、行动和结果分别属于哪一层？
两条回路	人与世界交往和人与人交往有什么不同？
DAOQL、有限接触面与 Agent Bridge	客观事件如何变成可更正的主观体验？
生命树树冠	注意、记忆、语言、内省、情绪与身体如何被组织？
生长、开花与结果	内部理解如何进入外部世界并产生分化后果？

语言证据与 Tender 状态	话语如何成为弱证据，而不是能力判决？
知识森林	全部知识体系如何成为可探索环境？
Agent、治理与路线图	支持者如何协作，权力和风险如何受到约束？

教学网站支持中文和 English 切换、学习进度保存、知识检查和打印。教学网站本身不包含数学公式；需要严格定义的模型公式、符号表和实验边界，请阅读《Tender 项目白皮书 V1.6》。

98.1 配套文档

- 项目白皮书 V1.6：预测加工、心智化、系统架构、语言证据、知识森林、证据与治理；
- 产品手册 V6.20：产品架构、角色、Agent、数据契约、实验与验收；
- 用户手册 V6.8：第一次启用、桌面弹幕、纠正、隐私与安全；
- 本教学手册 V5.3：从零开始的环境、数据、模型、Agent 和验收流程。

98.2 本地入口

教学网站：`http://127.0.0.1:8080/guide/`
主应用：`http://127.0.0.1:8080/ui/`
白皮书：`http://127.0.0.1:8080/guide/assets/docs/Tender-Whitepaper-v1.6.pdf`
产品手册：`http://127.0.0.1:8080/guide/assets/docs/Tender-Product-Manual-v6.20.pdf`
用户手册：`http://127.0.0.1:8080/guide/assets/docs/Tender-User-Guide-v6.8.pdf`

98.3 边界

教学网站是理解系统的入口，不是临床诊断工具、教育效果承诺或固定人格测试。学习者、家庭、教师、研究人员和工程人员应通过同一套分层数据边界理解系统能力。

99 B 端与 C 端交付模型

Tender 采用“一套核心、三类交付界面”。DAOQL、语言证据、Tender 状态、生命树、知识森林、Agent 运行时、授权和审计是共享核心。不同市场只改变界面、客户、权限、数据范围和商业模式。

交付方式	界面提供方	主要能力

B 端完整系统	Tender 提供完整教育系统	招生、排课、考勤、教学、班主任、执行校长、财务、学情和组织报表
B 端嵌入模块	合作方保留原有教育系统界面	API、SDK、事件契约、单点登录、对象权限与 Agent 能力嵌入
C 端自有界面	Tender 提供移动端、网页和桌面环境层	弹幕、对话条、学习护照、长期时间线与个人 Agent

99.1 B 端两种交付方式

B 端完整系统适用于希望由 Tender 统一承接核心教育业务的机构。Tender 直接提供教育系统，机构在同一个系统中完成教学、组织、角色、财务和学情管理。

B 端嵌入模块适用于已经拥有 LMS、SIS、CRM、教务、家校或企业培训系统的机构。合作方保留原有界面和业务记录源，Tender 只嵌入完成任务所需的心智化状态、语言证据、知识森林、Agent 与治理能力。嵌入实现必须满足最小事件、对象授权、机构与个人账号分离、用户授权后再进入个人护照，以及不复制合作方全部数据库。

99.2 C 端自有界面

C 端由 Tender 提供自己的产品界面，不依附于某个机构后台。用户可以在移动端、网页、桌面环境层、对话条和低频弹幕中获得连续支持。个人学习护照、长期时间线和记录导出归属于用户，不因离开机构而丢失。

99.3 数据边界

机构购买系统不等于拥有学习者全部心智数据；合作方保留业务系统不等于 Tender 可以读取其全部数据库；个人使用 C 端也不意味着机构可以读取个人记录。购买关系、监护关系、授权关系和数据处理关系必须分别计算。